JOUR 3

Contexte long dans les modèles de langage, capital-risque et apprentissage continu

29 juillet 2026

Intervenants et thèmes principaux :

Federico Barbara — Contexte long et RoPE

Máté Mitk — Capital-risque pour fondateurs

Claire Lyle & Razvan Pascanu — Apprentissage continu

Avant-propos

Ce document restitue, dans un format pédagogique et objectif, la troisième journée de l'Eastern European Machine Learning Summer School (EEML) 2026, suivie à distance. Comme pour les journées précédentes, il ne s'agit pas d'une transcription du direct, mais d'une réorganisation thématique du contenu, reformulée dans un registre académique neutre.

La matinée a débuté par une brève présentation d'un sponsor local (l'entreprise monténégrine Coinis, spécialisée dans la génération publicitaire par IA), non reprise ici car de nature commerciale et sans lien direct avec le contenu pédagogique de l'école. La journée a ensuite comporté trois interventions principales : un exposé du chercheur Federico Barbara (Google DeepMind) sur la propagation de l'information dans les modèles de langage à contexte long ; une présentation de Máté Mitk (Credo Ventures) sur les fondements du capital-risque à destination de futurs fondateurs de startups ; puis deux interventions complémentaires sur l'apprentissage continu, la première par Claire Lyle et la seconde par un chercheur de Google DeepMind désigné dans la transcription sous le prénom de Razvan.

Une précision est nécessaire concernant la source de ce document : les notes fournies se terminaient par un long passage traitant du Reinforcement Learning et des estimateurs statistiques appris — un contenu qui correspond en réalité à la journée précédente et non à cette troisième journée. Ce passage n'a donc pas été repris ici, conformément au contenu effectivement observé dans la transcription de la journée 3. Par ailleurs, la transcription disponible ne couvre pas la fin de journée (une plage d'environ trois heures, correspondant vraisemblablement à des sessions en petits groupes, des posters ou un événement social, n'a pas été enregistrée dans les notes fournies) ; ce document se limite donc aux interventions effectivement transcrites.

Comme pour les documents précédents, le corps du texte présente une synthèse concise de chaque chapitre, tandis que les développements plus techniques sont regroupés en annexe, avec renvoi explicite depuis chaque chapitre.

Partie I — Propagation de l'information dans les modèles de langage à contexte long

Cette intervention a été assurée par Federico Barbara, chercheur chez Google DeepMind, dont les travaux ont notamment contribué à l'architecture du modèle Gemma 4.

Chapitre 1. Le problème du contexte long : entraîner court, généraliser long

Un modèle de langage prédit, à chaque position, une probabilité conditionnelle sur le prochain jeton (token) étant donné un contexte de longueur k. L'entraînement se fait nécessairement sur des séquences d'une longueur maximale fixe, mais l'objectif est que le modèle continue de fonctionner correctement sur des contextes beaucoup plus longs que ceux vus à l'entraînement.

Idées clés

- L'entraînement sur de longues séquences est coûteux (mémoire nécessaire pour les gradients et l'optimiseur), ce qui pousse à entraîner sur des contextes courts tout en espérant une bonne généralisation à des contextes longs — un problème de généralisation à part entière.

- L'attention dans les modèles de langage est causale (ou autorégressive) : chaque position ne peut porter son attention que sur les positions qui la précèdent, au moyen d'un masque triangulaire, afin d'éviter que le modèle ne « triche » en observant le jeton qu'il doit précisément prédire.
- La génération de texte procède par échantillonnage successif (autorégression) plutôt que par modélisation conjointe de toute la séquence : cette simplification, bien que coûtant en principe de l'expressivité, fonctionne étonnamment bien en pratique.

Détails et formalisation du masque causal via la fonction softmax : voir Annexe A.1.

Chapitre 2. Défaillances mécaniques : comptage, copie et effondrement de représentation

L'intervenant illustre, à partir d'exemples simples, des défaillances caractéristiques des modèles de langage sur des tâches en apparence triviales, et propose une explication mécanique à ces échecs plutôt qu'une explication liée au seul choix du tokenizer.

Idées clés

- Sur une tâche de comptage (additionner des « 1 » successifs), la précision du modèle se dégrade et finit par converger vers une prédiction constante (par exemple toujours « 100 »), quelle que soit la vraie somme, à mesure que la séquence s'allonge.
- Ce phénomène est relié à un effondrement de représentation (representation collapse) : lorsque le contexte s'allonge, les représentations internes associées à des séquences qui ne diffèrent que par un seul jeton supplémentaire deviennent quasiment identiques, ce qui empêche le modèle de distinguer ces séquences lors de l'échantillonnage — un problème aggravé par l'usage de calculs en précision numérique réduite.
- Sur une tâche de copie (reproduire un jeton donné plus tôt dans la séquence), la difficulté dépend fortement de la position du jeton à copier : contrairement à l'intuition, copier le tout dernier jeton s'avère plus difficile que copier un jeton situé au tout début de la séquence.
- Cette asymétrie s'explique par la structure du mécanisme d'attention causale : le nombre de chemins d'information reliant un jeton donné au dernier jeton de la séquence croît de façon très déséquilibrée en faveur des jetons situés en début de séquence, ce qui en fait, paradoxalement, les plus « favorisés » du point de vue de la propagation de l'information.

Détails, mesure formelle de la sensibilité (dérivées partielles, théorie spectrale des graphes) et rôle des connexions résiduelles : voir Annexe A.2.

Chapitre 3. Dispersion de l'attention et « attention sinks »

L'intervenant relie ces défaillances à un phénomène plus général de dispersion de l'attention (attention dilution), observable dès qu'une seule tête d'attention doit traiter un nombre croissant d'éléments.

Idées clés

- Mécaniquement, la fonction softmax normalise les coefficients d'attention de sorte que leur somme reste égale à 1 ; à mesure que le nombre d'éléments augmente, chaque coefficient individuel tend donc vers zéro, ce qui dilue l'attention portée à chaque élément.
- Ce phénomène peut se mesurer par l'entropie de la distribution d'attention, qui croît naturellement avec la longueur du contexte.
- Une analogie est proposée avec l'équation de la chaleur : chaque couche d'attention agit comme une étape de diffusion qui mélange progressivement l'information ; répétée sur de nombreuses couches,

cette diffusion tend à uniformiser les représentations, un résultat rattaché à la théorie spectrale des graphes.

- Pour contrer cet effet, les modèles de langage développent spontanément des « attention sinks » (puits d'attention) : certaines têtes d'attention concentrent une grande partie de leur attention sur le tout premier jeton de la séquence — un jeton dépourvu de signification propre —, ce qui revient, en pratique, à neutraliser cette tête (comportement proche d'une simple connexion résiduelle).
- Ce phénomène s'intensifie avec la taille des modèles : sur un grand modèle comportant environ 12 000 têtes d'attention au total, une analyse a montré qu'environ 80 % de ces têtes s'avèrent peu ou pas utiles, ce qui ouvre des perspectives importantes de compression des modèles sans perte notable de performance.

Chapitre 4. Les encodages positionnels rotatifs (RoPE) et leur adaptation dans Gemma 4

La seconde partie de l'exposé porte sur les encodages positionnels, présentés comme l'un des composants les plus déterminants pour la généralisation d'un modèle à des contextes plus longs que ceux vus à l'entraînement.

Idées clés

- L'encodage positionnel le plus utilisé aujourd'hui est le RoPE (Rotary Position Embedding) : il fait tourner, par blocs de deux dimensions, les vecteurs de requête et de clé à des vitesses (fréquences) différentes selon la dimension considérée, de sorte que le produit scalaire d'attention entre deux positions ne dépende que de leur distance relative.
- L'article original justifiait ce choix par une propriété de décroissance du produit scalaire avec la distance, censée reproduire un biais linguistique naturel (l'attention portée aux mots proches). L'intervenant montre cependant que cette propriété de décroissance ne se vérifie pas dans le cas général, mais seulement pour des choix particuliers de vecteurs.
- L'analyse empirique révèle que le modèle utilise préférentiellement les fréquences basses (rotation lente) pour transmettre une information stable sur de longues distances, et les fréquences hautes (rotation rapide) pour une attention très locale.
- Le problème de généralisation au contexte long s'explique alors ainsi : un modèle entraîné avec une fréquence de base donnée, puis testé sur un contexte beaucoup plus long que celui de l'entraînement, voit ses composantes de basse fréquence effectuer plus d'un tour complet de rotation, ce qui casse les motifs d'attention appris à l'entraînement.
- La solution retenue, intégrée dans Gemma 4, consiste à neutraliser (mettre à zéro) les fréquences les plus basses plutôt que de simplement augmenter la base numérique du RoPE comme le faisaient certaines approches antérieures — une correction validée par une analyse mécaniste plutôt que par un réentraînement à grande échelle de modèles géants.

Détails mathématiques sur la matrice de rotation par blocs et la mesure de la norme des fréquences utilisées : voir Annexe A.3.

Partie II — Notions de capital-risque pour futurs fondateurs

Cette intervention a été assurée par Máté Mitk, de Credo Ventures, un fonds de capital-risque investissant depuis 2010 dans des équipes fondatrices ayant au moins un cofondateur originaire d'Europe de l'Est.

Chapitre 5. Pourquoi et comment lever des fonds de capital-risque

Idées clés

- Le capital-risque répond à un problème précis : certaines entreprises ne peuvent pas croître de façon organique et progressive (contrairement à une entreprise familiale) car leur modèle n'atteint son plein potentiel qu'à partir d'une certaine échelle (l'exemple cité est Uber, dont le service n'a de sens qu'avec un grand nombre de chauffeurs déjà présents).
- Toute entreprise financée par capital-risque doit, en théorie, viser une issue exceptionnelle (un « outlier ») : l'ensemble du modèle économique des fonds de capital-risque repose sur un petit nombre de réussites majeures compensant les échecs, plus fréquents, des autres investissements.
- Une alternative existe : l'autofinancement (bootstrapping), qui évite la dilution du capital mais reste statistiquement rare pour atteindre une valorisation d'un milliard de dollars (« licorne ») ou plus.
- Les étapes classiques de levée de fonds progressent par montants et exigences croissants : un tour de pré-amorçage (quelques collaborateurs, un budget limité pour valider une hypothèse), un tour d'amorçage (une fois la technologie validée et les premiers clients pilotes identifiés), puis une série A (généralement conditionnée à un revenu récurrent annuel significatif) et les séries suivantes.

Chapitre 6. Évaluer une opportunité : questions clés et études de cas

L'intervenant propose un ensemble de questions destinées à évaluer si un projet mérite d'être financé par capital-risque, inspirées des sept questions attribuées à l'investisseur Peter Thiel.

Questions clés évoquées

- La solution proposée est-elle nettement meilleure (dans l'idéal, un ordre de grandeur) que ce qui existe déjà sur le marché ?
- Pourquoi maintenant ? Cette question s'examine sous deux angles : pourquoi l'entreprise n'a-t-elle pas pu être créée plus tôt (la technologie ou le marché n'étaient pas encore prêts), et pourquoi n'existe-t-il pas déjà un concurrent équivalent qui réussit (auquel cas il convient de comprendre pourquoi des tentatives antérieures ont échoué) ?
- L'équipe fondatrice est-elle la mieux placée pour résoudre ce problème précis ? Pour des produits à forte composante de recherche, la légitimité technique de l'équipe est un critère déterminant ; pour des produits plus commerciaux, la vitesse d'exécution devient le facteur clé.
- Le marché adressable est-il suffisamment grand ? L'intervenant illustre ce point par un calcul de coin de table (nombre d'utilisateurs potentiels × taux de pénétration réaliste × prix), en insistant sur le fait qu'une modélisation trop sophistiquée est peu utile à un stade précoce : ce qui compte est de démontrer que le problème adressé est suffisamment important.

Études de cas évoquées

- ElevenLabs (technologie de synthèse vocale par IA) : investissement réalisé alors que l'entreprise ne disposait que d'un seul GPU ; la validation reposait sur le caractère nettement plus naturel de la voix produite par rapport aux solutions existantes, et sur la conjonction d'une équipe combinant expertise technique en modèles audio et expérience commerciale.

- Une société de trading algorithmique (issue d'anciens chercheurs en IA appliquée au poker) ayant réorienté une expertise en modélisation de l'incertitude vers les marchés financiers, avec une équipe jugée exceptionnellement dense en talents, bien que la défendabilité à long terme d'un tel positionnement reste, de l'aveu de l'intervenant, difficile à garantir dans un marché aussi concurrentiel.

L'intervenant conclut en rappelant qu'au-delà du produit, la réussite d'une startup dépend aussi de la capacité à comprendre et à convaincre un marché, et que le choix des cofondateurs mérite une attention comparable à celle portée au produit lui-même, étant donné l'engagement de long terme qu'implique cette aventure.

Partie III — Apprentissage continu

Cette dernière partie de la journée a réuni deux interventions complémentaires sur l'apprentissage continu (continual learning) : la première par Claire Lyle (Google DeepMind, docteure d'Oxford), la seconde par un chercheur de Google DeepMind désigné dans la transcription sous le prénom de Razvan, dont le parcours (doctorat avec Yoshua Bengio à Montréal, travaux sur les réseaux récurrents) évoque celui du chercheur Razvan Pascanu, sans que son nom complet soit confirmé explicitement dans les notes disponibles.

Chapitre 7. Pourquoi apprendre en continu ? Motivations et défis fondamentaux

Motivations

- Le monde change, et les connaissances d'un modèle figé à un instant donné se périment (l'exemple donné est celui d'un modèle interrogé sur le monarque du Royaume-Uni, dont la réponse correcte évolue avec le temps).
- De plus en plus de systèmes apprennent de leur propre expérience (agents de RL, robots), ce qui génère naturellement des données dont la distribution change au fil de l'apprentissage — un robot apprenant à nager, par exemple, ne rencontre pas les mêmes situations en début et en fin d'entraînement.

Deux défis fondamentaux

- Se souvenir du passé : un défi documenté depuis les années 1990, qui touche les réseaux de neurones nettement plus que les systèmes humains.
- Conserver la plasticité, c'est-à-dire la capacité du réseau à continuer d'apprendre de nouvelles choses efficacement — une capacité qui, comme la plasticité cérébrale, tend à se dégrader avec l'expérience accumulée si rien n'est fait pour la préserver.

L'intervenante souligne également un défi méthodologique propre au domaine : construire des bancs d'essai (benchmarks) qui capturent une notion utile de non-stationnarité sans pour autant reproduire un environnement trop désordonné pour permettre des expériences contrôlées — d'où le recours fréquent à des séquences de tâches définies artificiellement (par exemple en découpant un grand jeu de données en sous-ensembles de classes présentés successivement).

Chapitre 8. L'oubli catastrophique

L'oubli catastrophique désigne la dégradation des performances d'un réseau sur une tâche déjà apprise, lorsqu'il est ensuite entraîné sur une nouvelle tâche sans qu'on le lui rappelle.

Explication et illustration

- Ce phénomène provient du fonctionnement même de la descente de gradient : à chaque étape, l'ensemble des paramètres du réseau est mis à jour, sans distinction entre les paramètres réellement nécessaires à la nouvelle tâche et ceux qui restent utiles à d'anciennes tâches.
- Une illustration présentée porte sur une version incrémentale du jeu de données MNIST (chiffres manuscrits) : en entraînant un réseau successivement sur les paires de chiffres 0-1, puis 2-3, etc., on observe que les gradients associés à des tâches différentes pointent dans des directions largement opposées, ce qui explique l'interférence entre tâches.
- Une lecture complémentaire, en termes de paysage de perte, montre qu'il n'existe aucune raison, a priori, pour qu'une trajectoire d'optimisation trouvant une bonne solution pour une tâche conduise également à une bonne solution pour une autre tâche non corrélée.

Trois grandes catégories de solutions

- La régularisation : pénaliser les mises à jour de paramètres jugés importants pour les tâches précédentes (en s'appuyant, par exemple, sur une approximation de la courbure du paysage de perte), afin de privilégier des directions bénéfiques aux anciennes et aux nouvelles tâches à la fois.
- Le rejeu de données (replay) : conserver et réutiliser des données des tâches précédentes pendant l'entraînement sur de nouvelles tâches — une solution simple, souvent très efficace, à condition que le stockage des données reste possible.
- La réinitialisation périodique : repartir d'un réseau réinitialisé et le réentraîner sur l'ensemble des données collectées jusqu'ici, une approche proche d'un nouvel apprentissage supervisé classique, efficace si l'on peut se permettre d'attendre la convergence sur un ensemble de données plus large.

Chapitre 9. La perte de plasticité

La plasticité désigne la capacité d'un réseau de neurones à continuer d'apprendre efficacement de nouvelles tâches. Contrairement à l'intuition, cette capacité, présente à l'initialisation, peut se dégrader au fil de l'entraînement — un phénomène distinct de l'oubli catastrophique.

Deux formes de perte de plasticité identifiées

- La première forme, la plus radicale, correspond à un effondrement complet de l'entraînabilité du réseau : dans une expérience où un réseau doit mémoriser des étiquettes réattribuées aléatoirement à intervalles réguliers, la perte associée à un second cycle d'apprentissage se stabilise à un niveau correspondant à une prédiction uniforme, avec une proportion importante de neurones ReLU définitivement inactifs (« morts »).
- La seconde forme, plus subtile, est liée à un phénomène de surapprentissage précoce : un réseau entraîné d'abord sur une partie seulement d'un jeu de données, puis sur l'ensemble complet, finit par généraliser moins bien qu'un réseau entraîné directement sur l'ensemble des données dès le départ — alors même que l'ajout des données supplémentaires aurait dû, en théorie, améliorer la généralisation.

Mécanismes et remèdes évoqués

- La première forme de perte de plasticité est liée à un déplacement de la distribution des pré-activations hors de la plage attendue par les non-linéarités (proche d'une distribution centrée, de variance unitaire) ; des changements de tâche très marqués peuvent, combinés aux statistiques adaptatives d'optimiseurs comme Adam, provoquer des mises à jour de paramètres démesurées immédiatement après un changement de tâche.
- Des mesures de contrôle simples — normalisation des caractéristiques, légère régularisation (weight decay) pour limiter la croissance de la norme des paramètres, taux d'apprentissage maîtrisé — permettent, combinées, de maintenir une plasticité stable sur de très nombreuses tâches successives.
- La seconde forme de perte de plasticité, liée au surapprentissage précoce, peut être largement atténuée par une réaugmentation temporaire (warm-up) du taux d'apprentissage lors de l'ajout de nouvelles données, une intervention qui permet au réseau de retrouver une bonne capacité d'apprentissage de caractéristiques plutôt que de rester bloqué dans un minimum trouvé prématurément.
- Il existe des indices que ces phénomènes affectent également les grands modèles de langage (par exemple une moindre facilité à affiner un modèle sur-entraîné au sens des lois d'échelle de Chinchilla), ce qui relie ces observations à des enjeux pratiques d'entraînement à grande échelle.

Chapitre 10. Solutions et implications pour les grands modèles de langage

Au-delà de l'apprentissage par mise à jour des poids, les grands modèles de langage disposent d'une autre forme d'adaptation : l'apprentissage en contexte (in-context learning), qui se produit au moment de l'inférence plutôt que pendant l'entraînement.

Idées clés

- En fournissant à un modèle plusieurs exemples dans son contexte, celui-ci est souvent capable d'ajuster ses réponses en conséquence, sans aucune mise à jour de ses poids — une forme d'adaptation distincte de l'apprentissage continu classique, mais qui n'est pas exempte des instabilités observées lors de l'entraînement par descente de gradient.
- Cette capacité reste cependant limitée : une expérience simple montre que si l'on indique explicitement à un modèle qu'une de ses réponses précédentes était incorrecte, seule une fraction des modèles actuels parvient effectivement à corriger sa réponse lorsqu'on l'interroge à nouveau.
- Des travaux récents montrent qu'il est possible d'entraîner spécifiquement des modèles à mieux exploiter les informations correctives présentes dans leur contexte, ce qui améliore, sans le résoudre totalement, ce problème.
- Ce chapitre rejoint directement la problématique du contexte long abordée par Federico Barbara en début de journée : à mesure que le contexte s'allonge, il devient également plus difficile pour un modèle de retrouver et d'exploiter correctement l'information pertinente qui s'y trouve.

Chapitre 11. Apprentissage continu, durabilité et efficacité

La seconde intervention sur l'apprentissage continu élargit la discussion en interrogeant les limites du paradigme actuel, dominé par la mise à l'échelle (scaling), et propose l'apprentissage continu comme piste de réponse à plusieurs de ces limites.

Motivations complémentaires évoquées

- Une motivation liée à la durabilité environnementale : la consommation énergétique cumulée des centres de données mondiaux serait comparable à celle d'un pays comme le Japon, et leur consommation d'eau douce soulève des enjeux similaires, ce qui interroge la viabilité d'une croissance fondée uniquement sur la mise à l'échelle des modèles.
- Une justification plus formelle, empruntée à un article de Benjamin Van Roy : dans la mesure où le monde qu'un agent cherche à modéliser contient nécessairement cet agent lui-même, aucun modèle, aussi grand soit-il, ne peut représenter le monde dans son intégralité ; le problème de l'apprentissage devient donc, par nature, non stationnaire et continu.
- L'intervenant nuance toutefois cette justification en mettant en garde contre une conclusion hâtive selon laquelle il suffirait de choisir une tâche suffisamment complexe pour garantir un apprentissage continu utile ; la complexité perçue d'une tâche ne coïncide pas nécessairement avec sa réelle difficulté d'apprentissage, ni avec la complexité de la politique optimale qui la résout.

Repenser l'efficacité de l'apprentissage

- L'intervenant invite à ne plus définir l'efficacité d'un système d'apprentissage uniquement par rapport à un objectif statique (converger vers un état de l'art fixé sur un jeu de données donné), mais par la vitesse à laquelle un système parvient à suivre un monde qui continue de changer.
- Il rapproche cette idée d'un travail de Thomas Griffiths sur l'intelligence humaine, dont la thèse est que les limitations de calcul et d'énergie propres aux humains ont façonné, plutôt que contraint

négativement, les stratégies cognitives qu'ils emploient — notamment le recours systématique à la décomposition de problèmes complexes en sous-tâches.

- Le célèbre 37e coup joué par AlphaGo contre Lee Sedol illustre cette idée par contraste : contrairement à un joueur humain, qui aborde le jeu via une décomposition en sous-objectifs, AlphaGo optimise directement la victoire globale par une recherche brute, ce qui lui permet d'accéder à des solutions hors du répertoire compositionnel typiquement humain — la compositionnalité humaine, bien qu'efficace, ayant elle-même un coût en termes de solutions inaccessibles.
- L'intervenant illustre enfin, par une analogie avec un jeu de tir à la corde, comment la descente de gradient standard réalise un compromis entre les signaux parfois contradictoires fournis par différents exemples ou différentes tâches ; lorsqu'un mode de la distribution de données est absent (as en apprentissage séquentiel), ce compromis disparaît temporairement, ce qui explique une partie des interférences observées entre tâches apprises successivement.

Conclusion générale

Bien que couvrant des domaines très différents — architecture des modèles de langage, financement des startups, apprentissage continu —, les interventions de cette troisième journée partagent un intérêt commun pour les limites concrètes des systèmes actuels, qu'il s'agisse de limites mécaniques, économiques ou statistiques.

Fils conducteurs de la journée

- L'exposé de Federico Barbara illustre comment des choix architecturaux en apparence techniques (masquage causal, encodage positionnel) déterminent directement les capacités et les limites concrètes des modèles de langage actuels, y compris sur des tâches en apparence triviales.
- L'intervention sur le capital-risque rappelle que la réussite d'une innovation technique dépend aussi de facteurs extérieurs à la technique elle-même : la taille du marché, le moment de lancement, et la composition de l'équipe fondatrice.
- Les deux interventions sur l'apprentissage continu convergent vers un même constat : la descente de gradient standard, bien adaptée à un cadre d'apprentissage statique et bien mélangé, se comporte mal dès que la distribution des données change au fil du temps — que ce soit par oubli des tâches passées ou par perte de la capacité à apprendre de nouvelles tâches.
- Un fil plus large relie l'ensemble de la journée aux journées précédentes : dans chaque cas, la compréhension fine des mécanismes internes des réseaux de neurones (géométrie des représentations, dynamique du gradient, comportement de l'attention) permet d'expliquer, et souvent de corriger, des comportements qui semblent d'abord mystérieux ou arbitraires.

Ce document restitue les notions abordées dans un cadre pédagogique et objectif ; certains échanges avec le public, ainsi qu'une partie de la fin de journée non transcrite, n'ont pu être que partiellement ou pas du tout restitués dans les notes disponibles.

Annexe — Approfondissements par chapitre

Cette annexe reprend, chapitre par chapitre, les développements techniques qui étayent les synthèses présentées dans le corps du document.

A.1 — Le masque causal et la fonction softmax (complément du chapitre 1)

Formellement, l'attention repose sur une matrice de scores obtenue en multipliant les matrices de requêtes (Q) et de clés (K), de dimensions n × d chacune, ce qui produit une matrice n × n. Pour rendre l'attention causale, les scores correspondant à des positions futures (le triangle supérieur de cette matrice) sont fixés à moins l'infini avant l'application de la fonction softmax, qui les convertit alors en une probabilité quasi nulle. Ce mécanisme garantit que la prédiction à une position donnée ne peut dépendre que de l'information disponible aux positions antérieures, condition nécessaire à un entraînement cohérent avec la tâche de génération autorégressive.

A.2 — Sensibilité et propagation de l'information (complément du chapitre 2)

Pour quantifier formellement l'asymétrie de propagation de l'information selon la position, l'intervenant propose de mesurer la dérivée partielle de la représentation finale (au dernier jeton) par rapport à chaque jeton d'entrée. Cette dérivée peut s'interpréter comme une somme pondérée sur l'ensemble des chemins reliant, à travers les différentes couches d'attention, un jeton donné au dernier jeton de la séquence — un résultat qui se rattache formellement à la théorie spectrale des graphes.

Un pic particulier de sensibilité est observé pour l'avant-dernier jeton de la séquence, expliqué par la présence des connexions résiduelles, qui ajoutent artificiellement un poids supplémentaire à la diagonale de la matrice d'attention (chaque position « voit » toujours, au minimum, sa propre représentation grâce à ces connexions).

A.3 — RoPE : détails mathématiques (complément du chapitre 4)

Le RoPE construit une matrice de rotation par blocs diagonaux de taille 2×2, chaque bloc correspondant à une fréquence de rotation différente : les blocs associés aux indices les plus bas tournent lentement (environ 1 radian par jeton), tandis que les blocs associés aux indices les plus élevés tournent à une vitesse d'environ 1/θ radian par jeton, où θ (theta) est un grand nombre de base (typiquement de l'ordre de 10 000, parfois davantage).

Cette matrice étant orthogonale, ses puissances successives correspondent simplement à des multiples de la rotation initiale, ce qui rend son application très efficace en pratique et garantit, par construction, que le produit scalaire d'attention entre une requête à la position i et une clé à la position j ne dépend que de la distance relative j − i.

L'analyse empirique présentée mesure la norme de chaque bloc de fréquence dans les requêtes et les clés apprises par un modèle entraîné : cette norme révèle une structure nette, certaines têtes d'attention utilisant préférentiellement les hautes fréquences (attention très locale, y compris une tête observée ne portant attention qu'à elle-même, ou une autre spécialisée dans la détection d'un caractère spécifique tel que l'apostrophe), d'autres préférant les basses fréquences pour transmettre une information stable sur de longues distances. Ce sont précisément ces composantes de basse fréquence qui, en subissant plus d'un tour complet de rotation lorsque le contexte dépasse largement la longueur d'entraînement, perdent leur

cohérence — d'où la solution retenue de les neutraliser plutôt que d'ajuster uniformément la base θ, comme le faisaient certaines méthodes antérieures (approches dites « NTK-aware »).