JOUR 4

Calcul haute performance, IA en biomédecine et en mathématiques, RL et estimation statistique

30 juillet 2026

Intervenants et thèmes principaux :

NCC Monténégro / EuroCC — Calcul haute performance

Maria Brbić (EPFL) — IA pour la biomédecine

UiPath — Agents d'automatisation informatique

Matia Tapušković (Oxford) — IA pour les mathématiques

Kyunghyun Cho (NYU) — Statistics Upside Down

Introduction et programme de la journée

Ce chapitre propose une synthèse organisée de la quatrième journée de l'école d'été EEML 2026, tenue à Cetinje, au Monténégro. Le programme a comporté une conférence d'ouverture consacrée au calcul haute performance, deux conférences principales portant respectivement sur l'intelligence artificielle appliquée à la biomédecine et sur l'apprentissage automatique appliqué aux mathématiques, une présentation d'un partenaire industriel sur les agents d'automatisation informatique, ainsi qu'un ensemble de notions fondamentales relatives à l'apprentissage par renforcement et aux méthodes d'estimation statistique apprises par réseaux de neurones.

Programme de la journée

- Ouverture — Le rôle des centres de compétence en calcul haute performance (NCC Monténégro / EuroCC)
- Conférence — L'intelligence artificielle au service de la biomédecine (Maria Brbić, EPFL)
- Présentation partenaire — Les agents d'automatisation informatique (UiPath)
- Conférence — L'apprentissage automatique au service des mathématiques (Matia Tapušković, Université d'Oxford)
- Notions fondamentales — L'apprentissage par renforcement, du cadre théorique à l'alignement des grands modèles de langage
- Tutoriel pratique — Implémentation progressive d'algorithmes de RL
- Conférence — « Statistics Upside Down » : apprendre des estimateurs statistiques (Kyunghyun Cho, NYU)

Ouverture : le calcul haute performance au service de la recherche

La journée a été ouverte par une présentation du centre national de compétences (NCC) en calcul haute performance du Monténégro, porté conjointement par l'Université de Donja Gorica et l'Université du Monténégro. Ce centre s'inscrit dans le réseau européen EuroCC, financé à l'origine par les programmes Horizon Europe puis Europe numérique, dans le cadre de l'initiative commune EuroHPC. Le budget de ce programme est estimé à environ 60 à 65 millions d'euros, pour plus de 35 pays participants.

Ces centres nationaux ont pour mission de donner accès aux chercheurs, aux entreprises et au secteur public à des ressources de supercalcul européennes (parmi lesquelles Jupiter, LUMI en Finlande ou Leonardo en Italie), ainsi que de proposer des formations à leur utilisation. L'accès est ouvert à la recherche académique comme à l'industrie, à la seule condition que l'usage ne soit pas directement commercial. Initialement centré sur le calcul haute performance, le programme EuroCC couvre désormais également l'analyse de données à grande échelle et l'intelligence artificielle, notamment via l'émergence des « usines d'IA » (AI factories) dans plusieurs pays européens.

L'intervenant a souligné qu'au Monténégro, l'usage du calcul haute performance était quasiment inexistant avant la mise en place du centre, la plupart des acteurs locaux considérant leurs besoins couvrables par une infrastructure informatique classique. La diffusion rapide de l'apprentissage automatique a depuis largement changé cette perception : une trentaine à une quarantaine d'entreprises locales utilisent aujourd'hui ces ressources, dans des domaines aussi variés que l'agriculture, la médecine, le tourisme, le patrimoine culturel ou le marketing numérique.

Conférence — L'intelligence artificielle au service de la biomédecine

Intervenante : Maria Brbić, professeure adjointe en informatique et sciences de la vie à l'École polytechnique fédérale de Lausanne (EPFL), Suisse.

Contexte : une révolution des données biologiques

La conférence a débuté par un état des lieux des avancées technologiques récentes en biologie moléculaire, en particulier le séquençage de l'ARN à l'échelle de la cellule unique (« single-cell RNA sequencing »). Cette technologie permet de mesurer l'expression des gènes dans des centaines de milliers, voire des millions de cellules individuelles au cours d'une même expérience, alors que les techniques antérieures ne donnaient accès qu'à une expression génique moyennée sur des populations cellulaires entières — une limite importante lorsque ces populations sont hétérogènes, par exemple dans le cas d'une tumeur mêlant cellules malades et cellules saines.

Au-delà du transcriptome, les technologies actuelles permettent également de mesurer d'autres modalités biologiques : le protéome, l'épigénome (via l'accessibilité de la chromatine, qui renseigne sur l'activité de régulation génétique), ainsi que l'organisation spatiale des cellules au sein des tissus. Cette diversification des modalités mesurables, couplée à l'essor des méthodes d'intelligence artificielle, ouvre selon l'intervenante un moment particulier pour tenter de relier ces différentes échelles d'observation — moléculaire, cellulaire, tissulaire — afin de mieux comprendre le fonctionnement du corps humain, sain ou malade.

Relier transcriptome et morphologie cellulaire

Le premier axe de travail présenté vise à établir un lien quantitatif entre le profil transcriptomique d'une cellule (l'expression d'environ 20 000 gènes) et sa morphologie nucléaire. Ce travail s'appuie sur une technologie développée en laboratoire, nommée IRIS, qui permet d'obtenir pour une même cellule à la fois une image à haute résolution et son profil d'expression génique complet, par imagerie de cellules encapsulées dans des gouttelettes microfluidiques.

Le nombre d'échantillons appariés (image et transcriptome pour une même cellule) restant limité — de l'ordre de 10 000 —, l'approche retenue consiste à entraîner séparément un encodeur puissant pour chaque modalité avant d'apprendre la relation entre les deux représentations. Pour l'encodage transcriptomique, l'équipe s'appuie sur des modèles de fondation existants pour la biologie unicellulaire (par exemple des « embeddings cellulaires universels » ou des modèles de type scGPT), ainsi que sur des modèles plus simples comme scVI. Pour la morphologie nucléaire, faute de modèle de fondation disponible publiquement, l'équipe a entraîné son propre encodeur : un transformeur de vision d'environ 300 millions de paramètres, pré-entraîné par auto-encodage masqué sur plus de 22 millions d'images de noyaux cellulaires, avec le soutien de ressources de calcul suisses (environ 10 000 GPU H100).

Prédire la réponse des cellules aux perturbations

Un second axe, présenté comme un objectif central du domaine, concerne la prédiction de la réponse d'une cellule à une perturbation — modification de l'expression d'un gène, administration d'un médicament, etc. L'intervenante a indiqué que les méthodes existantes obtiennent, sur des perturbations génétiques non vues à l'entraînement, des performances de corrélation nettement inférieures à celles rapportées sur des tâches plus favorables, ce qui traduit une difficulté persistante à généraliser à de nouvelles perturbations. Ce constat a conduit l'équipe à s'interroger plus largement sur la fiabilité des métriques utilisées pour évaluer ce type de modèles en biologie.

Mesurer la similarité des représentations : biais et étalonnage

Cette partie de la conférence portait sur l'hypothèse dite de la « représentation platonicienne » (Platonic Representation Hypothesis), proposée par Phillip Isola et ses collaborateurs en 2024, selon laquelle des réseaux de neurones entraînés avec des objectifs différents, sur des données et des modalités différentes, convergeraient vers une représentation statistique partagée de la réalité. Cette hypothèse s'appuie sur l'observation empirique que la similarité de représentation entre modèles de vision et modèles de langage tend à augmenter avec la taille des modèles, mesurée à l'aide de métriques telles que l'alignement de noyau centré (CKA) ou l'analyse de corrélation canonique (CCA).

L'équipe de Maria Brbić montre cependant que ces métriques de similarité globale sont affectées par deux biais systématiques liés à l'architecture des réseaux plutôt qu'à leur contenu représentationnel : un « effet de largeur », par lequel des réseaux plus larges présentent une similarité apparente plus élevée du seul fait de la dimension supérieure de leur espace de représentation, et un « effet de profondeur », lié au nombre de comparaisons effectuées entre couches, qui accroît statistiquement la probabilité d'observer une similarité élevée par pur hasard. Ces deux effets ont été démontrés y compris entre vecteurs indépendants, ce qui en confirme le caractère artefactuel.

Pour corriger ce biais, l'équipe propose une méthode d'étalonnage fondée sur la construction d'une distribution nulle empirique — obtenue en brisant volontairement la correspondance entre paires vision-langage — permettant de replacer chaque score de similarité observé dans son contexte statistique. Cette méthode, indépendante de la métrique utilisée, a été appliquée à l'hypothèse de la représentation platonicienne : après étalonnage, la tendance de convergence globale observée à l'échelle du modèle disparaît, tandis qu'une convergence locale, mesurée par la similarité des plus proches voisins, demeure. Ce résultat conduit l'intervenante à proposer une reformulation plus restreinte, qualifiée d'hypothèse de représentation « aristotélicienne », selon laquelle seules les relations de voisinage local entre points de données convergeraient de façon robuste entre modèles, et non la géométrie globale de leurs représentations.

Ce travail se prolonge par une méthode de diagnostic permettant d'estimer, avant tout entraînement d'alignement coûteux, la compatibilité probable de deux modèles à l'aide de scores calculés à partir des plus proches voisins mutuels dans leurs espaces pré-entraînés respectifs.

Aligner des modèles pré-entraînés avec peu de données appariées

La dernière partie de la conférence portait sur l'alignement de modèles unimodaux pré-entraînés lorsque les données multimodales appariées sont rares — une situation fréquente en biomédecine, où les grands ensembles de données appariées de plusieurs centaines de millions d'exemples, courants en vision-langage, n'existent généralement pas. L'approche proposée introduit un terme de régularisation qui vise à préserver, dans l'espace d'alignement appris, la structure de voisinage déjà présente dans les espaces pré-entraînés de chaque modalité, en minimisant la divergence de Jensen-Shannon entre les distributions de similarité avant et après alignement.

Cette régularisation, présentée comme simple à intégrer à n'importe quelle fonction d'alignement existante (contrastive, linéaire ou non linéaire), permet une amélioration moyenne de l'ordre de 68 % sur des tâches de classification et de recherche en régime de faible disponibilité de données appariées (de l'ordre de 80 000 échantillons, soit moins de 1 % des volumes habituellement utilisés dans le domaine).

Discussion et perspectives

Les échanges qui ont suivi la présentation ont notamment porté sur la place des a priori de symétrie dans les modèles biologiques, sur la difficulté de mesurer la similarité de représentations humaines (par exemple entre diagnostics médicaux), et sur les axes de recherche jugés encore peu explorés : l'étude conjointe des données protéomiques et transcriptomiques, ainsi que l'articulation entre données dynamiques (imagerie de cellules vivantes) et données statiques mais destructives (séquençage unicellulaire), en vue de mieux caractériser la dynamique spatio-temporelle des systèmes biologiques.

Présentation partenaire — Les agents d'automatisation informatique

Intervenant : Radu Erdustanciu, ingénieur en science appliquée chez UiPath.

Cette présentation, proposée par le sponsor industriel de l'école d'été, portait sur l'évolution des technologies d'automatisation des tâches informatiques répétitives, illustrée par l'agent « Otto » développé par UiPath. L'intervenant a retracé trois générations successives de cette automatisation : les robots RPA (Robotic Process Automation) classiques, fondés sur des règles rigides et des sélecteurs d'interface prédéfinis, fragiles au moindre changement d'interface ; puis l'introduction de la vision par ordinateur, qui permet à l'agent de percevoir l'écran mais sans en comprendre la tâche sous-jacente ; enfin, les agents actuels, capables de raisonner sur une tâche et d'émettre des actions de manière autonome, en observant l'écran par captures successives et en exécutant leurs actions via un pilote logiciel proche du système d'exploitation.

La performance de ces agents est évaluée à l'aide de plusieurs référentiels standards : OSWorld (une évaluation de bout en bout de l'usage informatique), ainsi que OSWorld-G et ScreenSpot-Pro, qui évaluent plus spécifiquement la capacité de l'agent à situer correctement l'action à réaliser sur l'écran (par exemple prédire l'endroit où cliquer).

L'intervenant a également abordé les contraintes pratiques de déploiement de ces systèmes : la nécessité d'un compromis entre la taille du modèle utilisé, son coût d'inférence et la latence perçue par l'utilisateur ; la taille de la fenêtre de contexte, réduite (de l'ordre de 30 000 à 60 000 jetons) pour les modèles d'exécution afin de limiter le coût, mais nettement plus importante pour les modèles de planification ; ainsi que les enjeux de confidentialité liés au traitement de données d'entreprise par des fournisseurs de modèles tiers, gérés contractuellement par des clauses de non-conservation des données.

Conférence — L'apprentissage automatique au service des mathématiques

Intervenant : Matia Tapušković, chargé de développement de carrière en mathématiques, Corpus Christi College, Université d'Oxford.

Mathématicien de formation, spécialisé en théorie des nombres, en géométrie et en physique mathématique, l'intervenant a proposé une lecture en trois temps de la relation entre apprentissage automatique et recherche mathématique, en comparant cette relation naissante à celle qui a historiquement uni les mathématiques et la physique.

Apprendre à partir d'exemples

Le premier exemple présenté concerne les polynômes de Kazhdan-Lusztig, des objets combinatoires associés aux intervalles du graphe de permutations et centraux en théorie des représentations. Une équipe de chercheurs (dont les travaux ont été publiés dans Nature en 2021) a entraîné un réseau de neurones sur

graphes (GNN) à prédire les coefficients de ces polynômes à partir des graphes d'intervalles non étiquetés, avec une précision élevée. L'analyse des gradients du modèle — une technique usuelle d'attribution en apprentissage automatique — a permis d'identifier les arêtes du graphe les plus déterminantes pour la prédiction, révélant une décomposition du graphe en deux sous-structures plus simples jusqu'alors non identifiée par les mathématiciens, en raison de la croissance combinatoire très rapide de ces objets. Cette observation a directement contribué, dans les mois qui ont suivi, à une preuve partielle de la conjecture d'invariance combinatoire de Lusztig et Dyer, restée ouverte pendant plusieurs décennies.

Le second exemple porte sur le rang des courbes elliptiques, une quantité arithmétique parmi les plus difficiles à calculer en théorie des nombres. En 2022, une équipe a appliqué une simple régression logistique à des vecteurs de 500 coefficients (les nombres a_p, associés au nombre de solutions de l'équation modulo différents nombres premiers) afin de prédire si le rang d'une courbe était nul ou égal à un, obtenant une précision de 90 à 97 %. Cherchant à comprendre l'origine de ce signal, un étudiant de premier cycle a moyenné ces coefficients sur des intervalles de courbes classées par un indicateur de complexité arithmétique (le conducteur), et a mis en évidence un motif oscillant inattendu, baptisé depuis « murmuration », qui n'avait jamais été repéré visuellement malgré des décennies d'étude de ces objets par des spécialistes du domaine. Ce phénomène a depuis été démontré rigoureusement pour certaines classes de formes modulaires et observé dans d'autres familles de fonctions spéciales.

Les grands modèles de langage face aux problèmes mathématiques

Le deuxième axe de la conférence portait sur l'usage direct de grands modèles de langage pour aborder des problèmes mathématiques ouverts, notamment via des systèmes de recherche évolutionnaire tels qu'AlphaEvolve, qui a par exemple permis de réfuter une variante de la conjecture des distances d'Erdős en établissant un lien avec un domaine mathématique a priori distinct. L'intervenant a insisté sur le rôle déterminant, dans ces succès, de la qualité de l'évaluateur utilisé pour juger les propositions générées — un évaluateur peu coûteux, fiable et difficile à « tromper » étant présenté comme la condition la plus importante du succès, davantage que la recherche elle-même.

La formalisation des preuves mathématiques

Le troisième axe portait sur la formalisation des démonstrations à l'aide d'assistants de preuve, en particulier le langage Lean. Un assistant de preuve permet d'exprimer définitions et énoncés sous forme de programmes, dont un noyau vérifie mécaniquement la correction logique — une vérification de forme, non de vérité empirique. La bibliothèque communautaire Mathlib, qui rassemble l'essentiel des mathématiques de premier cycle formalisées ainsi qu'une partie significative de mathématiques de recherche, représente environ 2,3 millions de lignes de code accumulées en neuf ans.

Plusieurs jalons récents illustrent l'accélération de ce domaine : lors des Olympiades internationales de mathématiques 2024, les systèmes AlphaProof et AlphaGeometry de DeepMind ont atteint le niveau médaille d'argent en s'appuyant sur le noyau de vérification de Lean comme évaluateur d'apprentissage par renforcement ; en 2025, certains systèmes ont obtenu le niveau médaille d'or en raisonnant uniquement en langage naturel, sans recours à une vérification formelle, un résultat obtenu en quelques heures mais nécessitant une validation humaine a posteriori. Plus récemment, un système a permis de résoudre en Lean, en une vingtaine d'heures, un problème connu sous le nom de « cap set problem », tandis que la formalisation complète du théorème d'empilement de sphères en dimension 8 (théorème de Viazovska) a été réalisée par un moteur de formalisation en quelques jours, contre plusieurs années de travail humain

pour construire une bibliothèque de référence comparable. Un résultat intermédiaire du théorème de modularité, sur lequel repose la démonstration du grand théorème de Fermat, a par ailleurs été formalisé en environ 250 000 lignes de code en deux semaines, sous la supervision d'un unique doctorant.

L'intervenant a souligné que si la vérification formelle des démonstrations bénéficie clairement de l'apport de l'IA, la formulation même des définitions et des énoncés — c'est-à-dire s'assurer qu'un énoncé formel capture fidèlement ce que les mathématiciens entendent par une conjecture — demeure la difficulté la plus importante, qualifiée de problème de la signification (« meaning problem »), commun à de nombreuses applications de l'IA.

Discussion : quel rôle pour les LLM dans la recherche mathématique ?

Les échanges avec le public ont porté sur plusieurs questions ouvertes : l'importance relative de la formulation de conjectures par rapport à leur démonstration — l'intervenant estimant que les deux activités sont indissociables, une conjecture nouvelle émergeant le plus souvent d'une reformulation issue de tentatives de démonstration antérieures ; la capacité des modèles de langage à développer une intuition nouvelle par la lecture d'un large corpus de littérature, plutôt qu'à réellement innover ; et l'absence, à ce jour, d'exemple documenté de construction d'une théorie mathématique entièrement nouvelle par un système d'IA, la contribution de ces outils restant pour l'instant concentrée sur l'exploration de pistes déjà balisées et sur la vérification formelle.

Notions fondamentales — L'apprentissage par renforcement

Synthèse personnelle établie à partir du cours consacré à l'apprentissage par renforcement (RL) et à son application à l'alignement des grands modèles de langage.

Le processus de décision markovien (MDP)

Un problème d'apprentissage par renforcement est formalisé comme un processus de décision markovien, défini par un ensemble d'états, un ensemble d'actions, une fonction de transition, une fonction de récompense et un facteur d'actualisation γ (gamma). L'objectif de l'agent est de maximiser l'espérance du retour cumulé J(θ) = E[R]. Le facteur γ détermine l'importance accordée aux récompenses futures : une valeur proche de 0 privilégie la récompense immédiate, tandis qu'une valeur proche de 1 accorde un poids important aux récompenses à long terme.

Bandits manchots et dilemme exploration-exploitation

Le problème des bandits manchots constitue une version simplifiée du RL, dans laquelle l'agent choisit à chaque étape un « bras » et observe la récompense associée, sans notion d'état. Il illustre le dilemme fondamental entre exploration (tester de nouvelles actions pour mieux les évaluer) et exploitation (répéter l'action jugée la meilleure jusqu'ici). Une méthode classique pour arbitrer ce compromis est la stratégie ε-greedy : avec une probabilité ε, l'agent choisit une action aléatoire ; sinon, il choisit la meilleure action connue.

Gradient de politique et l'algorithme REINFORCE

Plutôt que d'apprendre des valeurs, l'approche par gradient de politique apprend directement une politique π_θ(a|s), c'est-à-dire une distribution de probabilité sur les actions, et ajuste ses paramètres θ par montée de gradient afin de maximiser le retour attendu. L'algorithme REINFORCE met à jour la politique en multipliant le gradient du logarithme de la politique par le retour total obtenu. Sa limite principale est un problème d'attribution du crédit (« credit assignment ») : toutes les actions d'un épisode reçoivent le même

signal, y compris celles qui n'ont pas contribué à un résultat favorable, dès lors que l'épisode se termine bien.

Fonctions de valeur et programmation dynamique

Pour résoudre ce problème d'attribution, on introduit deux fonctions de valeur : la valeur d'un état V(s) et la valeur d'un couple état-action Q(s,a), qui permettent d'identifier plus précisément quelle action est réellement responsable d'une récompense. Lorsque le modèle de l'environnement (transitions et probabilités) est entièrement connu, la programmation dynamique permet de calculer exactement V(s) ; cette approche, bien qu'efficace, reste peu réaliste pour des problèmes de grande taille.

Monte Carlo et différences temporelles

Lorsque le modèle de l'environnement est inconnu, deux familles de méthodes permettent d'estimer les valeurs à partir de l'expérience. Les méthodes de Monte Carlo attendent la fin de l'épisode pour calculer le retour réellement observé : elles produisent des estimations non biaisées, mais à forte variance. Les méthodes de différence temporelle (TD) mettent à jour l'estimation après chaque pas, à partir de la quantité $R + \gamma V(s')$, sans attendre la fin de l'épisode : elles présentent une variance plus faible, au prix d'un biais plus important. La programmation dynamique, Monte Carlo et TD se distinguent ainsi par l'horizon sur lequel elles s'appuient : le modèle complet pour la première, l'épisode entier pour la deuxième, un seul pas pour la troisième.

Apprentissage par renforcement basé sur un modèle

Une autre famille d'approches consiste à apprendre explicitement un modèle de l'environnement — une fonction de transition $P(s'|s,a)$ et une fonction de récompense $R(s,a)$ — puis à planifier les actions à partir de ce modèle appris, comme le font les algorithmes Dreamer ou MuZero. Cette approche permet de réduire fortement la quantité de données nécessaires et de raisonner sur la sécurité des actions envisagées, mais elle est sensible à l'exactitude du modèle appris : un modèle erroné conduit à une planification de mauvaise qualité.

Q-learning, rejeu d'expérience et réseau cible

Le Q-learning apprend directement la fonction Q(s,a) plutôt que V(s), la politique optimale étant alors obtenue en choisissant l'action qui maximise Q pour un état donné ; il s'agit d'un algorithme hors politique (« off-policy »). Deux techniques ont permis de stabiliser son entraînement dans le cadre du Deep Q-Network (DQN) : le rejeu d'expérience (« experience replay »), qui consiste à stocker les transitions observées et à les rejouer plusieurs fois afin de briser la corrélation temporelle des données d'entraînement, et le réseau cible (« target network »), une copie du réseau gelée puis mise à jour seulement toutes les N itérations, qui limite les oscillations de l'apprentissage.

Fonction d'avantage et architecture Actor-Critic

La fonction d'avantage $A(s,a) = Q(s,a) - V(s)$ répond à la question de savoir si une action donnée s'est révélée meilleure ou moins bonne que ce qui était attendu dans cet état ; son usage constitue une amélioration importante par rapport à REINFORCE. L'architecture Actor-Critic s'appuie sur deux réseaux : l'acteur, qui choisit les actions, et le critique, qui estime les valeurs et sert exclusivement à guider l'apprentissage de l'acteur.

Exploration par entropie

Lorsqu'une politique devient trop déterministe, elle cesse d'explorer de nouvelles actions. Pour l'éviter, un terme d'entropie $+\beta H(\pi)$ est ajouté à la fonction objectif, encourageant une politique plus diversifiée. Le coefficient β est généralement élevé en début d'entraînement, pour favoriser l'exploration, puis diminué progressivement à mesure que l'apprentissage progresse.

Proximal Policy Optimization (PPO)

L'algorithme TRPO, prédécesseur de PPO, impose une contrainte de divergence de Kullback-Leibler coûteuse à calculer. PPO remplace cette contrainte par un mécanisme d'écrêtage (« clipping ») du ratio entre la nouvelle et l'ancienne politique, borné dans l'intervalle $[1-\varepsilon, 1+\varepsilon]$. Cette simplification rend l'entraînement nettement plus stable, ce qui explique l'adoption très large de PPO comme algorithme de référence pour l'alignement des grands modèles de langage.

RLHF : l'apprentissage par renforcement à partir du retour humain

L'entraînement d'un grand modèle de langage par retour humain (RLHF) suit typiquement une séquence en quatre étapes : le pré-entraînement, le réglage fin supervisé (SFT), l'entraînement d'un modèle de récompense représentant les préférences humaines, puis l'optimisation de la politique du modèle par PPO à l'aide de ce modèle de récompense.

DeepSeek-R1 et les récompenses vérifiables

Le modèle DeepSeek-R1 introduit une alternative à cette chaîne, en se passant entièrement de modèle de récompense appris à partir de préférences humaines. Il s'appuie à la place sur des récompenses vérifiables automatiquement — par exemple la réussite de tests unitaires en programmation ou l'exactitude d'un résultat en mathématiques — ce qui permet au modèle d'apprendre directement par renforcement, sans étape intermédiaire de modélisation des préférences humaines.

GRPO

DeepSeek remplace également PPO par l'algorithme GRPO (Group Relative Policy Optimization), qui se passe du réseau critique : plusieurs réponses sont générées pour un même prompt, puis comparées entre elles ; leur récompense est normalisée (moyenne et variance au sein du groupe), avant de mettre à jour directement la politique. Cette approche réduit sensiblement le coût de calcul de l'entraînement.

Tutoriel pratique

Un tutoriel pratique a permis d'illustrer, par une implémentation progressive, la traduction concrète des notions théoriques précédentes en code : mise en place d'environnements simples (Grid World, Cliff Walking), implémentation d'un algorithme de gradient de politique puis de REINFORCE, implémentation de PPO, et enfin réglage fin d'un petit modèle de langage (Qwen, environ 500 millions de paramètres) à l'aide de ces méthodes.

Conférence — « Statistics Upside Down »

Intervenant : Kyunghyun Cho, New York University (NYU).

Cette conférence défendait une idée centrale : plutôt que de concevoir manuellement des estimateurs statistiques à partir de considérations théoriques, il est possible d'entraîner un réseau de neurones à apprendre directement un estimateur à partir de données synthétiques, en optimisant une fonction de perte adaptée à la quantité à estimer.

Exemple 1 — Apprendre à estimer l'écart-type

L'estimateur usuel de l'écart-type est biaisé, notamment en raison de la non-linéarité introduite par la racine carrée. L'approche proposée consiste à générer un grand nombre d'échantillons synthétiques, à en calculer l'écart-type exact, puis à entraîner un réseau — un ensemble reçu en entrée, l'écart-type attendu en sortie, avec une perte de type erreur quadratique moyenne — à produire un meilleur estimateur que les formules classiques. L'architecture retenue est un Set Transformer, choisie car elle est invariante à l'ordre des échantillons présentés, une propriété essentielle puisque l'ordre des observations d'un échantillon n'a pas de sens statistique.

Exemple 2 — Estimer l'information mutuelle

Le même principe est appliqué à l'estimation de l'information mutuelle, à travers une méthode nommée MIST (Mutual Information by Supervised Training) : générer des problèmes synthétiques puis apprendre directement un estimateur. Les résultats présentés indiquent que MIST surpasse plusieurs estimateurs classiques (CCA, KSG, InfoNCE, InfoNet), avec un biais et une variance plus faibles ainsi qu'une meilleure généralisation selon les dimensions testées.

Régression quantile et estimation d'incertitude

Enfin, la régression quantile a été présentée comme une alternative permettant au réseau d'apprendre directement les quantiles d'une distribution plutôt qu'une simple moyenne. Cette approche fournit naturellement une estimation de l'incertitude associée à une prédiction, avec une calibration présentée comme nettement meilleure que celle obtenue par des méthodes de rééchantillonnage telles que le bootstrap.

Synthèse générale de la journée

- Le réseau européen EuroCC / EuroHPC met à disposition des chercheurs et des entreprises des ressources de calcul haute performance, avec un accès conditionné par un usage non commercial pour l'industrie.
- En biomédecine, les progrès conjoints de l'IA et des technologies de mesure à l'échelle de la cellule unique ouvrent la voie à des modèles multimodaux capables de relier expression génique, morphologie et organisation spatiale des cellules, mais la fiabilité des métriques d'évaluation employées mérite une attention particulière.
- Les agents d'automatisation informatique évoluent de règles rigides vers des systèmes capables de percevoir et raisonner sur une interface, sous contrainte d'un compromis entre taille du modèle, coût d'inférence et latence.
- En mathématiques, l'apprentissage automatique contribue déjà à des découvertes concrètes (invariance combinatoire, murmurations des courbes elliptiques) et la formalisation des preuves progresse rapidement, sans qu'un exemple documenté de construction autonome d'une théorie mathématique nouvelle par un système d'IA n'ait encore été observé.
- L'apprentissage par renforcement, du cadre du processus de décision markovien jusqu'à PPO et GRPO, constitue le socle méthodologique de l'alignement des grands modèles de langage, avec une évolution notable vers des récompenses vérifiables automatiquement plutôt que des modèles de préférences humaines.
- Les réseaux de neurones peuvent être entraînés à apprendre directement des estimateurs statistiques — écart-type, information mutuelle, quantiles — parfois plus performants que les formules analytiques conçues manuellement, avec un bénéfice notable en matière de calibration de l'incertitude.