# JOUR 5

*Engagement communautaire, IA pour la médecine, recherches régionales et apprentissage efficace en calcul*

31 juillet 2026

**Intervenants et thèmes principaux :**

Suad Glass — Association ANT et bénévolat

Elma Dervishi — IA pour la médecine

Recherches régionales : anomalies, graphes, jumeaux numériques

Dan Alistarh (IST Austria) — Compression de modèles

## Avant-propos

Ce document restitue, dans un format pédagogique et objectif, la cinquième journée de l'Eastern European Machine Learning Summer School (EEML) 2026, suivie à distance. Comme pour les journées précédentes, il ne s'agit pas d'une transcription du direct, mais d'une réorganisation thématique du contenu, reformulée en français dans un registre académique neutre — la transcription source étant, cette fois, disponible directement en anglais plutôt qu'auto-traduite.

La journée s'est ouverte sur une intervention de Suad Glass, représentant de l'association bosnienne ANT (Association for Advancement of Science, Technology and Innovation), qui a présenté une « démonstration mathématique » de l'intérêt du bénévolat avant de détailler les projets de son organisation. Elma Dervishi (chercheuse à l'université de Vienne) a ensuite présenté ses travaux sur l'usage de l'IA en médecine, à partir de données de santé autrichiennes. La matinée s'est poursuivie avec trois présentations courtes de recherches menées localement dans la région (Monténégro et Albanie) : détection d'anomalies, analyse spectrale de graphes, et jumeaux numériques portuaires. L'après-midi a été consacrée à un exposé de Dan Alistarh (IST Austria, chercheur ayant également travaillé chez Anthropic) sur l'apprentissage informatiquement efficace, centré sur la compression de modèles (élagage et quantification).

Comme pour les documents précédents, le corps du texte présente une synthèse concise de chaque chapitre, tandis que les développements plus techniques — en particulier les dérivations mathématiques de la deuxième moitié de la journée — sont regroupés en annexe, avec renvoi explicite depuis chaque chapitre.

## Partie I — Engagement communautaire et présentation de l'association ANT

Cette intervention a été assurée par Suad Glass, représentant de l'association ANT (Association for Advancement of Science, Technology and Innovation), organisation bosnienne partenaire de l'école d'été, qui avait notamment coorganisé l'édition EEML de l'année précédente en Bosnie-Herzégovine.

### Chapitre 1. Une « démonstration mathématique » de l'intérêt du bénévolat

Sur un ton volontairement humoristique, l'intervenant construit une analogie entre trois notions d'apprentissage automatique et d'optimisation — la descente de gradient, l'équilibre de Nash et une fonction de coût personnelle — pour argumenter que l'engagement bénévole constitue un optimum global que l'individu ne peut atteindre en optimisant seul, égoïstement, son propre confort.

#### Les trois étapes de l'analogie

- La descente de gradient est présentée comme un algorithme « glouton » (greedy) : à chaque étape, elle choisit la direction localement la meilleure, ce qui peut la piéger dans un minimum local sans qu'elle ait conscience qu'une solution globalement meilleure existe ailleurs — une première intuition selon laquelle une stratégie purement individuelle et locale ne mène pas nécessairement au meilleur résultat possible.
- L'équilibre de Nash est ensuite introduit à l'aide d'un exemple de vie courante (deux colocataires devant faire la vaisselle) : si chacun raisonne égoïstement selon sa seule fonction de coût, la stratégie individuellement rationnelle pour chacun consiste à ne jamais faire la vaisselle — ce qui conduit les deux colocataires vers l'équilibre le plus coûteux pour l'ensemble (aucune vaisselle faite), alors qu'une coopération aurait permis un résultat globalement meilleur pour les deux.

- Enfin, en s'appuyant sur la représentation populaire selon laquelle le confort personnel dépend du temps, de l'argent et de l'énergie disponibles à différents âges de la vie, l'intervenant propose d'ajouter une variable supplémentaire à cette fonction de confort individuel : la contribution de la communauté environnante, elle-même déterminée en partie par les actions d'autrui.

La conclusion proposée est que, de la même façon qu'il faut parfois s'écarter d'une trajectoire de descente de gradient purement locale pour atteindre un meilleur optimum, il est nécessaire de « sacrifier » une partie de son temps, de son argent et de son énergie personnels — par le bénévolat — afin d'accéder à un niveau de bien-être collectif et individuel plus élevé que celui atteignable par la seule optimisation égoïste.

## Chapitre 2. L'association ANT : projets et impact en Bosnie-Herzégovine

L'intervenant présente ensuite l'historique et les activités concrètes de son association, fondée en 2017 par un groupe de jeunes scientifiques bosniens dispersés à travers le monde, et comptant aujourd'hui environ 150 membres, dont plus de 40 titulaires d'un doctorat.

**Principaux projets présentés**

- Un programme destiné aux lycéens, réunissant de jeunes Bosniens autour de conférences données par des chercheurs bosniens ayant réussi à l'international, dans le but de les aider à découvrir des domaines d'études qui les intéressent réellement.
- Un programme de recherche de niveau licence/master, mettant en relation des étudiants avec des chercheurs membres de l'association autour de petits projets de recherche d'environ six mois — souvent la première expérience de recherche scientifique réelle pour ces étudiants, et parfois déterminante dans l'obtention ultérieure d'une place en master ou en doctorat à l'étranger.
- Une plateforme de recensement de la diaspora scientifique bosnienne (un pays dont environ la moitié de la population résiderait à l'étranger), construite par extraction de données plutôt que par inscription volontaire, ayant permis d'identifier plus de 3 400 chercheurs et plus de 45 000 publications associées.
- La rédaction de documents stratégiques nationaux, notamment sur la numérisation et l'intelligence artificielle en Bosnie-Herzégovine.
- La coorganisation, l'année précédente, de l'édition EEML tenue en Bosnie, avec plus de 300 participants et environ 900 candidatures.

L'intervenant conclut en insistant sur le fait que l'ampleur du temps et de l'effort nécessaires à l'organisation d'un tel événement n'est généralement pas perçue par les participants, et invite chacun à identifier, dans sa propre communauté, une cause à laquelle contribuer même modestement.

## Partie II — Intelligence artificielle pour la médecine

Cette intervention a été assurée par Elma Dervishi, chercheuse postdoctorale à l'université de Vienne (alumni de l'université du Monténégro), venue remplacer au pied levé un intervenant initialement prévu. Ses travaux, menés au Complexity Science Hub de Vienne, portent sur l'analyse de larges bases de données médicales autrichiennes à l'aide de réseaux (graphes).

### Chapitre 3. Réseaux de comorbidité et trajectoires de maladies

Le point de départ du projet est un constat démographique : l'allongement de l'espérance de vie ne se traduit pas par davantage d'années en bonne santé, mais par davantage d'années de dépendance et de comorbidités. L'intervenante a eu accès, via le ministère autrichien de la Santé, à une base de données couvrant 45 millions d'admissions hospitalières sur environ 9 millions d'individus, sur une période de 20 ans.

**Idées clés**

- Plutôt que d'étudier chaque maladie isolément, l'équipe construit des réseaux de comorbidité (comorbidity networks) : deux maladies sont reliées par un lien si elles apparaissent conjointement chez un même patient plus souvent que ne le voudrait le hasard. Ces liens n'encodent qu'une corrélation statistique, sans indication de causalité ni de direction.
- En répétant cette construction pour différentes tranches d'âge (enfants, adolescents, adultes, personnes âgées), on observe que la complexité de ces réseaux augmente fortement avec l'âge, révélant des maladies centrales caractéristiques de chaque étape de la vie (par exemple l'hypertension chez les femmes autour de la quarantaine).
- En exploitant la dimension temporelle des données (un même patient suivi sur 20 ans), il devient possible d'orienter certains liens et de parler, avec prudence, de trajectoires de maladies : par exemple, une cohorte de patients obèses dans la vingtaine présentant, dix ans plus tard, un risque plus élevé de dépression — sans qu'il soit établi de mécanisme causal direct.
- Un algorithme de détection de communautés non supervisé, tolérant le chevauchement entre communautés (une même maladie pouvant appartenir à plusieurs groupes, reflétant sa diversité clinique selon les patients), est utilisé pour identifier des centaines de groupes de maladies et des trajectoires plus ou moins sévères, mesurées notamment par la mortalité et la durée d'hospitalisation associées.

*Détails sur les biais des données médico-administratives et sur l'exemple des trajectoires divergentes liées aux troubles du sommeil : voir Annexe A.1.*

### Chapitre 4. Validation moléculaire et repositionnement de médicaments

Consciente que des données hospitalières autrichiennes présentent des biais propres (sous-diagnostic de certaines maladies, biais de remboursement, etc.), l'équipe a cherché à valider ses résultats à un niveau biologique indépendant, en les confrontant à des bases de données de profils moléculaires des maladies.

**Idées clés**

- Après un important travail d'harmonisation de plusieurs bases de données moléculaires hétérogènes (nomenclatures différentes pour une même maladie, couverture inégale selon les types de maladies), l'équipe a pu confirmer qu'une partie substantielle des associations statistiques observées dans les données hospitalières se retrouve également au niveau des profils moléculaires — un signal que ces

trajectoires reflètent, au moins en partie, une réalité biologique et non seulement un artefact des données.

- Un phénomène de biais de littérature est également mis en évidence : les maladies les plus étudiées dans la littérature scientifique (via PubMed) sont mécaniquement mieux représentées dans les bases de données moléculaires ; la combinaison de plusieurs bases de données permet cependant d'atténuer partiellement ce biais.
- En s'appuyant sur une base de données de médicaments approuvés (DrugBank) croisée avec les profils moléculaires des trajectoires de maladies, l'équipe identifie des candidats potentiels de repositionnement de médicaments (drug repurposing) — par exemple 55 candidats pour l'endométriose, contre 9 médicaments déjà approuvés pour cette seule maladie prise isolément.
- Une étape de validation complémentaire, utilisant un agent conversationnel spécialisé en biomédecine (TxAgent, fondé sur un modèle de langage open source), a permis d'écarter automatiquement des candidats non pertinents sur le plan clinique (l'exemple donné étant l'éthanol, statistiquement associé à la dépendance à l'alcool dans les données mais évidemment inadapté comme traitement) — tout en reconnaissant explicitement, en réponse à une question du public, les limites de fiabilité des modèles de langage pour ce type de validation.

*Détails sur l'usage de stades de sévérité et leur validation au niveau des réseaux d'interaction protéine-protéine (PPI) : voir Annexe A.2.*

## Partie III — Recherches régionales en vitrine

Cette partie de la matinée a réuni trois présentations courtes (20 minutes chacune, sans session de questions dédiée), mettant en avant des recherches entièrement conduites et développées dans la région.

### Chapitre 5. Détection d'anomalies : modération de commentaires et fibrillation auriculaire

Cette intervention a été assurée par Alexander Pllumaj, doctorant à l'université du Monténégro, sur ses travaux de thèse consacrés à la détection d'anomalies.

**Définitions et premier cas d'usage : modération de commentaires**

- Trois types d'anomalies sont distingués : ponctuelle (une valeur toujours anormale, quel que soit le contexte), contextuelle (une valeur normale dans un contexte mais anormale dans un autre, par exemple une température élevée selon la saison), et collective (un ensemble de points, individuellement normaux, qui forme une anomalie une fois considéré globalement).
- Le premier cas d'usage visait à modérer automatiquement les commentaires d'un portail d'actualités local en les traitant comme des anomalies (discours haineux) par rapport à des commentaires normaux. Cette approche s'est révélée inadaptée : sur plus de 4,5 millions de commentaires analysés, près de 40 % avaient été bannis par les modérateurs humains — un taux bien trop élevé pour que le discours haineux constitue une anomalie statistique au sens propre.
- L'analyse a également révélé un biais et des erreurs de modération humaine significatifs dans les données d'origine, ce qui a conduit l'équipe à faire annoter un sous-ensemble de 5 000 commentaires par une linguiste professionnelle afin de constituer une vérité de terrain fiable.
- Les détecteurs d'anomalies se sont révélés peu performants (proches d'un modèle aléatoire), notamment parce que les deux classes de commentaires occupent des régions largement superposées dans l'espace des représentations. Un modèle de classification supervisée classique (régression logistique sur des embeddings BERTić, un modèle BERT adapté aux langues slaves du Sud) a en revanche atteint un score satisfaisant d'environ 0,85, ce qui a conduit l'équipe à abandonner l'approche par détection d'anomalies au profit d'une classification directe.

**Second cas d'usage : détection de fibrillation auriculaire**

- Le second projet vise à détecter des anomalies cardiaques (en particulier la fibrillation auriculaire) à partir de signaux ECG à canal unique, enregistrés par un capteur portable grand public (Polar H10), nettement moins riches que les 12 dérivations d'un électrocardiogramme clinique.
- Sur un jeu de données de 1 520 enregistrements annotés par un médecin (dont 22 cas de fibrillation auriculaire), des modèles à une seule classe (Mahalanobis, Isolation Forest, One-Class SVM) obtiennent des scores autour de 0,88.
- Une caractéristique appelée « cohérence de l'onde P » (Pwave consistency) — complémentaire aux irrégularités d'intervalles RR habituellement utilisées par les dispositifs grand public — s'est révélée fortement corrélée à la fibrillation auriculaire sur ce dispositif, suggérant une piste d'amélioration pour la détection sur appareils portables, à valider sur un échantillon plus large.
- Face à la faible taille du jeu de données propre, l'équipe a exploré l'apprentissage par transfert à partir d'une base de données clinique ouverte bien plus large (PTB-XL, environ 22 000 enregistrements à 12 dérivations) : un réseau convolutif résiduel est pré-entraîné sur cette base, puis affiné en deux temps (couches convolutives gelées, puis dégelées) sur les données du capteur

portable, ce qui améliore sensiblement la reconnaissance de la fibrillation auriculaire malgré la faible quantité de données disponibles.

## Chapitre 6. Analyse spectrale des graphes orientés acycliques

Cette intervention a été assurée par Isidora Stanović, de la faculté de génie électrique de l'université du Monténégro, spécialiste du traitement du signal appliqué aux graphes.

**Idées clés**

- Les graphes orientés acycliques (DAG, Directed Acyclic Graphs) sont omniprésents en apprentissage automatique (graphes de calcul, réseaux bayésiens causaux, modèles autorégressifs). L'outil central pour en étudier le contenu fréquentiel est la transformée de Fourier sur graphe (Graph Fourier Transform, GFT), fondement des réseaux de neurones spectraux sur graphes.
- Le problème spécifique des DAG est que leur matrice d'adjacence, une fois les sommets triés topologiquement, devient strictement triangulaire supérieure — donc nilpotente, avec toutes ses valeurs propres égales à zéro. La transformée de Fourier sur graphe s'effondre alors : il devient impossible de distinguer les différentes fréquences (modes) du graphe, bien que la propagation de l'information dans le graphe reste, elle, parfaitement définie.
- Les approches existantes pour contourner ce problème (changement de base via un opérateur laplacien hermitien, ou ajout d'arêtes pour forcer la diagonalisabilité) modifient la dynamique ou la sortie du système étudié — ce que l'équipe cherche précisément à éviter.
- La solution proposée, appelée zero padding, s'inspire directement de la transformée de Fourier discrète classique : de même qu'on suppose un signal périodique et qu'on lui ajoute des zéros pour éviter le repliement spectral (aliasing), l'équipe ajoute une arête reliant le dernier au premier sommet du graphe (pour créer une périodicité), puis insère des sommets supplémentaires de valeur nulle (le nombre de sommets ajoutés dépendant de l'ordre du filtre de graphe utilisé).
- Pour un graphe en forme de chemin simple, cette méthode restaure des valeurs propres situées sur le cercle unité, permettant de retrouver une notion cohérente de fréquence (les rotations lentes correspondant aux basses fréquences, les rotations rapides aux hautes fréquences) — tout en garantissant mathématiquement que la sortie du système zero-paddé reste strictement identique à celle du DAG d'origine sur ses sommets originaux.
- Pour un DAG quelconque (non réductible à un simple chemin), une étape préalable de connexion par un chemin hamiltonien est nécessaire avant d'appliquer le zero padding ; sur des graphes-test de 7 et 8 sommets, cette approche complète permet de restaurer une matrice diagonalisable dans plus de 98 % des cas testés.

*Détails et exemple d'application au débruitage d'un signal porté par un graphe : voir Annexe B.1.*

## Chapitre 7. Jumeaux numériques pour la surveillance côtière portuaire

Cette intervention a été assurée par Manuela Zanelli, enseignante-assistante à l'université Alexandër Moisiu de Durrës (Albanie), sur ses travaux de recherche appliqués au port de Durrës, menés après plusieurs années d'expérience dans l'industrie portuaire.

**Idées clés**

- Un jumeau numérique (digital twin) est un modèle virtuel d'un actif physique, combinant capteurs, intégration de données (technologies cloud), modélisation 3D/hydrodynamique et algorithmes

d'apprentissage automatique (le LSTM étant cité comme particulièrement adapté aux données séquentielles typiques de ce domaine), dans une boucle de rétroaction.

- Les jumeaux numériques peuvent être passifs (simple visualisation des données captées, sans action en retour) ou actifs (boucle fermée, avec décisions prises à partir des données) ; leur maturité progresse typiquement du descriptif (état actuel) au diagnostique, puis au prédictif, et enfin à l'autonome.
- Le projet présenté applique cette approche à quatre scénarios côtiers du port de Durrës : tempêtes et submersions, érosion côtière, élévation du niveau de la mer, et surveillance fragmentée des différents systèmes existants ; à ce stade, le jumeau numérique développé reste passif, destiné à informer des opérateurs humains plutôt qu'à déclencher des actions automatiques.
- Les principaux défis identifiés pour la généralisation de cette approche sont la fiabilité des données, le manque d'expertise technique locale spécialisée en jumeaux numériques (particulièrement marqué en Albanie), la connectivité en temps réel, et les enjeux de cybersécurité et de gouvernance des données.

## Partie IV — Apprentissage informatiquement efficace

Cette intervention de l'après-midi a été assurée par Dan Alistarh, professeur à IST Austria, dont le parcours inclut un passage récent chez Anthropic, et dont les travaux portent sur la parcimonie (sparsity), la quantification et plus généralement l'optimisation des réseaux de neurones.

### Chapitre 8. La « bitter lesson » et l'explosion du besoin en calcul

L'intervenant introduit son propos par la « bitter lesson » (leçon amère) formulée par Richard Sutton (lauréat du prix Turing) : sur les 70 dernières années de recherche en IA, ce sont les méthodes générales tirant parti d'une grande quantité de calcul qui se sont avérées, de loin, les plus efficaces — bien davantage que les méthodes intégrant des connaissances spécifiques au domaine.

**Idées clés**

- Le calcul nécessaire pour entraîner un modèle de langage à l'état de l'art a été multiplié par environ 50 000 sur les cinq dernières années (doublant environ tous les 3 à 6 mois), et celui nécessaire à l'inférence par environ 300 sur la même période, alors que la puissance des GPU les plus avancés n'a progressé, sur cette période, que d'un facteur d'environ 20 — creusant un écart de plusieurs milliers entre besoin et capacité matérielle, comblé par la multiplication de centres de données massifs.
- Cette dynamique s'explique en grande partie par les lois d'échelle (scaling laws, dites « chinchilla »), des relations empiriques permettant de prédire la performance d'un grand modèle à partir d'expériences réalisées à petite échelle, et qui montrent une amélioration continue de la performance à mesure que le calcul augmente — ce qui a incité une grande partie de l'industrie à privilégier la croissance du calcul disponible comme stratégie principale.
- Cette course au calcul a un coût environnemental mesurable, mais dont l'ampleur reste, selon l'intervenant, difficile à évaluer précisément par manque d'études publiques détaillées ; une étude de Google portant sur une requête moyenne adressée à l'un de ses modèles rapporte des ordres de grandeur relativement faibles par requête individuelle (une fraction de watt-heure, quelques dizaines de milligrammes de $CO_2$, une fraction de millilitre d'eau), tout en soulignant que ces coûts, multipliés par des centaines de millions de requêtes quotidiennes, deviennent significatifs à l'échelle globale.
- Cette même étude de Google indique qu'une meilleure efficacité logicielle — en particulier la compression de modèles (quantification et décodage spéculatif) — a contribué de façon majeure (environ un facteur 10 sur un facteur global de réduction de coût de 32) à l'amélioration de l'efficacité de leurs infrastructures d'inférence sur la dernière année, ce qui motive directement le reste de l'exposé.

*Détails et repères chiffrés sur la taille des modèles récents et leur coût d'entraînement : voir Annexe C.1.*

### Chapitre 9. Fondements mathématiques de la compression de modèles

L'intervenant présente ensuite les bases mathématiques de la compression de modèles, en s'appuyant sur des travaux fondateurs des années 1990 (Optimal Brain Damage, Optimal Brain Surgeon), restés largement d'actualité malgré leur ancienneté.

**Idées clés**

- Le problème général consiste à trouver, à partir d'un réseau déjà entraîné (poids $W^*$), une version compressée dont la perte reste proche de celle du modèle original — que la compression prenne la forme d'un élagage (mise à zéro de certains poids) ou d'une quantification (réduction de la précision numérique des poids).

- En développant la fonction de perte du modèle compressé par une approximation de Taylor autour du point optimal W*, et en supposant le gradient du modèle original nul (puisqu'il a déjà convergé), l'impact de la compression sur la perte se réduit essentiellement à un terme quadratique impliquant la matrice hessienne de la perte — ce qui transforme le problème de compression en un problème d'optimisation quadratique sous contrainte.
- La résolution de ce problème par la méthode des multiplicateurs de Lagrange conduit, pour l'élagage, à retirer en priorité les poids dont l'impact sur la perte (mesuré par leur magnitude au carré, pondérée par l'inverse de la hessienne) est le plus faible — et, dans le cas simplifié où la hessienne est diagonale (poids non corrélés), cette solution se réduit exactement à la méthode heuristique consistant à élaguer les poids de plus faible magnitude.
- Le même raisonnement, appliqué à une contrainte de quantification plutôt que d'élagage, conduit à la méthode dite d'arrondi au plus proche (round-to-nearest) dans le cas simplifié de poids non corrélés — la version corrélée, prenant en compte la hessienne complète, permettant de compenser l'erreur introduite sur un poids en ajustant légèrement les autres poids restants.

*Détails, formalisation complète de la dérivation et illustration géométrique de la correction inter-poids : voir Annexe C.2.*

## Chapitre 10. Le mur du passage à l'échelle et la solution GPTQ

Ce cadre mathématique, bien que satisfaisant sur le plan théorique, devient totalement impraticable dès lors que l'on considère des modèles comportant plusieurs milliards de paramètres : le calcul, le stockage et l'inversion de la matrice hessienne complète deviennent physiquement impossibles (l'intervenant cite l'exemple de ResNet-50, dont la hessienne occuperait à elle seule 25 pétaoctets de stockage).

### La solution GPTQ

- Face à l'impossibilité de traiter le réseau dans son ensemble, la méthode GPTQ (développée par l'équipe de l'intervenant) adopte une stratégie de type « diviser pour régner » : le réseau est découpé couche par couche, et pour chaque couche, le problème est reformulé comme une régression visant à trouver des poids compressés qui reproduisent, sur un ensemble de données de calibration, la même sortie que les poids originaux.
- L'observation clé qui rend cette approche praticable est que, pour ce problème de régression couche par couche, la hessienne ne dépend que des activations d'entrée de la couche (et non des poids) : elle est donc constante et peut être précalculée une seule fois lors d'une simple passe avant sur les données de calibration.
- L'algorithme traite ensuite la matrice de poids d'une couche colonne par colonne : chaque colonne est quantifiée, l'erreur introduite est mesurée, puis toutes les colonnes restantes sont ajustées pour compenser cette erreur en s'appuyant sur les corrélations encodées dans la hessienne précalculée — un procédé réalisable en une seule passe (« one-shot »), sans nécessiter de réentraînement complet ni de rétropropagation sur l'ensemble du modèle.

*Détails et exemple géométrique du calcul colonne par colonne : voir Annexe C.3.*

## Chapitre 11. Résultats, impact pratique et limites théoriques de la quantification

### Résultats empiriques et impact pratique

- Appliquée à des modèles de la famille OPT (jusqu'à 175 milliards de paramètres), la méthode GPTQ en quantification 4 bits maintient une perplexité quasiment inchangée par rapport au modèle original sur

les grands modèles, là où l'arrondi naïf au plus proche dégrade fortement et de façon imprévisible la performance de certains modèles.

- Sur le plan pratique, la compression à 3 bits par poids d'un modèle comme OPT-175B (initialement réparti sur huit GPU) permet de le faire tenir sur un seul GPU, avec un gain de vitesse d'environ 3,5 fois pour la génération de texte — la génération étant, en pratique, limitée par le temps de transfert des poids depuis la mémoire plutôt que par le temps de calcul proprement dit.
- Une étude plus récente et à plus grande échelle (menée avec Red Hat, portant sur plus d'un million d'évaluations) confirme qu'une quantification à 8 bits est aujourd'hui quasiment sans perte de performance, tandis qu'une quantification à 4 bits entraîne une dégradation généralement limitée à environ 1 % sur des tâches simples, mais plus marquée sur des tâches de raisonnement complexe.

**Limites théoriques et perspectives**

- Des travaux théoriques plus récents (« théorème de linéarité ») montrent que, sous certaines hypothèses, l'augmentation de la perplexité causée par la quantification est approximativement une fonction linéaire de l'erreur relative introduite couche par couche — ce qui permet de prédire assez fidèlement l'impact d'une quantification avant même de l'appliquer, tant que l'erreur reste modérée (typiquement au-dessus d'environ trois bits par paramètre) ; au-delà de ce seuil, les prédictions deviennent trop optimistes par rapport à la dégradation réellement observée.
- Un phénomène récemment documenté concerne les modèles de raisonnement quantifiés : ceux-ci ont tendance à générer davantage de jetons de raisonnement avant de produire une réponse (« inflation de jetons »), ce qui peut masquer une dégradation de la qualité intrinsèque du modèle et, dans certains cas, annuler une partie du gain de rapidité obtenu par la quantification.
- L'intervenant conclut en identifiant comme axe de recherche ouvert la possibilité d'entraîner directement des modèles en précision réduite (plutôt que de quantifier un modèle déjà entraîné), ce qui nécessiterait de repenser certains aspects fondamentaux de l'optimisation (rétropropagation sur des valeurs discrètes, conception du matériel et des optimiseurs associés).

## Conclusion générale

Cette cinquième journée, plus hétérogène que les précédentes dans ses sujets, relie néanmoins des échelles très différentes d'un même souci : celui de l'usage réfléchi de ressources limitées, qu'il s'agisse du temps individuel consacré à une communauté, des données de santé disponibles pour la recherche médicale, ou du calcul nécessaire à l'entraînement et au déploiement des modèles d'intelligence artificielle.

**Fils conducteurs de la journée**

- L'intervention d'ouverture, bien que non technique dans son objectif, réutilise des concepts d'optimisation (minima locaux, équilibres non coopératifs) pour illustrer une idée plus large : une stratégie individuellement rationnelle n'est pas toujours globalement optimale — un thème qui resurgit, sous une forme très différente, dans la seconde moitié de la journée à propos de la compression de modèles.
- Les travaux présentés en IA médicale illustrent comment une lecture en réseau de grandes bases de données administratives, combinée à une validation biologique indépendante, permet d'extraire une information exploitable malgré des données bruitées, biaisées et jamais causales par nature.
- Les trois présentations régionales montrent, chacune dans son domaine (modération de contenu, traitement du signal sur graphes, jumeaux numériques portuaires), qu'une recherche de qualité internationale peut être conduite localement, souvent en confrontant une méthode standard à ses limites concrètes (détection d'anomalies inadaptée à un problème trop fréquent, effondrement spectral propre aux graphes acycliques, manque d'expertise technique locale) avant d'y apporter une solution adaptée.
- L'exposé de clôture relie directement la théorie de l'optimisation présentée en tout début de journée (via l'analogie de la descente de gradient) à un problème très concret et actuel : comment continuer à bénéficier des gains de performance liés à l'augmentation du calcul sans que son coût matériel, énergétique et économique ne devienne insoutenable.

Ce document restitue les notions abordées dans un cadre pédagogique et objectif ; certains échanges informels avec le public, ainsi que la teneur exacte de quelques questions difficilement audibles dans la transcription, n'ont pu être que partiellement restitués.

## Annexe — Approfondissements par chapitre

Cette annexe reprend, chapitre par chapitre, les développements techniques qui étayent les synthèses présentées dans le corps du document.

### A.1 — Biais des données médico-administratives (complément du chapitre 3)

L'intervenante souligne que les données de réclamations hospitalières (medical claims data) sont collectées à des fins de remboursement d'assurance et non de recherche, ce qui introduit des biais spécifiques : une maladie non remboursée directement (comme certaines formes d'obésité, diagnostiquée seulement dans les cas les plus sévères en Autriche) sera mécaniquement sous-représentée dans les données, indépendamment de sa prévalence réelle dans la population.

L'exemple des trajectoires divergentes illustre l'intérêt de l'approche par trajectoires plutôt que par simple corrélation statistique : deux patients aux profils très similaires dans la vingtaine et la trentaine peuvent ensuite diverger fortement, l'un évoluant vers un groupe de maladies sévères, l'autre restant sur une trajectoire plus bénigne. Un exemple mis en avant par les médecins collaborateurs du projet concerne les troubles du sommeil chez les hommes dans la vingtaine et la trentaine, identifiés comme un possible événement critique précédant des trajectoires plus sévères — ce qui suggérerait des pistes de prévention proactive si ce signal se confirme à plus large échelle.

### A.2 — Stades de sévérité et validation moléculaire (complément du chapitre 4)

Pour quantifier la sévérité d'une trajectoire, l'équipe introduit la notion de stade : chaque nouvelle maladie acquise par un patient au cours du temps fait progresser son stade, un stade plus élevé correspondant à une trajectoire plus sévère. Cette notion, construite uniquement à partir des données hospitalières, se retrouve également au niveau moléculaire : les maladies associées aux stades les plus avancés occupent, dans les réseaux d'interaction protéine-protéine (PPI), des positions plus centrales (davantage de connexions), ce qui corrobore, à un niveau biologique indépendant, la progression de sévérité observée dans les données cliniques.

### B.1 — Zero padding et débruitage sur graphe (complément du chapitre 6)

L'analogie avec le traitement du signal classique est explicite : de même qu'en traitement du signal discret on suppose la périodicité d'un signal fini pour en calculer la transformée de Fourier, et qu'on y ajoute des zéros pour éviter que les premiers et derniers échantillons ne s'entremêlent artificiellement (repliement spectral), l'équipe transforme le DAG en graphe cyclique en ajoutant une arête du dernier sommet vers le premier, puis insère un nombre de sommets fictifs de valeur nulle égal à l'ordre du filtre de graphe utilisé, ce qui retarde suffisamment la boucle de rétroaction pour éviter toute contamination artificielle du signal.

Le DAG original reste, dans cette construction, un sous-graphe inchangé du graphe augmenté : ses sommets, ses arêtes et sa dynamique de propagation restent identiques, seule l'analyse spectrale se fait sur le graphe élargi. Les valeurs propres du graphe zero-paddé se répartissent alors sur le cercle unité, avec un angle de phase directement interprétable comme une fréquence (rotation lente pour les basses fréquences, rapide pour les hautes fréquences), permettant de retrouver un ordre de fréquence cohérent et exploitable pour, par exemple, filtrer ou débruiter un signal porté par les sommets du graphe — une expérience illustrative montre une amélioration du rapport signal sur bruit d'environ 13 décibels (de −6,99 dB à 6,21 dB) sur un exemple de filtrage simple.

### C.1 — Repères chiffrés sur les grands modèles récents (complément du chapitre 8)

À titre d'illustration de la course au calcul décrite en introduction de l'exposé, l'intervenant cite le modèle Llama 4 Maverick (400 milliards de paramètres au total, 17 milliards de paramètres actifs, entraîné sur environ 22 000 milliards de jetons pour environ 6 millions d'heures-GPU) ainsi que la variante plus grande Behemoth (2 000 milliards de paramètres au total, 300 milliards actifs, environ 30 000 milliards de jetons), dont l'entraînement aurait été interrompu prématurément. Il note que des modèles ouverts plus récents, tels que Kimi K2, présentent des ordres de grandeur de calcul similaires, illustrant la poursuite de cette même tendance à l'échelle du secteur.

### C.2 — Dérivation complète de l'élagage et de la quantification optimaux (complément du chapitre 9)

En notant $W^*$ les poids optimaux d'un modèle entraîné et $\hat{W} = W^* + \delta$ les poids compressés (où $\delta$ est une perturbation contrainte, par exemple imposant qu'un poids donné devienne nul pour l'élagage), le développement de Taylor de la perte autour de $W^*$ s'écrit : $\text{perte}(\hat{W}) \approx \text{perte}(W^*) + \nabla\text{perte}(W^*)^T\delta + \frac{1}{2}\delta^T H\delta$, où $H$ est la matrice hessienne de la perte. Le terme de premier ordre étant négligé (le gradient à l'optimum étant proche de zéro), minimiser la différence de perte entre le modèle compressé et le modèle original revient à minimiser le terme quadratique restant, sous la contrainte structurelle imposée par le type de compression choisi.

La résolution de ce problème quadratique sous contrainte par la méthode des multiplicateurs de Lagrange conduit, pour l'élagage d'un poids $i$, à un impact sur la perte proportionnel à $w_i^2/(2\times[H^{-1}]_{ii})$, et à une mise à jour compensatoire des poids restants proportionnelle à $-w_i/[H^{-1}]_{ii}$ multipliée par la colonne $i$ de l'inverse de la hessienne. Géométriquement, corriger les autres poids en tenant compte de leur corrélation avec le poids supprimé (encodée dans la hessienne) permet d'atteindre une courbe de niveau de la perte strictement meilleure que si l'on se contentait d'éliminer ce poids isolément, sans ajustement des autres — cette correction croisée étant précisément ce qui distingue Optimal Brain Surgeon d'un simple élagage par magnitude.

Pour la quantification, le raisonnement est identique mais la contrainte impose que le poids compressé appartienne à une grille (latis) de valeurs quantifiées prédéfinie ; la formule d'impact sur la perte devient alors $(w_i - q(w_i))^2/(2\times[H^{-1}]_{ii})$, où $q(w_i)$ désigne la valeur quantifiée la plus proche de $w_i$, et la mise à jour compensatoire des autres poids suit une formule analogue à celle de l'élagage.

### C.3 — GPTQ : traitement colonne par colonne (complément du chapitre 10)

Pour une couche de poids $W$ et une entrée $X$ (obtenue par une simple passe avant sur des données de calibration), le problème résolu par GPTQ est de trouver des poids compressés $\hat{W}$ minimisant la norme $\|WX - \hat{W}X\|^2$ sous contrainte de quantification. La hessienne de ce problème de régression, égale à $XX^T$ (ou $X^TX$ selon la convention), ne dépend que des données d'entrée $X$ et non des poids eux-mêmes : elle est donc constante et peut être calculée une seule fois, avant tout traitement des poids.

L'algorithme parcourt ensuite la matrice de poids colonne par colonne : à chaque étape, la colonne courante est quantifiée, l'erreur de sortie ainsi introduite est mesurée, puis toutes les colonnes non encore traitées sont mises à jour pour compenser cette erreur, en utilisant les corrélations encodées dans la hessienne précalculée entre la colonne courante et les colonnes restantes. Ce traitement séquentiel, couche par couche puis colonne par colonne, ramène un problème initialement impraticable à l'échelle du

modèle complet à une succession de problèmes de taille gérable, résolubles en une seule passe sur les données de calibration.