JOUR 6

Écosystème IA local, apprentissage profond géométrique, trajectoires de carrière et éthique de l'IA

1er août 2026 — dernier jour

Intervenants et thèmes principaux :

Mariana Neshovska — AI Albania

Petar Veličković (Google DeepMind) — Apprentissage profond géométrique

Dorothy Chou (Google DeepMind) — Réécrire les règles

Magd — Éthique de l'IA

Avant-propos

Ce document restitue, dans un format pédagogique et objectif, la sixième et dernière journée de l'Eastern European Machine Learning Summer School (EEML) 2026, suivie à distance. Comme pour les journées précédentes, il ne s'agit pas d'une transcription du direct, mais d'une réorganisation thématique du contenu, reformulée en français dans un registre académique neutre.

La journée s'est ouverte sur une présentation de Mariana Neshovska (AI Albania) consacrée à la construction d'un écosystème local d'intelligence artificielle en Albanie. Elle s'est poursuivie par un long exposé de Petar Veličković (Google DeepMind, université de Cambridge) sur l'apprentissage profond géométrique, retraçant l'histoire des symétries en mathématiques pour en tirer une grille de lecture unifiée des architectures de deep learning modernes. L'après-midi a débuté par une intervention plus personnelle et inspirante de Dorothy Chou (Google DeepMind), invitant les participants à interroger les règles implicites qui structurent les trajectoires de carrière dans ce domaine. La journée s'est close sur un exposé volontairement provocateur de Magd (chercheur, ancien de l'équipe éthique de Google), intitulé « pourquoi je ne recommande pas de travailler sur l'éthique de l'IA », consacré aux réalités concrètes — techniques, professionnelles et politiques — de ce champ de recherche.

Comme pour les documents précédents, le corps du texte présente une synthèse concise de chaque chapitre, tandis que les développements plus techniques — en particulier les dérivations mathématiques de la partie consacrée à l'apprentissage profond géométrique — sont regroupés en annexe, avec renvoi explicite depuis chaque chapitre.

Partie I — Construire un écosystème local d'intelligence artificielle

Chapitre 1. AI Albania : bâtir une communauté de recherche là où elle n'existait pas

Cette intervention a été assurée par Mariana Neshovska, professeure d'informatique à l'université de New York Tirana et fondatrice d'AI Albania, premier centre à but non lucratif dédié à l'intelligence artificielle en Albanie.

Idées clés

- L'intervenante part d'un constat : plusieurs personnalités albanaises internationalement reconnues (dont la chercheuse Mira Murati, ancienne directrice technique d'OpenAI) ont dû quitter le pays pour développer leur carrière, faute d'écosystème de recherche, de puissance de calcul et de communauté scientifique locale suffisants.
- Son propre parcours illustre ce constat : doctorante albanaise sans laboratoire de recherche ni calcul disponible dans son université d'origine, elle a découvert EEML par hasard, y a obtenu une bourse, et cette expérience a directement motivé la création, en 2023, d'AI Albania — d'abord sous la forme d'un atelier albanais d'apprentissage automatique organisé avec des chercheurs de Google DeepMind.
- AI Albania revendique aujourd'hui plus de 250 membres, 30 partenaires institutionnels, plus de 25 projets réalisés, organisés en neuf « clusters » thématiques (quantique, IA agentique, éthique de l'IA, etc.).
- Le projet phare actuellement en cours, ASDRN (Albanian Standard Dataset Registry for Emerging NLP), vise à construire les premiers jeux de données standardisés pour la langue albanaise — une langue à

faibles ressources numériques malgré ses 7,5 millions de locuteurs dans le monde — posant ainsi les bases d'un futur modèle de langage albanais ouvert, avec le soutien de programmes de recherche de Microsoft et de Google.

- D'autres initiatives incluent un hackathon régional annuel réunissant des participants de toute la région balkanique, un programme de ressources pédagogiques pour les enseignants, et une étude de perception de l'IA par les enseignants du primaire et du secondaire, menée en collaboration avec le laboratoire de démocratie délibérative de Stanford.

L'intervenante conclut en formulant l'ambition de son organisation : permettre à la prochaine génération de talents albanais de construire une carrière internationalement reconnue sans avoir à quitter le pays — condition qu'aucun des exemples cités en introduction n'avait pu remplir.

Partie II — Apprentissage profond géométrique

Cette intervention a été assurée par Petar Veličković, chercheur senior chez Google DeepMind et enseignant affilié à l'université de Cambridge, coauteur du livre de référence sur l'apprentissage profond géométrique (Geometric Deep Learning).

Chapitre 2. Symétrie, géométrie et groupes : le programme d'Erlangen

L'intervenant retrace, avant d'aborder le deep learning, l'histoire de la notion de symétrie en mathématiques, pour en tirer une méthode transposable à l'étude des architectures de réseaux de neurones.

Repères historiques

- Le terme même de symétrie remonte à Platon (« symmetria », « même mesure »), tandis que la géométrie, pendant plus de deux mille ans, s'est confondue avec la géométrie euclidienne et son postulat des parallèles (par un point extérieur à une droite, il passe exactement une parallèle à cette droite).
- Au XIXe siècle, plusieurs mathématiciens (Lobatchevski, Bolyai, puis Riemann) découvrent, indépendamment, des géométries entièrement cohérentes où ce postulat ne tient plus (géométrie hyperbolique, où plusieurs parallèles sont possibles ; géométrie elliptique, où aucune ne l'est) — bouleversant la croyance en une géométrie euclidienne unique et nécessaire.
- Face à cette prolifération de géométries, Felix Klein propose en 1872, dans son « programme d'Erlangen », de les organiser non plus par leurs objets mais par leurs symétries : ce qui définit une géométrie, ce sont les transformations sous lesquelles ses propriétés restent invariantes.
- Ce programme a eu une influence considérable bien au-delà des mathématiques : il est à l'origine de la théorie des catégories (Eilenberg et Mac Lane citent explicitement Klein), et a inspiré en physique le théorème de Noether (reliant symétries et lois de conservation) puis le modèle standard des particules élémentaires.

L'intervenant propose alors une analogie directe : de même que la géométrie du XIXe siècle a connu une prolifération d'objets divers avant d'être unifiée par la théorie des groupes, l'apprentissage profond des années 2020 connaît une prolifération d'architectures spécialisées (CNN, GNN, LSTM, transformeurs…) qui peuvent, elles aussi, être organisées et comprises à travers les symétries qu'elles respectent — c'est tout l'objet du « plan directeur » de l'apprentissage profond géométrique (Geometric Deep Learning, GDL).

Chapitre 3. Le plan directeur du GDL : invariance et équivariance

Avant de construire ce plan directeur, l'intervenant répond à une objection fréquente : à l'ère des transformeurs, qui semblent se passer de toute contrainte géométrique explicite, étudier les symétries serait-il devenu une « distraction pour matheux » ? Il propose quatre raisons de continuer à s'y intéresser malgré tout : mieux comprendre les données naturelles (intrinsèquement structurées), mieux comprendre les contraintes cachées des transformeurs eux-mêmes, savoir pourquoi certaines architectures (CNN notamment) prennent nécessairement la forme qu'elles ont, et savoir construire des réseaux sur des structures de données non standard (sphères, maillages, etc.).

Définitions fondamentales

- Une transformation de symétrie d'un objet est une application inversible qui préserve la structure de cet objet — par exemple, une rotation de 120° d'un triangle équilatéral le laisse identique à lui-même.

- Une fonction est dite invariante à une symétrie si son résultat ne change pas lorsqu'on applique cette symétrie à son entrée (exemple : un classifieur chat/chien doit donner la même réponse quelle que soit l'orientation de la photo).
- Une fonction est dite équivariante à une symétrie si, lorsqu'on applique cette symétrie à l'entrée, la sortie se transforme de façon prévisible et correspondante (par exemple : décaler un objet dans une image doit décaler de façon identique la prédiction de sa position).
- L'outil mathématique central pour formaliser ces notions est le groupe (un ensemble muni d'une opération associative, avec un élément neutre et un inverse pour chaque élément), auquel on associe une représentation — une façon de traduire chaque transformation abstraite du groupe en une matrice concrète, exploitable par un réseau de neurones.

Le plan directeur du GDL consiste alors à spécifier, pour tout problème donné, un domaine (l'ensemble des positions où vivent les données : grille, ensemble, graphe…), un signal (les données elles-mêmes, définies sur ce domaine), un groupe de symétrie pertinent, et une représentation de ce groupe — à partir de quoi on peut construire une architecture alternant couches équivariantes, non-linéarités équivariantes, et une opération d'invariance finale si une seule prédiction globale est requise.

Détails et formalisation complète de l'invariance et de l'équivariance (diagrammes commutatifs) : voir Annexe A.1.

Chapitre 4. Graphes et transformeurs : les LLM sont des réseaux de passage de messages

L'intervenant applique d'abord ce cadre aux graphes — des ensembles de nœuds reliés par des arêtes — avant de démontrer, en direct, que l'architecture transformeur n'est rien d'autre qu'un cas particulier de réseau de neurones sur graphe.

Idées clés

- La contrainte de symétrie naturelle des graphes est l'invariance (ou l'équivariance) par permutation : l'ordre dans lequel on numérote les nœuds d'un graphe est arbitraire, et un modèle correct ne doit pas dépendre de ce choix.
- Cette contrainte est satisfaite en rendant chaque calcul local : chaque nœud met à jour sa représentation en fonction de ses seules caractéristiques et de celles de ses voisins, agrégées par une fonction elle-même invariante par permutation (somme, moyenne, maximum…) — c'est le principe général du passage de messages (message passing) qui sous-tend l'ensemble des réseaux de neurones sur graphes (GNN).
- En représentant les jetons (tokens) d'une séquence comme les nœuds d'un graphe, et le masque causal des transformeurs comme la structure de voisinage de ce graphe (un jeton n'étant connecté qu'aux jetons qui le précèdent, afin d'éviter toute « triche » lors de la prédiction du jeton suivant), l'intervenant démontre par une réécriture algébrique que le mécanisme d'attention (numérateur et dénominateur du softmax) correspond exactement à un message, une agrégation par somme, et une fonction de mise à jour — autrement dit, un transformeur causal est un réseau de neurones sur graphe.
- Cette lecture explique directement pourquoi les transformeurs, malgré leur réputation de modèles « génériques », intègrent en réalité de fortes contraintes structurelles (partage de paramètres entre positions, interactions limitées à des paires de jetons) — ce qui rejoint les analyses présentées la veille par Federico Barbara sur les phénomènes de sur-mélange et d'effondrement de représentation dans les modèles à contexte long.

Détails et dérivation algébrique complète reliant l'attention aux passages de messages : voir Annexe A.2.

Chapitre 5. Grilles et convolutions : pourquoi les CNN sont incontournables

En restreignant la symétrie de permutation à la seule translation (le voisinage de chaque position d'une grille étant toujours identique, par exemple « un pixel à gauche, un pixel à droite »), l'intervenant montre que la classe de fonctions équivariantes qui en résulte se réduit exactement aux convolutions.

Idées clés

- Un opérateur linéaire équivariant par translation prend nécessairement la forme d'une matrice circulante — un ensemble fixe de coefficients qu'on fait glisser le long du signal.
- C'est un résultat classique du traitement du signal : toute fonction linéaire équivariante par décalage circulaire s'exprime nécessairement comme une convolution. Il n'existe donc, sous cette contrainte précise, aucun autre modèle valide qu'un réseau convolutif pour traiter une image avec une symétrie de translation.
- Ce résultat se généralise directement aux grilles multidimensionnelles (filtres 2D des CNN classiques), et une observation similaire, fondée sur l'invariance au changement de vitesse d'échantillonnage d'un signal temporel, explique pourquoi les réseaux récurrents à portes (LSTM, GRU) intègrent nécessairement des mécanismes de porte pour rester robustes à ce type de déformation.

Chapitre 6. Domaines exotiques : sphères, graphes géométriques et applications sportives

L'intervenant étend ensuite le cadre à des domaines plus exotiques : la sphère, les graphes intégrant des coordonnées spatiales en 3D, et des applications sportives concrètes.

Convolutions sur la sphère

- Certaines données (signaux météorologiques, mesures astrophysiques) vivent naturellement à la surface d'une sphère, où la symétrie pertinente n'est plus la translation mais la rotation en trois dimensions.
- En appliquant la même logique de convolution généralisée à ce nouveau groupe de symétrie, on obtient les réseaux convolutifs sphériques — une architecture ayant remporté le prix du meilleur article à la conférence ICLR en 2018 — dont les couches successives opèrent sur l'espace des rotations 3D (le groupe SO(3)) plutôt que sur la sphère elle-même.

Graphes géométriques et molécules

- Pour des données comme les molécules, où les atomes possèdent à la fois des caractéristiques et des coordonnées spatiales, la symétrie pertinente combine permutation des nœuds et transformations rigides de l'espace 3D (rotations, translations, réflexions), formant le groupe euclidien E(3).
- Un réseau respectant cette symétrie peut, par exemple, ne faire dépendre ses caractéristiques scalaires que des distances entre atomes (invariantes par construction à ces transformations), tandis que la mise à jour des coordonnées elles-mêmes doit rester équivariante à ces mêmes transformations.

Application au football (TacticAI)

- En football, une symétrie approximative — le groupe diédral D2, correspondant aux symétries horizontale et verticale du terrain — permet de traiter les corners joués dans les quatre coins du terrain comme des variantes d'une même situation.

- Exploitée dans le modèle TacticAI (développé avec le club de Liverpool FC, publié dans Nature Communications), cette contrainte améliore significativement l'efficacité des données disponibles, une ressource rare en football professionnel (peu de matchs joués chaque saison) ; le modèle est aujourd'hui utilisé par plusieurs clubs professionnels, notamment pour l'analyse de corners et, plus récemment, pour la prédiction d'actions de jeu ouvert.

Chapitre 7. Variétés et jauges : d'AlphaFold aux maillages

Le dernier domaine abordé est celui des variétés (manifolds) — des surfaces courbes plus générales qu'une simple sphère, comme celles rencontrées en modélisation de protéines ou en aérodynamique — qui nécessitent l'introduction d'une nouvelle forme de symétrie, la symétrie de jauge (gauge symmetry).

Idées clés

- Une variété est un objet qui ressemble localement, au voisinage de chaque point, à un plan (son espace tangent), même si elle est globalement courbée.
- Contrairement à une grille, il n'existe pas de moyen canonique et continu de choisir un système de coordonnées (une jauge) en tout point d'une variété courbe — un résultat connu sous le nom de théorème de la boule chevelue (hairy ball theorem) : on ne peut pas « peigner » une sphère sans créer au moins un épi (une singularité).
- Un modèle correct sur une variété doit donc être équivariant à tout changement local de jauge, ce qui se ramène en pratique, grâce au transport parallèle (le fait de faire pivoter un vecteur d'un point à un autre le long de la surface), à une contrainte d'équivariance locale par rotation, relativement simple à mettre en œuvre malgré l'apparente complexité du problème général.
- Ce même principe — maintenir un référentiel local et prédire des coordonnées par rapport à ce référentiel — est au cœur du fonctionnement d'AlphaFold 2, première architecture équivariante ayant contribué à l'attribution d'un prix Nobel : chaque acide aminé d'une protéine se voit associer un référentiel local, à partir duquel sont prédites les positions de tous ses atomes.

Détails sur le transport parallèle et la dérivation de la couche équivariante de jauge : voir Annexe A.3.

Partie III — Réécrire les règles de la trajectoire professionnelle

Cette intervention, de nature plus personnelle et inspirante que technique, a été assurée par Dorothy Chou, conseillère stratégique chez Google DeepMind, à partir de vingt années d'expérience dans l'industrie technologique (Google, Dropbox, Uber, puis DeepMind).

Chapitre 8. Trois mythes hérités, et comment les réécrire

L'intervenante identifie trois croyances implicites, largement partagées par les jeunes chercheurs de la région, qu'elle invite chacun à interroger plutôt qu'à accepter telles quelles.

Mythe 1 — La réussite se joue en battant les autres

- S'appuyant sur son propre parcours (notamment un épisode où elle a été critiquée, en interne chez Google, pour avoir partagé la responsabilité d'un projet stratégique plutôt que de la garder pour elle seule), l'intervenante avance que la collaboration, et non la compétition individuelle, est le facteur déterminant de réussite dans ce domaine.
- Elle cite la première cause de mortalité des startups — non pas le manque de marché ou de financement, mais la rupture entre cofondateurs — ainsi que l'exemple d'AlphaFold, présenté comme le fruit de décennies de données ouvertes et de collaborations croisées plutôt que d'un génie solitaire.

Mythe 2 — Il faut attendre d'être pleinement qualifié pour se lancer

- L'intervenante oppose l'exemple d'une fondatrice qu'elle a personnellement soutenue, ancienne ingénieure senior chez DeepMind portant un produit fonctionnel et des utilisateurs payants, mais n'ayant pas réussi à lever les fonds nécessaires, à des exemples médiatisés de personnes levant des sommes considérables sur la seule base d'un projet de diapositives.
- Sa conclusion est que les qualifications formelles pèsent souvent moins, dans les décisions de financement ou de recrutement, que la clarté de conviction et la ténacité de la personne — et qu'un refus doit être lu comme la limite de la vision de son interlocuteur, non comme un jugement définitif sur sa propre valeur.

Mythe 3 — Les structures existantes sont immuables, et il faut partir pour compter

- L'intervenante cite un chiffre pour illustrer les effets de cette croyance à l'échelle du secteur : au premier trimestre de l'année en cours, près des deux tiers du capital-risque mondial se seraient concentrés sur seulement quatre entreprises — une concentration qu'elle attribue moins à un manque de talent ou de capital qu'à un manque collectif d'imagination sur les lieux et les façons possibles de construire.
- Elle prend pour contre-exemple InstaDeep, entreprise fondée en Tunisie et rachetée par BioNTech, dont les travaux sur le suivi géographique des maladies infectieuses illustrent qu'un ancrage régional peut constituer un avantage — permettant de percevoir des problèmes que d'autres, plus éloignés, ne voient pas — plutôt qu'un handicap.
- Elle invite en particulier les femmes présentes dans la salle, soulignant l'équilibre de genre relativement favorable des universités de la région comparé à d'autres pays européens, à s'appuyer sur des réseaux tels que Women in Machine Learning, et rappelle enfin que la structure interdisciplinaire de DeepMind lui-même (chercheurs de disciplines très différentes réunis autour d'un même tableau blanc, à l'origine par exemple d'AlphaFold) est elle-même le résultat d'un choix délibéré de réécrire les règles habituelles d'organisation de la recherche.

Partie IV — Ce que signifie (vraiment) travailler sur l'éthique de l'IA

Cette dernière intervention de l'école a été assurée par un chercheur désigné dans la transcription sous le nom de Magd, ancien membre de l'équipe d'IA éthique de Google (dont il a démissionné, selon ses propres mots, « pour des raisons éthiques »), aujourd'hui professeur à l'École Polytechnique à Paris. L'exposé, volontairement provocateur dans son titre — « pourquoi je ne recommande pas de travailler sur l'éthique de l'IA » —, vise moins à décourager qu'à exposer honnêtement les réalités concrètes de ce champ de recherche.

Chapitre 9. Distinguer l'éthique de l'IA des questions de sécurité et d'ingénierie

L'intervenant commence par retirer de la catégorie « éthique de l'IA » un ensemble de sujets qui y sont fréquemment rattachés à tort, selon lui, y compris dans le cadre de cette même école d'été.

Idées clés

- Des sujets tels que l'apprentissage automatique adversarial (empoisonnement de données, évasion de modèles, extraction de données), l'interruptibilité sûre d'un système d'IA, la protection et la vérification de la propriété des données, ou l'alignement d'un modèle avec un objectif donné, sont selon l'intervenant des questions scientifiques et techniques — pas des questions d'éthique.
- Son argument est que ces sujets répondent à des besoins et à des normes déjà définis par la société (par exemple, des lois anciennes protégeant le secret de la correspondance) : le rôle du chercheur y consiste à concevoir une solution technique permettant de respecter une règle déjà établie, non à déterminer ce qui devrait être fait.
- L'éthique, par contraste, est définie comme l'étude de ce qui devrait être fait — une question normative plutôt que technique — étant entendu qu'il existe une boucle de rétroaction entre les deux : une découverte technique (une nouvelle capacité de violation de la vie privée, par exemple) peut informer en retour la réflexion éthique sur ce qui devrait être interdit ou régulé.

Chapitre 10. Le coût personnel : les effets Sagan et Gabru sur la carrière

L'intervenant introduit ensuite un coût de carrière spécifique et documenté, associé au fait de s'engager publiquement sur les questions sociétales de l'IA.

Idées clés

- L'effet Sagan, nommé d'après l'astrophysicien Carl Sagan, désigne le fait que les pairs d'un scientifique tendent à sous-estimer sa productivité et sa rigueur scientifiques dès lors qu'il s'engage dans la vulgarisation ou la communication publique — un phénomène documenté empiriquement dans la littérature, et qui a par exemple contribué au fait que Sagan, malgré une production scientifique supérieure au seuil habituel, n'ait jamais été élu à l'Académie nationale des sciences américaine.
- L'intervenant décrit un phénomène analogue, qu'il nomme par extension « effet Gabru » (du nom de la chercheuse Timnit Gebru), chez les personnes travaillant aujourd'hui sur les conséquences sociétales de l'IA : leur compétence technique tend à être systématiquement sous-estimée par leurs pairs, y compris lorsque leur formation technique est solide et documentée (il rappelle par exemple que Gebru a participé au développement matériel de l'iPad chez Apple avant de rejoindre le champ de l'éthique de l'IA).
- La conséquence concrète, selon l'intervenant, est que les chercheurs travaillant sur ces questions doivent s'attendre, lors d'entretiens d'embauche ou d'évaluations de carrière, à être perçus comme

moins rigoureux techniquement — voire à être qualifiés d'« activistes » plutôt que de scientifiques — quelle que soit la qualité réelle de leur travail.

Chapitre 11. Où peut-on — et ne peut-on pas — mener ce travail ?

L'intervenant passe en revue, un par un, les environnements institutionnels où l'on pourrait espérer mener ce type de recherche, pour conclure qu'aucun d'entre eux, en l'état actuel des choses, n'offre selon lui les conditions nécessaires.

Environnement	Limite identifiée par l'intervenant
Entreprise privée	Autocensure structurelle : impossible d'étudier de façon indépendante des pratiques qui iraient à l'encontre des intérêts commerciaux de l'employeur ; les sujets autorisés restent, selon l'intervenant, superficiels et consensuels.
Institution publique / université	Absence d'accès aux données pertinentes (détenues par les entreprises privées), contraignant le chercheur à des travaux spéculatifs ou empiriquement peu étayés, faute de terrain d'étude accessible.
États et régulateurs	Manque actuel de moyens humains, financiers et techniques pour auditer véritablement les grandes entreprises technologiques, contrairement à ce qui se pratique déjà dans d'autres secteurs industriels.

L'intervenant illustre cette impasse par un exemple concret : il serait, selon lui, impossible d'étudier depuis l'intérieur d'une grande entreprise technologique la façon dont certains régimes autoritaires utilisent les systèmes de recommandation des réseaux sociaux à des fins de répression psychologique — un sujet qu'il juge pourtant légitime, mais structurellement hors de portée dans le cadre institutionnel actuel.

Chapitre 12. Défis techniques propres à l'étude des impacts sociétaux de l'IA

Au-delà des contraintes institutionnelles, l'intervenant identifie des difficultés proprement méthodologiques, qui distinguent ce champ de recherche des problèmes d'apprentissage automatique plus classiques.

Idées clés

- L'absence de vérité de terrain (ground truth) fiable : contrairement à un jeu de données comme MNIST, où l'étiquette correcte d'une image ne fait guère débat, il n'existe généralement pas de label objectivement correct pour des données décrivant des interactions sociales complexes (discours haineux, désinformation, etc.).
- Le travail d'annotation de données repose largement sur une main-d'œuvre payée, souvent dans des conditions de travail documentées comme problématiques ; ce travail reste peu étudié, en partie parce qu'il est structurellement invisibilisé dans les organisations qui en dépendent — l'intervenant note, à titre d'illustration personnelle, n'avoir jamais entendu quiconque, dans une entreprise technologique, désigner spontanément les annotateurs de données comme des « collègues ».
- L'intervenant identifie néanmoins un sous-domaine qu'il juge praticable sans nécessiter d'accès à des données sensibles : la théorie du choix social (social choice theory), qui permet de formaliser mathématiquement, par exemple, l'entraînement collaboratif d'un modèle comme une forme de vote agrégeant les préférences implicites contenues dans chaque paire donnée-étiquette.

Détails et illustration du problème de l'absence de vérité de terrain : voir Annexe B.1.

Chapitre 13. Le véritable goulot d'étranglement est politique, non technique

L'intervenant conclut son exposé, largement prolongé par les échanges avec le public, en formulant sa thèse centrale : les progrès substantiels attendus dans ce domaine ne viendront pas d'une meilleure fonction de perte, mais d'une évolution des structures politiques, juridiques et de gouvernance.

Idées clés

- Un exemple récurrent est celui des réseaux sociaux, dont l'objectif d'optimisation (maximiser le temps passé sur la plateforme, illustré par une citation attribuée au PDG de Netflix selon laquelle « notre principal concurrent est le sommeil ») est aujourd'hui bien identifié et documenté, sans que cela ait, à ce jour, entraîné de conséquences juridiques substantielles pour les entreprises concernées — bien que l'Union européenne commence, selon l'intervenant, à agir sur ce terrain.
- L'intervenant relève un phénomène de deux poids, deux mesures dans l'écosystème international de la recherche : il cite l'exemple d'une conférence scientifique majeure accueillant un stand sponsorisé portant le nom d'un dirigeant politique controversé, une situation qu'il juge impensable si elle impliquait des dirigeants occidentaux, et qu'il présente comme une source d'usure pour quiconque s'engage dans ce champ.
- Face à une question sur la responsabilité individuelle des ingénieurs et chercheurs impliqués dans des systèmes controversés, l'intervenant plaide pour une responsabilité concentrée sur les directions d'entreprise plutôt que sur les employés techniques, ces derniers ayant le plus souvent, selon son expérience des dossiers documentés, signalé les problèmes en interne sans que cela n'entraîne de changement de politique.
- En conclusion, l'intervenant recommande explicitement aux étudiants présents de mesurer, avant de s'engager dans ce champ, le décalage entre l'importance collective de ce travail pour la société et son coût individuel pour la carrière de celui ou celle qui le mène — recommandant à certains de commencer par des activités plus rémunératrices avant de s'y consacrer, et rappelant que ce travail gagne à être mené collectivement plutôt qu'isolément.

Conclusion générale

Cette dernière journée, clôturant l'école d'été, relie des thèmes en apparence très éloignés — écosystème régional de recherche, mathématiques des symétries, trajectoires de carrière, éthique de l'IA — autour d'une même question implicite : quelles structures, souvent présentées comme données ou immuables, méritent en réalité d'être interrogées et, le cas échéant, réécrites ?

Fils conducteurs de la journée

- La présentation d'AI Albania illustre, à l'échelle d'un pays, la construction volontaire d'une structure de recherche là où elle faisait défaut — un thème qui rejoint directement l'intervention de Suad Glass le jour précédent sur l'engagement communautaire.
- L'exposé de Petar Veličković montre comment une même grille de lecture mathématique (les symétries et leurs groupes) permet d'unifier et de justifier rigoureusement des architectures de deep learning en apparence disparates — des CNN aux transformeurs jusqu'à AlphaFold — prolongeant ainsi, sous un angle différent, les analyses sur les contraintes structurelles des transformeurs déjà abordées dans la semaine.
- L'intervention de Dorothy Chou invite à interroger les règles implicites de la compétition, de la légitimité et de la localisation géographique qui façonnent les trajectoires de carrière en intelligence artificielle, en particulier pour les chercheurs de la région.
- L'exposé final sur l'éthique de l'IA referme la boucle en montrant que les limites les plus difficiles à surmonter dans ce domaine ne sont pas d'ordre mathématique, mais institutionnel, professionnel et politique — un message qui, par contraste, met en perspective l'essentiel des contenus plus techniques présentés au cours des journées précédentes.

Ce document restitue les notions abordées dans un cadre pédagogique et objectif ; les nombreux échanges avec le public lors des deux dernières interventions, particulièrement riches, n'ont pu être que partiellement synthétisés dans le corps du texte et l'annexe.

Annexe — Approfondissements par chapitre

Cette annexe reprend, chapitre par chapitre, les développements techniques qui étayent les synthèses présentées dans le corps du document.

A.1 — Formalisation de l'invariance et de l'équivariance (complément du chapitre 3)

Pour un groupe de symétrie G agissant sur un espace d'entrée X (par exemple, une action ρ_X(g) transformant l'entrée), une fonction f est dite invariante à G si, pour tout élément g du groupe, f(ρ_X(g)·x) = f(x) : le résultat ne dépend pas de la transformation appliquée en amont. Elle est dite équivariante à G s'il existe une seconde action ρ_Y(g), définie sur l'espace de sortie, telle que f(ρ_X(g)·x) = ρ_Y(g)·f(x) — c'est-à-dire qu'appliquer la symétrie avant ou après la fonction donne le même résultat, à condition de transformer la sortie selon sa propre action ρ_Y. L'invariance est un cas particulier de l'équivariance, obtenu lorsque ρ_Y est l'identité (la sortie ne change jamais).

Une représentation ρ d'un groupe associe à chaque élément g du groupe une matrice, de telle sorte que la représentation de l'élément neutre soit la matrice identité, et que la représentation d'une composition de deux éléments soit égale au produit des représentations de chaque élément séparément ($\rho(g_1 g_2) = \rho(g_1)\rho(g_2)$) — cette propriété garantissant que les matrices respectent fidèlement la structure algébrique du groupe. Exemple donné en séance : le groupe SO(2) des rotations planes est représenté par les matrices de rotation habituelles (cosinus, sinus) ; le groupe des permutations de n objets est représenté par des matrices de permutation, obtenues en réarrangeant les lignes ou colonnes de la matrice identité.

A.2 — Dérivation complète : l'attention comme passage de messages (complément du chapitre 4)

Pour établir l'équivalence, l'intervenant part de la formule standard de l'attention par produit scalaire : chaque coefficient d'attention α (obtenu par un softmax sur les logits, eux-mêmes calculés à partir du produit scalaire d'une requête et d'une clé) pondère un vecteur de valeur, et la somme pondérée de ces valeurs constitue la nouvelle représentation du jeton receveur.

En réécrivant explicitement le softmax comme une fraction (un numérateur exponentiel divisé par une somme de termes exponentiels sur l'ensemble des voisins autorisés par le masque causal), on peut définir un message comme la paire formée par le numérateur partiel (produit de l'exponentielle du logit et du vecteur de valeur) et le dénominateur partiel (l'exponentielle du logit seule) associés à chaque voisin. L'agrégation de ces messages sur l'ensemble des voisins se fait alors par une simple somme (une opération invariante par permutation, comme l'exige la contrainte de passage de messages), et la fonction de mise à jour finale se réduit à la division du numérateur agrégé par le dénominateur agrégé — retrouvant exactement le résultat du softmax d'origine. La fonction de mise à jour globale du jeton correspond, elle, au réseau à propagation directe (feed-forward network) partagé et appliqué indépendamment à chaque jeton dans un bloc transformeur.

Un point de vigilance signalé par l'intervenant : contrairement à un graphe standard, le graphe sous-jacent à un transformeur causal (défini par le masque d'attention) doit lui-même être permuté de façon cohérente avec les jetons lorsqu'on vérifie la condition d'équivariance par permutation — la structure de voisinage n'est donc pas fixe indépendamment de l'ordre des jetons, contrairement à un graphe moléculaire par exemple.

A.3 — Transport parallèle et couche équivariante de jauge (complément du chapitre 7)

Trois notions successives permettent de manipuler des données sur une variété courbe : l'espace tangent en un point (une approximation locale de la variété par un plan, où l'on peut stocker et manipuler des vecteurs comme dans un espace euclidien ordinaire) ; l'application exponentielle, qui permet de reprojeter un vecteur de l'espace tangent sur la variété elle-même ; et le transport parallèle, qui permet de déplacer un vecteur défini dans l'espace tangent d'un point vers l'espace tangent d'un point voisin, le long de la surface, en préservant son orientation relative.

Plutôt que d'exiger une équivariance simultanée à deux jauges arbitraires et différentes (une pour chaque nœud impliqué dans le passage de message, condition jugée trop complexe à vérifier et à implémenter), l'astuce mathématique présentée consiste à ramener le problème à une équivariance locale à un seul nœud à la fois, en transportant d'abord parallèlement le vecteur du nœud voisin vers le référentiel du nœud receveur — cette opération de transport se réduisant, dans le cas d'une variété localement plane à deux dimensions, à une simple rotation, prédéterminée uniquement par la géométrie de la variété (et non apprise). La couche résultante ressemble alors, formellement, à un réseau de neurones sur graphe standard, à ceci près que les caractéristiques vectorielles des voisins doivent être transportées (pivotées) avant d'être agrégées, et que les matrices de poids doivent elles-mêmes dépendre des angles relatifs entre les référentiels locaux, afin de garantir la symétrie de rotation recherchée en sortie.

B.1 — L'absence de vérité de terrain en apprentissage supervisé sociétal (complément du chapitre 12)

L'intervenant illustre ce problème par contraste avec un jeu de données classique comme MNIST (chiffres manuscrits), où l'étiquette correcte d'une image, bien qu'occasionnellement ambiguë (un « 7 » mal formé pouvant ressembler à un « 1 »), fait globalement consensus. Dès lors que les données décrivent des relations sociales complexes — un commentaire en ligne, une interaction entre individus — la notion même d'étiquette « correcte » devient discutable : deux annotateurs raisonnables peuvent légitimement diverger, sans qu'il existe de procédure objective pour trancher entre eux, ce qui remet en question la validité même de l'approche par apprentissage supervisé classique pour de tels problèmes.