EEML 2026

Eastern European Machine Learning Summer School

Cetinje, Monténégro — 27 juillet au 1er août 2026

TECHNICAL NOTES & LEARNING JOURNAL

Six journées de conférences, restituées et mises en forme pour l'étude

Sylvère Kinox KOUFFOSSI

Étudiant en Intelligence Artificielle (L2)

Institut de Formation et de Recherche en Informatique (IFRI) — UAC, Bénin

Participant en ligne

Préface

J'ai suivi l'édition 2026 de l'Eastern European Machine Learning Summer School (EEML) entièrement à distance, depuis le Bénin, en participant en ligne aux six journées de conférences données à Cetinje, au Monténégro. Je suis étudiant en deuxième année de licence à l'IFRI, sur le parcours Intelligence Artificielle, et je cherchais avant tout à me confronter à un contenu de niveau international, au contact de chercheurs et de laboratoires que je ne croise pas dans mon cursus habituel.

Ce document est né d'un besoin très concret. Au fil des journées, j'ai pris des notes en direct, dans le désordre propre à toute prise de notes en temps réel : parfois en français, parfois en anglais, parfois sous forme de transcription brute d'un passage que je voulais pouvoir relire plus tard, parfois sous forme de synthèse déjà digérée. Ce matériau, précieux sur le moment, restait difficilement exploitable tel quel — trop dense, trop inégal, trop mélangé entre le contenu scientifique et le déroulé logistique de l'événement pour servir de vraie ressource de révision.

J'ai donc entrepris, journée après journée, de reprendre ce matériau pour le transformer en quelque chose que je pourrais relire dans six mois ou dans un an sans avoir à me souvenir du contexte du direct : un contenu réorganisé par thème plutôt que par ordre chronologique, reformulé dans un registre académique neutre, débarrassé des éléments purement logistiques, et structuré de façon à séparer clairement l'essentiel — ce qu'il faut retenir — des développements plus techniques, réservés à qui souhaite approfondir un point précis.

Ce travail poursuit plusieurs objectifs à la fois. Le premier est simplement de consolider mon propre apprentissage : reformuler un contenu, c'est déjà commencer à se l'approprier. Le second est de me constituer une base de référence en français sur des sujets — apprentissage profond géométrique, apprentissage par renforcement, compression de modèles, géométrie des représentations, entre autres — qui structurent une bonne partie de la recherche actuelle en intelligence artificielle, et auxquels je compte revenir régulièrement dans la suite de mon parcours. Le troisième, plus personnel, est de garder une trace fidèle de cette semaine particulière : le hasard d'avoir pu y assister à distance, la diversité des intervenants et des sujets abordés, et la façon dont plusieurs interventions — sur l'engagement communautaire, sur les trajectoires de carrière, sur l'éthique de l'IA — ont autant marqué ma réflexion que les contenus les plus techniques.

Ce document assemble ainsi, dans l'ordre chronologique de l'école d'été, les six comptes rendus que j'ai produits journée après journée. Chacun conserve sa structure propre — synthèses en corps de texte, approfondissements en annexe — telle qu'elle avait été pensée au moment de sa rédaction ; je n'ai pas cherché à lisser artificiellement ces différences d'une journée à l'autre, préférant qu'elles témoignent de la progression réelle de ce travail au fil de la semaine.

Table des matières

Préface

Conclusion personnelle

JOUR 1 — Fondements du Deep Learning et géométrie des représentations neuronales

- Partie I — Des modèles linéaires aux réseaux de neurones profonds
  - Chapitres 1 à 6 : du problème XOR au gradient qui s'annule
- Partie II — Géométrie des représentations neuronales
  - Chapitres 7 à 10 : lecture géométrique, métriques de similarité, hypothèse platonicienne

JOUR 2 — Apprentissage par renforcement, estimation statistique apprise et atelier pratique

- Partie I — Introduction à l'apprentissage par renforcement (chapitres 1 à 7)
- Partie II — Statistics Upside Down, Kyunghyun Cho (chapitres 8 à 11)
- Partie III — Atelier pratique : construire un agent RL (chapitres 12 et 13)

JOUR 3 — Contexte long, capital-risque et apprentissage continu

- Partie I — Propagation de l'information en contexte long, Federico Barbara (chapitres 1 à 4)
- Partie II — Notions de capital-risque, Máté Mitk (chapitres 5 et 6)
- Partie III — Apprentissage continu, Claire Lyle et Razvan Pascanu (chapitres 7 à 11)

JOUR 4 — Calcul haute performance, IA en biomédecine et en mathématiques, RL et estimation statistique

- Ouverture — Le calcul haute performance (EuroCC / EuroHPC)
- Conférence — L'IA au service de la biomédecine, Maria Brbić (EPFL)
- Présentation partenaire — Les agents d'automatisation informatique (UiPath)
- Conférence — L'apprentissage automatique au service des mathématiques, Matia Tapušković (Oxford)
- Notions fondamentales — L'apprentissage par renforcement
- Conférence — « Statistics Upside Down », Kyunghyun Cho (NYU)

JOUR 5 — Engagement communautaire, IA médicale, recherches régionales et apprentissage efficace en calcul

- Partie I — L'association ANT, Suad Glass (chapitres 1 et 2)
- Partie II — IA pour la médecine, Elma Dervishi (chapitres 3 et 4)
- Partie III — Recherches régionales en vitrine (chapitres 5 à 7)
- Partie IV — Apprentissage informatiquement efficace, Dan Alistarh (chapitres 8 à 11)

JOUR 6 — Écosystème IA local, apprentissage profond géométrique, trajectoires de carrière et éthique de l'IA

- Partie I — AI Albania, Mariana Neshovska (chapitre 1)
- Partie II — Apprentissage profond géométrique, Petar Veličković (chapitres 2 à 7)

- Partie III — Réécrire les règles de la trajectoire professionnelle, Dorothy Chou (chapitre 8)
- Partie IV — Éthique de l'IA, Magd (chapitres 9 à 13)

JOUR 1

Fondements du Deep Learning et géométrie des représentations neuronales

27 juillet 2026

Intervenants et thèmes principaux :

Session 1 — Des modèles linéaires aux réseaux de neurones profonds

Session 2 — Géométrie des représentations (hypothèse platonicienne)

Avant-propos

Ce document constitue une restitution structurée de la première journée de l'Eastern European Machine Learning Summer School (EEML) 2026, suivie à distance. Il ne s'agit pas d'une transcription brute de l'intervention orale, mais d'une réorganisation pédagogique du contenu : les notions sont regroupées par thème, reformulées dans un registre académique neutre et présentées selon une progression logique plutôt que selon l'ordre chronologique du direct.

La journée a comporté deux interventions principales. La première portait sur les fondements des réseaux de neurones profonds, depuis les limites des modèles linéaires jusqu'aux techniques ayant permis l'essor du deep learning moderne. La seconde, consacrée à la géométrie des représentations neuronales, a exploré la question de savoir dans quelle mesure différents modèles d'intelligence artificielle apprennent des représentations comparables du monde.

Le corps du document présente, pour chaque chapitre, une synthèse concise des idées essentielles. Les développements plus détaillés — démonstrations intuitives, exemples numériques, schémas commentés — sont regroupés en annexe, avec un renvoi explicite depuis chaque chapitre concerné, conformément à la structure demandée.

Partie I — Des modèles linéaires aux réseaux de neurones profonds

Chapitre 1. Les limites des modèles linéaires : le problème XOR

La régression logistique et le perceptron sont deux modèles d'apprentissage très proches : tous deux définissent une frontière de décision linéaire de la forme $w_1x_1 + w_2x_2 + b = 0$. Cette frontière ne fonctionne que lorsque les classes sont linéairement séparables.

Idées clés

- En 1969, Marvin Minsky et Seymour Papert démontrent, dans leur ouvrage Perceptrons, qu'un perceptron à une seule couche ne peut pas apprendre la fonction logique XOR (« ou exclusif »), car ce problème n'est pas linéairement séparable.
- Cette démonstration a été généralisée à tort : elle a conduit une partie de la communauté scientifique à conclure que les réseaux de neurones, plus largement, étaient d'une capacité limitée.
- Les conséquences ont été notables : réduction des financements et ralentissement des recherches sur les réseaux de neurones — une période aujourd'hui connue sous le nom de premier « hiver de l'IA ».
- La solution — l'ajout d'une couche cachée — était pourtant déjà à portée : un réseau multicouche permet de construire des frontières de décision non linéaires et résout le problème XOR sans difficulté.

Détails, table de vérité et représentation graphique : voir Annexe A.1.

Chapitre 2. Du feature engineering à l'apprentissage de représentations

Face à un problème non linéairement séparable, deux stratégies sont possibles : changer de modèle, ou changer la représentation des données. La seconde approche consiste à transformer les variables d'entrée x en de nouvelles variables $\phi(x)$, choisies de sorte que le problème redevienne linéairement séparable. Ce travail de construction manuelle de variables est appelé feature engineering (ingénierie des caractéristiques).

Idées clés

- Le feature engineering a dominé la recherche en apprentissage automatique dans les années 1980-1990, notamment en vision par ordinateur.
- Cette approche devient impraticable dès que la dimensionnalité des données augmente (des milliers, voire des millions de variables dans le cas d'images).
- L'idée fondatrice du deep learning est d'inverser la logique : au lieu de fabriquer les caractéristiques à la main, on laisse le modèle les apprendre directement à partir des données. C'est le principe du representation learning (apprentissage de représentations).
- Sur le plan architectural, cela se traduit par l'ajout d'une couche cachée (hidden layer) entre l'entrée et la classification : cette couche apprend automatiquement une nouvelle représentation utile des données, sans intervention humaine directe.

Détails, schémas et exemple appliqué à la reconnaissance faciale : voir Annexe A.2.

Chapitre 3. Anatomie d'un réseau de neurones feedforward

Un réseau de neurones artificiel s'inspire du fonctionnement du cerveau biologique, sans en constituer une réplique fidèle : un seul neurone biologique reste considérablement plus complexe qu'un neurone artificiel. Cette architecture porte plusieurs noms selon la propriété que l'on souhaite souligner : réseau de neurones artificiel (ANN), réseau feedforward (l'information circule uniquement de l'entrée vers la sortie) et réseau entièrement connecté (fully connected), où chaque neurone d'une couche est relié à tous les neurones de la couche suivante.

Le calcul, couche par couche

- Pré-activation : $a(x) = W_1^T x + b_1$ — une simple combinaison linéaire des entrées.
- Activation : $h(x) = g(a(x))$, où g est une fonction non linéaire (sigmoïde, tanh…). C'est cette étape qui introduit la non-linéarité.
- Sortie : $y = f(W_2^T h + b_2)$, où f est choisie selon la tâche (identité pour la régression, sigmoïde pour la classification binaire, softmax pour la classification multiclasse).

Détails sur les fonctions d'activation et le choix de la couche de sortie : voir Annexe A.3.

Chapitre 4. Entraînement d'un réseau : descente de gradient et rétropropagation

Pourquoi une fonction non linéaire est-elle indispensable ? Parce que la composition de deux transformations linéaires reste une transformation linéaire : empiler des couches purement linéaires n'apporte donc aucune puissance de modélisation supplémentaire par rapport à un modèle linéaire simple. L'introduction d'une non-linéarité (sigmoïde, tanh, puis plus tard ReLU) est ce qui confère au réseau sa capacité à modéliser des relations complexes.

Idées clés

- L'entraînement d'un réseau de neurones repose sur les mêmes principes que ceux de la régression logistique : descente de gradient et minimisation d'une fonction de perte.
- Le calcul des gradients s'effectue par application de la règle de dérivation en chaîne, depuis la sortie jusqu'à l'entrée.
- La rétropropagation (backpropagation) est l'algorithme qui applique cette règle de manière efficace, par programmation dynamique, ce qui rend l'entraînement de réseaux comptant des millions de paramètres possible en pratique.

- Historiquement, l'algorithme a été décrit dès 1974 dans la thèse de Paul Werbos, avant d'être popularisé par l'article de David Rumelhart, Geoffrey Hinton et Ronald Williams en 1986.
- Les bibliothèques modernes (PyTorch, TensorFlow, JAX) automatisent entièrement ce calcul grâce à la différentiation automatique (autodiff), ce qui a considérablement accéléré la recherche en deep learning.

Détails et repères historiques sur les frameworks de calcul de gradients : voir Annexe A.4.

Chapitre 5. Expressivité et capacité d'apprentissage

Le théorème d'approximation universelle (Hornik, 1991) établit qu'un réseau de neurones à une seule couche cachée peut approximer n'importe quelle fonction continue, à condition de disposer d'un nombre suffisant de neurones. Ce résultat, bien que puissant en apparence, appelle une nuance essentielle.

Idées clés

- La formulation « à condition d'avoir suffisamment de neurones » cache un piège : ce nombre peut croître de façon exponentielle avec la complexité du problème, ce qui expose le modèle au surapprentissage (overfitting).
- Il faut distinguer deux notions : l'expressivité, c'est-à-dire ce qu'un modèle peut représenter en théorie, et la capacité d'apprentissage (learnability), c'est-à-dire ce que l'algorithme d'entraînement (la descente de gradient) parvient réellement à trouver.
- Un jeu de poids optimal peut exister sans qu'aucun algorithme connu ne soit capable de le découvrir.
- C'est cette limite qui motive le passage à des réseaux profonds (plusieurs couches successives) plutôt qu'à un unique réseau très large : chaque couche effectue une transformation modérée, et l'empilement de plusieurs couches permet d'atteindre une séparabilité satisfaisante sans recourir à un nombre exponentiel de neurones.

Détails et illustration progressive de la séparation des données couche après couche : voir Annexe A.5.

Chapitre 6. Le problème du gradient qui s'annule et ses remèdes

Dans les années 1990, les réseaux profonds n'ont pas tenu leurs promesses : un réseau à trois ou cinq couches obtenait parfois de moins bons résultats qu'un réseau à une seule couche cachée. La cause identifiée est le phénomène du vanishing gradient (gradient qui s'annule) : les dérivées des fonctions sigmoïde et tanh étant toujours inférieures à 1, leur multiplication successive à travers de nombreuses couches fait tendre le gradient vers zéro, empêchant l'apprentissage des couches les plus profondes.

Solutions historiques

- Le greedy layer-wise pretraining (Hinton et al., 2006 ; Bengio et al.) entraîne le réseau couche par couche à l'aide d'autoencodeurs — des réseaux apprenant, sans étiquettes, à reconstruire leur propre entrée à partir d'une représentation compressée. Chaque couche est figée avant l'entraînement de la suivante, puis l'ensemble est affiné (supervised fine-tuning) sur la tâche finale. Cette méthode, précurseur du couple pré-entraînement/fine-tuning utilisé aujourd'hui pour les grands modèles de langage, améliore l'initialisation des poids mais ne résout pas fondamentalement le problème du gradient.
- Le remplacement des fonctions d'activation constitue la solution la plus directe : la fonction ReLU (Rectified Linear Unit), f(x) = max(0, x), possède une dérivée constante (1) sur sa partie positive, ce qui limite fortement l'atténuation du gradient.

- La ReLU introduit toutefois un nouvel écueil, celui des neurones morts (dead neurons), qui restent bloqués dans leur partie négative et cessent d'apprendre. La Leaky ReLU ($f(x) = \max(\varepsilon x, x)$) corrige ce défaut en laissant passer un faible gradient même côté négatif.
- Des fonctions d'activation plus récentes, comme Swish et SwiGLU (utilisée dans plusieurs grands modèles de langage actuels), affinent encore ce principe et contribuent aux performances des architectures modernes.

Détails, étapes du greedy layer-wise pretraining et comparaison des fonctions d'activation : voir Annexe A.6.

Partie II — Géométrie des représentations neuronales

La seconde intervention de la journée change de perspective : plutôt que d'étudier comment un réseau de neurones apprend, elle interroge la nature de ce qu'il apprend, à travers une lecture géométrique des représentations internes.

Chapitre 7. Une lecture géométrique des réseaux de neurones

Chaque couche d'un réseau de neurones peut être vue comme une représentation (ou embedding) des données : elle associe à chaque exemple un point dans un espace vectoriel. Les données brutes elles-mêmes constituent déjà un embedding — une image couleur de 256 × 256 pixels est un point dans un espace à 196 608 dimensions.

Idées clés

- Le réseau ne fait, couche après couche, que déplacer un nuage de points (point cloud) dans de nouveaux espaces, jusqu'à ce que les catégories deviennent facilement séparables.
- Classifier revient ainsi, géométriquement, à rapprocher les points d'une même classe et à éloigner ceux de classes différentes — puis, en sortie, à envoyer chaque nuage vers un sommet du simplex (l'espace des distributions de probabilité).
- Chaque type de couche dispose d'un répertoire d'actions limité : une couche linéaire ne peut effectuer que des transformations affines (rotation, étirement, translation) ; la fonction ReLU agit point par point en écrasant les valeurs négatives ; la fonction softmax convertit des scores bruts (logits) en probabilités.
- C'est l'empilement de ces opérations élémentaires, simples individuellement, qui permet au réseau de réaliser des réorganisations complexes du nuage de données.

Détails, notion de simplex et description de la visualisation animée de l'entraînement par SGD : voir Annexe B.1.

Chapitre 8. Comparer deux représentations : les métriques de similarité

Cette lecture géométrique ouvre une question de recherche active en interprétabilité : deux réseaux de neurones entraînés séparément apprennent-ils la « même » représentation des données ? Plusieurs familles de métriques permettent d'apporter une réponse nuancée.

Trois grandes familles de métriques

- Les métriques par régression : on cherche à prédire les embeddings d'un réseau à partir de ceux d'un autre (typiquement par régression linéaire). Une faible erreur résiduelle indique une forte similarité. Cette approche est intuitive mais peut être trompeuse : une transformation trop permissive peut faire apparaître deux représentations comme identiques alors que l'une a perdu de l'information.
- Les métriques par alignement de noyaux (kernel alignment), dont la plus connue est le CKA (Centered Kernel Alignment) : plutôt que de comparer les coordonnées des points, on compare les relations de proximité entre les objets (distances, similarités). Cette approche reste valable même lorsque les deux réseaux produisent des embeddings de dimensions différentes, et elle est insensible aux rotations, translations et changements d'échelle.
- Les métriques par plus proches voisins (Mutual k-Nearest Neighbors, MKNN) : on vérifie si les deux réseaux s'accordent sur l'identité des voisins les plus proches de chaque point, sans exiger l'égalité exacte des distances.

Le message central de ce chapitre est qu'il n'est pas nécessaire que deux réseaux produisent des vecteurs numériquement identiques pour que l'on puisse parler de représentations équivalentes : ce qui importe est la préservation des relations structurelles entre les objets représentés.

Détails, exemples chiffrés et tableau comparatif complet des métriques : voir Annexe B.2.

Chapitre 9. L'hypothèse platonicienne de la représentation

Prolongeant les chapitres précédents, l'hypothèse platonicienne de la représentation (Platonic Representation Hypothesis) avance que des modèles d'intelligence artificielle entraînés indépendamment — voire des cerveaux biologiques — tendraient à converger vers une organisation similaire de l'information, reflétant une structure sous-jacente commune du monde.

Idées clés

- L'égalité numérique exacte des représentations n'est ni attendue ni nécessaire : les réseaux de neurones possèdent des symétries internes (une rotation globale des embeddings, compensée par une rotation équivalente du classifieur final, laisse les prédictions inchangées).
- Mesurée par la métrique MKNN, l'alignement entre modèles de vision et modèles de langage s'est renforcé au fil des générations de modèles, suggérant une convergence vers une organisation conceptuelle comparable.
- Cette tendance est toutefois moins nette lorsqu'elle est mesurée par CKA, qui peut artificiellement augmenter avec la simple augmentation de la taille des modèles, sans réelle convergence sous-jacente.
- L'accord entre modèles est plus net à un niveau sémantique global (grandes catégories) qu'à un niveau très fin (voisin le plus proche parmi un million d'exemples), où des différences d'organisation subsistent.
- Pour certaines familles de modèles, la convergence peut être démontrée mathématiquement : les apprentissages contrastifs de type InfoNCE convergent vers un noyau lié à l'information mutuelle ponctuelle ; deux modèles de type CLIP entraînés indépendamment convergent vers des embeddings reliés par une simple transformation orthogonale.

Détails sur l'alignement entre langues et sur les nuances apportées par les travaux évoqués en séance : voir Annexe B.3.

Chapitre 10. Applications et discussion finale

L'intérêt de mesurer l'alignement entre représentations n'est pas seulement théorique : il conditionne la capacité à faire coopérer des modèles entraînés séparément.

Applications évoquées

- CLIP illustre un alignement construit explicitement : un encodeur d'images et un encodeur de texte sont entraînés conjointement pour que l'embedding d'une image et celui de sa légende pointent dans la même direction.
- REPA (Representation Alignment) illustre un alignement guidé : un modèle de diffusion est entraîné pour que ses représentations internes se rapprochent de celles d'un encodeur de vision déjà pré-entraîné, ce qui accélère et stabilise son apprentissage.
- L'alignement non apparié (unpaired alignment) montre que, si deux espaces d'embeddings sont reliés par une isométrie (une transformation qui préserve les distances), la correspondance entre eux peut

être retrouvée à partir de la seule géométrie des deux nuages de points, sans exemples appariés (image-légende, phrase-traduction).

Bénéfices et limites évoqués en discussion

- Bénéfices : connexion de modèles par une simple « couche de raccordement », transfert d'apprentissage, partage de supervision entre modalités, réutilisation de représentations existantes comme fondation pour de nouveaux modèles.
- Limite potentielle : une convergence excessive entre modèles pourrait réduire la diversité des façons de raisonner (risque de « mode collapse » ou d'uniformisation des représentations).
- Question ouverte sur les world models : l'hypothèse d'une convergence géométrique entre modèles n'a pas encore été étudiée systématiquement pour les modèles du monde, mais elle serait cohérente avec l'idée que les grands modèles de langage construisent une forme de modèle interne du monde.
- La séance s'est achevée sur une question restée sans réponse, portant sur les architectures multimodales sans encodeur de vision séparé (de type Gemma), la transcription s'interrompant avant la réponse de l'intervenant.

Détails et compte rendu complet des échanges avec le public : voir Annexe B.4.

Conclusion générale

Les deux interventions de cette première journée, bien que traitant de sujets distincts, dessinent une même trajectoire intellectuelle : celle du passage de modèles simples et contraints (régression logistique, perceptron) vers des architectures profondes capables d'apprendre automatiquement des représentations complexes, puis vers une réflexion sur la nature même de ces représentations.

Fils conducteurs de la journée

- Le passage de l'ingénierie manuelle de caractéristiques à leur apprentissage automatique constitue le socle conceptuel du deep learning.
- La profondeur d'un réseau (plusieurs couches) répond à une limite pratique de l'apprentissage — et non de l'expressivité théorique — des réseaux peu profonds.
- Les difficultés d'entraînement des réseaux profonds (gradient qui s'annule) ont retardé, mais non invalidé, cette approche ; leur résolution progressive (nouvelles activations, pré-entraînement, outils de calcul automatique des gradients) a permis l'essor du deep learning moderne.
- Une fois entraînés, ces réseaux peuvent être analysés comme des systèmes géométriques qui réorganisent progressivement les données, ce qui ouvre la voie à la comparaison de modèles entre eux et à l'hypothèse d'une convergence vers des représentations du monde partagées.

Ce document restitue les notions abordées dans un cadre pédagogique et objectif ; il ne prétend pas à l'exhaustivité de l'intervention orale, dont certains échanges avec le public n'ont pu être que partiellement restitués.

Annexe — Approfondissements par chapitre

Cette annexe reprend, chapitre par chapitre, les développements, exemples et éléments visuels qui étayent les synthèses présentées dans le corps du document.

A.1 — Le problème XOR (complément du chapitre 1)

La fonction logique XOR (« ou exclusif ») retourne 0 lorsque ses deux entrées sont identiques, et 1 lorsqu'elles diffèrent :

X_1	X_2	XOR
0	0	0
0	1	1
1	0	1
1	1	0

Si l'on place ces quatre points dans le plan (X_1, X_2), les points de classe 1 — (0,1) et (1,0) — se trouvent sur une diagonale, tandis que les points de classe 0 — (0,0) et (1,1) — se trouvent sur l'autre diagonale. Aucune droite ne peut séparer ces deux groupes : quel que soit son emplacement, au moins un point se retrouve du mauvais côté. Une frontière de décision valide devrait ressembler à deux régions disjointes entourant chaque paire de points de même classe — ce qui n'est plus une frontière linéaire, mais une frontière composée de plusieurs segments.

Minsky et Papert ont démontré ce résultat de façon rigoureuse en 1969, ce qui a été interprété, à tort, comme une limite générale des approches fondées sur l'apprentissage par descente de gradient — freinant la recherche sur les réseaux de neurones pendant près d'une décennie, jusqu'à la généralisation de l'usage des couches cachées et, plus tard, de la rétropropagation.

A.2 — Du feature engineering au representation learning (complément du chapitre 2)

Pour rendre le problème XOR linéairement séparable, il suffit de construire deux nouvelles variables $\phi_1(x)$ et $\phi_2(x)$ à partir des entrées originales (par exemple des combinaisons logiques telles que « x_1 ET NON x_2 »), puis d'appliquer une régression logistique standard sur ces nouvelles variables. Le classifieur reste inchangé ; seule la représentation des données change.

Cette approche, appelée feature engineering, exige une expertise humaine du domaine. En reconnaissance faciale par exemple, un ingénieur pouvait construire manuellement des variables telles que la distance entre les yeux, la largeur du nez ou la forme des sourcils. Cette méthode devient impraticable dès que le nombre de variables augmente : pour une image de plusieurs milliers de pixels, concevoir manuellement des caractéristiques pertinentes est hors de portée.

Le pipeline classique des années 1980-1990 était : Image → Feature engineering (humain) → Classifieur linéaire ou SVM → Prédiction. Le representation learning inverse cette logique : Données → Apprentissage automatique des représentations → Classifieur → Prédiction. Architecturalement, cela revient à insérer une couche cachée entre l'entrée et la sortie ; les poids de cette couche (souvent notés v_{11}, v_{12}, v_{21}, v_{22}...) sont appris par descente de gradient, au même titre que les poids du classifieur final. On parle de couche « cachée » non pas parce qu'elle est dissimulée, mais parce qu'aucune signification n'est imposée a priori à ce qu'elle apprend : seul compte le résultat final de la prédiction.

A.3 — Fonctions d'activation et couche de sortie (complément du chapitre 3)

Les deux fonctions d'activation historiquement utilisées pour les couches cachées sont :

- Sigmoïde : $\sigma(a) = 1 / (1 + e^{-a})$, à valeurs dans l'intervalle (0, 1).
- Tangente hyperbolique (tanh) : à valeurs dans l'intervalle (−1, 1), centrée sur zéro, ce qui facilite souvent l'apprentissage par rapport à la sigmoïde.

Le choix de la fonction d'activation de sortie dépend de la nature de la tâche :

Tâche	Activation de sortie	Remarque
Régression	Identité	Aucune contrainte sur la valeur prédite
Classification binaire	Sigmoïde	Renvoie une probabilité entre 0 et 1
Classification multiclasse	Softmax	Probabilités sur toutes les classes, dont la somme vaut 1

Remarque terminologique : l'intervenant emploie parfois le terme « multi-label » pour désigner ce qui correspond en réalité à la classification multiclasse (une seule classe correcte parmi plusieurs, via softmax). Une véritable classification multi-label — où plusieurs classes peuvent être vraies simultanément — repose en général sur une sortie sigmoïde indépendante pour chaque classe.

A.4 — Rétropropagation et outils de calcul (complément du chapitre 4)

L'entraînement suit le cycle : prédiction → calcul de l'erreur → calcul des gradients (règle de la chaîne) → mise à jour des poids → nouvelle prédiction. Faire ce calcul « à la main », terme par terme, serait extrêmement coûteux pour un réseau à plusieurs couches ; la rétropropagation résout ce problème en réutilisant efficacement les calculs intermédiaires, selon un principe de programmation dynamique.

L'algorithme a été redécouvert à plusieurs reprises dans l'histoire de la discipline. Deux jalons sont généralement cités : la thèse de doctorat de Paul Werbos (1974), puis l'article de David Rumelhart, Geoffrey Hinton et Ronald Williams (1986), qui en a popularisé l'usage pour l'entraînement des réseaux de neurones.

Les bibliothèques de différentiation automatique ont, elles aussi, une histoire longue : Torch (Collobert et al., 2002), Theano (issu du groupe de Yoshua Bengio, 2007-2008), Caffe, puis TensorFlow, PyTorch et plus récemment JAX. Ces outils calculent aujourd'hui automatiquement les gradients — une opération qu'il fallait auparavant implémenter manuellement — ce qui a grandement facilité l'expérimentation à grande échelle en deep learning.

A.5 — Expressivité, apprentissage et profondeur (complément du chapitre 5)

Le théorème d'approximation universelle (Hornik, 1991) porte sur l'expressivité d'un réseau à une seule couche cachée : il garantit l'existence d'une configuration de poids permettant d'approximer n'importe quelle fonction continue, sans garantir que cette configuration soit atteignable par un algorithme d'apprentissage donné. Une illustration intuitive : la combinaison de plusieurs fonctions en forme de « marche » ou de plusieurs sigmoïdes permet déjà de construire des frontières de décision courbes, puis, en en combinant davantage, des frontières arbitrairement complexes (par exemple des régions imbriquées les unes dans les autres).

Le recours à des réseaux profonds (plusieurs couches successives de projections non linéaires) répond à une intuition simple : au lieu de tenter de séparer des données mêlées en une seule transformation potentiellement très large, chaque couche effectue une séparation partielle, progressive. Illustration schématique :

- Données initiales : classes mélangées (○ ● ○ ● ● ○)
- Après la 1re couche : début de regroupement (○ ○ ● ● ○ ●)
- Après la 2e couche : regroupement plus marqué (○ ○ ○ ● ● ●)
- Après la 3e couche : classes presque parfaitement séparables, qu'une simple régression logistique finale peut alors distinguer.

Ce processus est entièrement piloté par les données : aucune consigne explicite n'indique au réseau selon quel critère séparer à chaque étape ; ces représentations intermédiaires émergent de la descente de gradient. C'est précisément ce mécanisme qui n'a pas fonctionné comme attendu dans les années 1990 (voir chapitre 6 et annexe A.6), en raison du problème du gradient qui s'annule.

A.6 — Le gradient qui s'annule : mécanisme et remèdes (complément du chapitre 6)

Mécanisme : la dérivée de la sigmoïde est toujours inférieure à 0,25, et proche de zéro lorsque les poids sont initialisés près de zéro. Lorsque le gradient de l'erreur est propagé de la sortie vers les premières couches, il est multiplié, à chaque couche traversée, par un facteur de cet ordre. Pour un réseau à cinq couches ou plus, ce produit de facteurs très inférieurs à 1 fait tendre le gradient vers zéro dans les couches les plus profondes, qui cessent alors d'apprendre efficacement.

Étapes du greedy layer-wise pretraining (Hinton et al., 2006 ; étendu par Bengio et al. aux autoencodeurs) :

- 1. Entraîner un autoencodeur reliant les données X à une représentation H1, puis à une reconstruction de X ; ne conserver que l'encodeur (X → H1).
- 2. Figer cette première couche, puis entraîner un second autoencodeur reliant H1 à H2, et ainsi de suite pour chaque couche supplémentaire.
- 3. Empiler les encodeurs ainsi obtenus (X → H1 → H2 → … → Hk), ajouter une couche de classification, puis affiner l'ensemble du réseau sur la tâche finale (supervised fine-tuning).

Il est important de noter que cette méthode n'élimine pas mathématiquement le problème du gradient qui s'annule : l'architecture du réseau reste inchangée, et le gradient continue de s'atténuer pendant la phase de fine-tuning. Le bénéfice est indirect : les couches disposent déjà, grâce au pré-entraînement, de représentations utiles, ce qui rend l'entraînement supervisé plus stable en pratique — un principe qui préfigure le couple pré-entraînement / fine-tuning des grands modèles de langage actuels.

La solution la plus directe consiste à remplacer les fonctions d'activation saturantes (sigmoïde, tanh) par la ReLU, f(x) = max(0, x), dont la dérivée vaut exactement 1 sur la partie positive — le gradient traverse alors les couches sans être atténué lorsque le neurone est actif. Le revers de cette solution est le phénomène des neurones morts : un neurone dont l'entrée reste toujours négative a une sortie et un gradient constamment nuls, et cesse donc d'apprendre. La Leaky ReLU, f(x) = max(εx, x) avec ε petit (par exemple 0,01), corrige ce défaut en laissant passer un gradient résiduel côté négatif. Des activations plus récentes, telles que Swish (x·σ(x)) et SwiGLU — qui combine une activation de type Swish à un mécanisme de porte (gating) contrôlant l'information transmise —, sont aujourd'hui utilisées dans de nombreux modèles de grande taille.

B.1 — Embeddings, nuages de points et simplex (complément du chapitre 7)

Un embedding associe à chaque exemple (une image, un mot…) un vecteur de nombres, c'est-à-dire un point dans un espace de grande dimension. Deux exemples sémantiquement proches (deux images de voitures, par exemple) tendent à être associés à des points proches dans cet espace, tandis que deux exemples très différents (une voiture et un requin-baleine) en sont éloignés — un phénomène qui apparaît de manière constante quel que soit l'objectif d'entraînement (classification supervisée, apprentissage auto-supervisé, apprentissage contrastif).

Chaque couche du réseau produit son propre nuage de points, obtenu en réorganisant celui de la couche précédente. Les données brutes elles-mêmes constituent le tout premier de ces nuages : une image couleur de 256 × 256 pixels est un point dans un espace à 256 × 256 × 3 = 196 608 dimensions.

Le simplex est l'espace de toutes les distributions de probabilité possibles sur un ensemble de classes. Pour une classification binaire, il s'agit du segment reliant les points (1, 0) et (0, 1) : un point (0,5 ; 0,5) sur ce segment correspond à une incertitude totale entre les deux classes. Pour trois classes, le simplex devient un triangle, dont chaque sommet représente une certitude absolue en faveur d'une classe. L'objectif de l'entraînement peut alors se lire géométriquement : déplacer chaque point du nuage de données vers le sommet du simplex correspondant à sa vraie classe.

Chaque type de couche ne dispose que d'un répertoire d'opérations restreint :

- Une couche linéaire ne peut réaliser que des transformations affines du nuage de points : rotation, étirement, compression, translation — jamais de courbure.
- La fonction ReLU agit indépendamment sur chaque coordonnée : elle « écrase » sur zéro toute valeur négative et laisse inchangée toute valeur positive, introduisant ainsi la non-linéarité nécessaire.
- La fonction softmax convertit des scores bruts (logits), non contraints, en un point du simplex — c'est-à-dire en une distribution de probabilité valide.

La démonstration présentée en séance faisait visualiser, pour un petit réseau de largeur 2 entraîné par descente de gradient stochastique (SGD), comment l'alternance de couches linéaires et de ReLU étire, replie puis sépare progressivement deux nuages de points (par exemple deux classes « chat » et « chien »), jusqu'à ce que softmax les projette chacun vers un sommet distinct du simplex.

B.2 — Métriques de similarité représentationnelle (complément du chapitre 8)

Formellement, une métrique de similarité représentationnelle est une fonction $S(f_1, f_2)$ qui prend en entrée deux réseaux (ou deux couches) et renvoie un score : proche de 1 pour des représentations quasi identiques, proche de 0 pour des représentations très différentes. En pratique, on ne compare pas directement les réseaux mais l'action de chacun sur un même ensemble de points de test (probe points), ce qui produit deux nuages d'embeddings Z1 et Z2 à comparer.

Métriques par régression

On mesure l'erreur résiduelle d'une régression (le plus souvent linéaire) entraînée à prédire les embeddings du second réseau à partir de ceux du premier. Deux nuages reliés par une simple rotation obtiennent ainsi un score de similarité maximal, ce qui est cohérent avec l'intuition que seule la structure relative importe, non la position absolue des vecteurs.

Cette approche présente une faiblesse : une transformation trop permissive peut masquer une perte d'information. Par exemple, un réseau qui ignore totalement l'une des deux dimensions d'entrée (en renvoyant systématiquement 0 pour cette dimension) peut malgré tout obtenir un score de similarité parfait avec un réseau qui, lui, conserve cette information — la relation « garder Y, envoyer X vers 0 » étant elle-même une transformation linéaire valide. Des correctifs existent : exiger une matrice de transformation inversible, symétriser la mesure en régressant dans les deux sens, ou autoriser une régression non linéaire (par exemple un petit réseau) pour tolérer un écart plus large entre les deux représentations.

Métriques par alignement de noyaux (kernel alignment) et CKA

Plutôt que de comparer les coordonnées, cette famille de métriques compare les relations de proximité entre les objets représentés : la matrice de distances (ou de similarités) entre toutes les paires d'exemples, appelée noyau (kernel). Deux représentations peuvent ainsi être jugées équivalentes même si leurs dimensions numériques diffèrent — un embedding de dimension 128 peut être comparé à un embedding de dimension 2048, car seules les distances entre exemples sont mises en correspondance.

Le CKA (Centered Kernel Alignment) est la métrique la plus utilisée de cette famille. Le terme « centré » indique que la moyenne des données est retirée avant comparaison, à la manière du centrage préalable au calcul d'une corrélation en statistiques. Le CKA considère comme équivalentes deux représentations reliées par une rotation, une translation, une symétrie ou un changement d'échelle — ces transformations, appelées isométries lorsqu'elles préservent les distances, sont traitées comme des détails techniques sans importance (nuisances).

Métriques par plus proches voisins (MKNN)

Plutôt que de comparer des distances exactes, ces métriques vérifient uniquement si les deux réseaux s'accordent sur l'identité des voisins les plus proches de chaque point (une mesure de nature ordinale plutôt que continue). Le Mutual k-Nearest Neighbors (MKNN) calcule, pour chaque point, la proportion de voisins communs entre les deux représentations.

Métrique	**Principe**	**Avantage**	**Limite**
Régression	Peut-on prédire les embeddings d'un réseau à partir de l'autre ?	Simple, intuitive	Peut masquer une perte d'information si la transformation autorisée est trop permissive
Kernel / CKA	Les deux réseaux préservent-ils les mêmes relations de proximité ?	Fonctionne même à dimensions différentes ; robuste aux rotations et changements d'échelle	Peut artificiellement augmenter avec la seule taille du modèle
MKNN	Les deux réseaux s'accordent-ils sur les plus proches voisins ?	Mesure locale, robuste, de nature ordinale	Ne renseigne pas sur la structure globale de l'espace

Au-delà de ces trois familles, l'intervenant a évoqué des approches fondées sur l'information mutuelle (deux représentations véhiculent-elles la même information, au sens formel du terme ?) et sur la cohérence cyclique (cycle consistency), qui teste l'existence d'une fonction bijective reliant les deux espaces, sans contrainte de linéarité. Interrogé sur sa préférence, l'intervenant a indiqué privilégier les métriques de type noyau, en avançant que deux représentations mesurant les distances de la même façon se comportent de manière équivalente pour la plupart des usages pratiques (recherche des plus proches voisins, régression

linéaire, régime des noyaux tangents neuronaux), même si cette position reste, de son propre aveu, un point de vue théorique et non une conclusion démontrée dans l'absolu.

B.3 — Hypothèse platonicienne : compléments (complément du chapitre 9)

Une démonstration interactive proposée au public a consisté à comparer un jugement de similarité visuelle humain à celui d'un modèle de vision (DINO) : face à trois images, l'assistance devait indiquer laquelle des deux images latérales était la plus proche de l'image centrale. Le consensus du public a coïncidé avec le jugement du modèle, illustrant que les réseaux de neurones et les humains semblent souvent mesurer la similarité visuelle de façon comparable.

L'alignement entre modèles de vision et modèles de langage, mesuré par MKNN, s'est renforcé au fil des générations de modèles jusque vers 2024 environ ; au-delà, la tendance devient plus difficile à étudier car les modèles de langage open source ont cessé de progresser significativement en perplexité de prédiction du mot suivant, la recherche s'étant réorientée vers le post-entraînement (raisonnement, code, mathématiques) plutôt que vers l'amélioration des représentations de base.

Interrogé sur une possible baisse récente d'alignement entre modèles récents, l'intervenant a avancé trois explications possibles : l'incertitude des résultats sur l'alignement avec le cerveau biologique (domaine jugé encore mal stabilisé) ; l'effet du post-entraînement, qui modifierait la nature des embeddings extraits des modèles de langage actuels par rapport aux modèles simplement pré-entraînés ; et, de façon plus spéculative, l'effet de contenus synthétiques générés par IA sur le web, jugé possible mais peu probable comme explication principale à ce stade.

Concernant l'alignement entre langues humaines, l'intervenant a indiqué que la similarité géométrique entre langues (par exemple entre l'anglais et le français) est nettement plus forte que celle observée entre modalités (vision et langage). Si certains concepts culturellement spécifiques ne se traduisent pas parfaitement d'une langue à l'autre, la plupart des concepts courants (pomme, personne, amour, haine…) existent dans l'ensemble des langues, ce qui explique un socle géométrique largement partagé.

Un point de nuance a également été apporté par des travaux tiers cités en séance : la convergence observée serait avant tout locale et de nature ordinale (préservation de l'ordre relatif des distances) plutôt qu'une convergence stricte vers une même géométrie globale ; le CKA global montre une tendance beaucoup plus faible que le MKNN local, ce qui a pu conduire certains commentateurs à conclure, de façon excessive, à une absence totale de convergence structurelle entre modèles.

B.4 — Applications et échanges avec le public (complément du chapitre 10)

Des résultats théoriques, et non seulement empiriques, viennent étayer certaines de ces observations pour des familles de modèles spécifiques : pour l'apprentissage contrastif de type InfoNCE, il peut être démontré que le noyau appris converge vers une fonction liée à l'information mutuelle ponctuelle (pointwise mutual information) ; pour des modèles de type CLIP entraînés indépendamment, il peut être démontré que leurs embeddings convergent vers une correspondance reliée par une même transformation orthogonale, appliquée de façon identique aux embeddings visuels et textuels.

Sur le plan applicatif, l'alignement des représentations permet notamment : de connecter des modèles de modalités différentes par une simple couche de raccordement (stitching layer) plutôt que par un

réentraînement complet ; de transférer un apprentissage d'un modèle à un autre ; de partager de la supervision entre modalités ; et de servir de fondation à de nouveaux modèles par affinage (fine-tuning).

L'intervenant a néanmoins souligné un risque potentiel : une convergence excessive entre modèles pourrait réduire la diversité des façons de raisonner, un phénomène rapproché du « mode collapse », où l'ensemble des systèmes d'IA finiraient par partager une seule et même façon de représenter le monde.

Deux questions du public sont restées partiellement ou totalement sans réponse dans la transcription disponible : l'une portant sur l'extension de cette hypothèse aux world models (modèles du monde), à laquelle l'intervenant a répondu que la question restait largement ouverte mais plausible au regard du débat actuel sur la nature de modèle du monde des grands modèles de langage ; l'autre, posée en toute fin de séance, portant sur les architectures multimodales sans encodeur de vision séparé (de type Gemma), pour laquelle la transcription s'interrompt avant que l'intervenant n'ait pu répondre, la session s'étant achevée sur une pause déjeuner.

JOUR 2

Apprentissage par renforcement, estimation statistique apprise et atelier pratique

28 juillet 2026

Intervenants et thèmes principaux :
Introduction au Reinforcement Learning
Kyunghyun Cho — Statistics Upside Down
Miruna Pislar — Atelier pratique RL

Avant-propos

Ce document restitue, dans un format pédagogique et objectif, la deuxième journée de l'Eastern European Machine Learning Summer School (EEML) 2026, suivie à distance. Comme pour la journée précédente, il ne s'agit pas d'une transcription du direct, mais d'une réorganisation thématique du contenu, reformulée dans un registre académique neutre.

La journée a comporté trois temps distincts. Le premier a introduit l'apprentissage par renforcement (Reinforcement Learning, RL), depuis ses fondements formels jusqu'à ses usages les plus récents dans l'entraînement des grands modèles de langage. Le second, présenté par le chercheur Kyunghyun Cho sous le titre « Statistics Upside Down », a proposé une réflexion sur l'apprentissage automatique d'estimateurs statistiques, en remplacement de leur dérivation analytique traditionnelle. Le troisième temps était un atelier pratique animé par Miruna Pislar (Google DeepMind) et son collègue Seba, consacré à l'implémentation progressive d'un agent RL, de l'algorithme REINFORCE jusqu'aux bases de PPO et GRPO.

Comme pour le document de la journée 1, le corps du texte présente une synthèse concise de chaque chapitre, tandis que les développements plus détaillés sont regroupés en annexe, avec renvoi explicite depuis chaque chapitre.

Partie I — Introduction à l'apprentissage par renforcement

Cette première intervention de la journée a été assurée par un chercheur d'Isomorphic Labs, spécialisé dans la découverte de molécules thérapeutiques, et désigné plus tard dans la journée sous le prénom d'Andreas par une autre intervenante. Ce prénom est repris ci-après par commodité, faute d'une identification plus complète dans les notes disponibles.

Chapitre 1. Qu'est-ce que le RL ? Cadre général et applications

L'apprentissage par renforcement (Reinforcement Learning, RL) est présenté comme un changement de perspective par rapport à l'apprentissage supervisé : au lieu d'apprendre une fonction entre des entrées et des sorties connues, un agent apprend un comportement en interagissant avec un environnement, selon une boucle état → action → récompense.

Applications évoquées en introduction

- Les systèmes de recommandation par bandits (Spotify, Amazon, recommandation d'actualités), présentés comme l'application du RL la plus discrète mais la plus rentable.
- AlphaZero, capable d'atteindre un niveau de jeu supérieur dans plusieurs jeux de plateau, notamment le Go, où certains de ses coups ont surpris les experts humains.
- Le contrôle de champs de fusion nucléaire superchauffés, où le RL est utilisé pour stabiliser le plasma.
- L'apprentissage par renforcement à partir de retours humains (RLHF) et ses variantes plus récentes, aujourd'hui présents dans la plupart des grands modèles de langage utilisés chaque semaine par plus d'un milliard de personnes.

Détails et comparaison terme à terme entre apprentissage supervisé et RL : voir Annexe A.1.

Chapitre 2. Formaliser le problème : le processus de décision markovien

Le problème du RL est formalisé par un processus de décision markovien (Markov Decision Process, MDP), défini par cinq éléments : un ensemble d'états S, un ensemble d'actions A, une fonction de transition, une fonction de récompense, et un facteur d'actualisation γ (gamma).

Idées clés

- La propriété markovienne suppose que le futur ne dépend que de l'état présent, et non de l'historique complet (système « sans mémoire »). En pratique, les agents contournent souvent cette contrainte en empilant plusieurs états successifs pour simuler une forme de mémoire.
- L'agent cherche une politique — un comportement — qui maximise le retour, c'est-à-dire la somme des récompenses obtenues le long d'une trajectoire complète, et non la seule récompense immédiate.
- Le facteur d'actualisation γ détermine l'importance relative des récompenses futures par rapport aux récompenses immédiates.

Détails et exemple du monde en grille (banane, pièce, états terminaux) illustrant le rôle du facteur d'actualisation : voir Annexe A.2.

Chapitre 3. Bandits multi-bras et dilemme exploration/exploitation

Les bandits multi-bras (multi-armed bandits) constituent la version la plus simple du RL : un agent doit répartir ses essais entre plusieurs options (par analogie, plusieurs machines à sous) afin d'identifier celle qui rapporte le plus, sans notion d'état ni de transition.

Idées clés

- L'exploration consiste à essayer de nouvelles actions pour recueillir de l'information sur leur valeur.
- L'exploitation consiste à utiliser les actions déjà connues pour être les plus profitables.
- L'équilibre entre exploration et exploitation constitue l'un des problèmes fondamentaux de tout algorithme de RL : trop d'exploitation prématurée risque de figer l'agent sur une solution sous-optimale ; trop d'exploration retarde l'obtention de bons résultats.

Chapitre 4. Apprendre une politique : Policy Gradient et fonctions de valeur

Une première famille d'approches consiste à paramétrer directement la politique — typiquement par un réseau de neurones — et à optimiser ses paramètres par descente de gradient, de manière à maximiser la récompense attendue. C'est le principe du Policy Gradient.

Limite et notions complémentaires

- Dans sa forme la plus simple, le Policy Gradient attribue la même récompense à l'ensemble d'une trajectoire : le modèle ne sait donc pas distinguer précisément quelles actions ont réellement contribué au succès ou à l'échec (problème d'attribution du crédit).
- La fonction de valeur (Value Function) estime la qualité d'un état donné.
- La Q-valeur (Q-value) estime la qualité d'un couple état-action, ce qui permet ensuite de choisir l'action optimale dans chaque état.

Détails sur le calcul du retour et le rôle du gradient dans l'apprentissage de la politique : voir Annexe A.3.

Chapitre 5. Estimer les valeurs : programmation dynamique, Monte Carlo, différence temporelle

Trois grandes méthodes permettent d'estimer les fonctions de valeur d'un environnement.

Méthode	Principe	Caractéristiques
Programmation dynamique	Suppose une connaissance parfaite de l'environnement (transitions et récompenses)	Très efficace, mais rarement applicable en pratique
Monte Carlo	Attend la fin de l'épisode et utilise le retour réellement observé	Faible biais, variance élevée
Différence temporelle (TD)	Met à jour l'estimation immédiatement, sans attendre la fin de l'épisode	Variance plus faible, biais plus élevé ; fondement de nombreux algorithmes modernes

Chapitre 6. Familles d'algorithmes modernes : DQN, Actor-Critic, PPO

Model-free vs. model-based

- Les approches model-free (sans modèle) apprennent directement à agir, sans modéliser le fonctionnement de l'environnement. Exemples cités : PPO, DQN, SAC.
- Les approches model-based (avec modèle) apprennent en plus un modèle de l'environnement, capable de prédire le prochain état et la récompense associée, ce qui permet la planification et la simulation. Exemples cités : Dreamer, MuZero. Avantage : meilleure efficacité d'apprentissage. Inconvénient : si le modèle appris est erroné, les prédictions et décisions qui en découlent se dégradent.

On-policy vs. off-policy

- Les méthodes on-policy apprennent uniquement à partir des actions réellement exécutées par la politique courante (exemple : PPO).
- Les méthodes off-policy peuvent apprendre à partir d'expériences passées, même générées par une politique différente (exemples : Q-learning, DQN).

Trois architectures clés

- DQN (Deep Q-Network) : combine un réseau estimant les Q-valeurs, un mécanisme de rejeu d'expérience (Experience Replay) et un réseau cible (Target Network) ; ces ingrédients ont permis aux agents de DeepMind de dominer un large ensemble de jeux Atari.
- Actor-Critic : combine deux réseaux — l'Actor, qui choisit les actions, et le Critic, qui évalue leur qualité — ce dernier accélérant significativement l'apprentissage de l'Actor.
- Un bonus d'entropie est souvent ajouté à l'objectif d'entraînement pour encourager l'exploration : une politique très déterministe a une faible entropie, une politique très aléatoire une entropie élevée ; l'entropie est généralement élevée en début d'apprentissage puis réduite progressivement.

PPO (Proximal Policy Optimization) est présenté comme l'un des algorithmes les plus utilisés aujourd'hui : son principe est d'empêcher la politique de changer trop brutalement d'une mise à jour à l'autre, en limitant (« clipping ») l'amplitude des mises à jour, ce qui stabilise l'entraînement. C'est notamment cet algorithme qui a popularisé l'usage du RL pour l'entraînement des grands modèles de langage.

Chapitre 7. Le RL au service des grands modèles de langage

La dernière partie de cette intervention relie les concepts précédents à l'entraînement des grands modèles de langage (LLM).

Idées clés

- L'approche historique est le RLHF (Reinforcement Learning from Human Feedback) : des évaluateurs humains notent les réponses du modèle, et ces notes servent de signal de récompense.
- Une approche plus récente repose sur des récompenses vérifiables : tests automatiques de code, vérification de résultats mathématiques, réponses objectivement correctes — moins coûteuses, plus facilement mises à l'échelle et moins sensibles aux biais humains que le RLHF classique.
- DeepSeek R1 est cité comme illustration récente de cette approche : entraînement fondé sur des récompenses objectives, supervision humaine finale réduite, et émergence spontanée de comportements de raisonnement et d'auto-correction (décrits comme des « aha moments »).
- GRPO (Group Relative Policy Optimization) est présenté comme une évolution qui se passe du réseau Critic : plutôt que d'entraîner un réseau de valeur séparé, plusieurs réponses sont générées pour un même prompt, comparées entre elles, et leurs scores normalisés servent de signal d'apprentissage — ce qui réduit la mémoire nécessaire et accélère l'entraînement.
- L'intervenant a également évoqué la génération automatique d'environnements interactifs à partir d'un simple prompt textuel (par exemple un monde 3D), ouvrant de nouvelles perspectives pour l'entraînement d'agents RL.

Partie II — Statistics Upside Down : apprendre les estimateurs statistiques

Cette seconde intervention, assurée par le chercheur Kyunghyun Cho, change radicalement de sujet : elle porte sur une méthode alternative de conception d'estimateurs statistiques, fondée sur l'apprentissage automatique plutôt que sur la dérivation analytique.

Chapitre 8. Le biais caché de l'écart-type échantillonné

L'intervenant part d'une observation volontairement provocatrice : l'écart-type calculé sur un échantillon n'est pas un estimateur non biaisé de l'écart-type de la population, même après la correction de Bessel appliquée à la variance.

Idées clés

- La variance d'échantillon peut être corrigée pour devenir un estimateur non biaisé de la variance de la population (correction de Bessel, division par $n - 1$ plutôt que par n).
- L'écart-type, étant la racine carrée de la variance, reste néanmoins biaisé, car la racine carrée est une fonction non linéaire : en général, l'espérance d'une racine carrée n'est pas égale à la racine carrée de l'espérance.
- En conséquence, l'écart-type échantillonné a tendance à sous-estimer systématiquement l'écart-type réel de la population.
- Ce constat motive une question de recherche : est-il possible de construire un meilleur estimateur, qui minimise à la fois le biais et la variance ?

Détails et rappel du compromis biais-variance (décomposition du MSE) : voir Annexe B.1.

Chapitre 9. Apprendre un estimateur : le Set Transformer++

Plutôt que de chercher analytiquement une meilleure formule, l'intervenant et son collaborateur Maxim proposent de reformuler le problème comme une tâche d'apprentissage supervisé standard : entraîner un réseau de neurones à prédire directement l'écart-type réel d'une population à partir d'un échantillon.

Méthode et résultats

- Génération des données d'entraînement : on choisit aléatoirement une distribution (par exemple un mélange de deux lois normales) dont l'écart-type réel est connu exactement, on en tire un échantillon, puis on entraîne le réseau à minimiser l'erreur quadratique moyenne (MSE) entre sa prédiction et la valeur réelle.
- Choix architectural : les données d'entrée forment un ensemble (set) et non une séquence ordonnée ; le modèle doit donc être invariant par permutation. Les auteurs utilisent un Set Transformer++, une architecture conçue pour ce type de données.
- Évaluation : le modèle, entraîné sur des mélanges de gaussiennes, est testé sur des distributions jamais vues en entraînement (log-normales, à queues épaisses).
- Résultat : le Set Transformer++ obtient un estimateur presque non biaisé et de variance plus faible que les estimateurs classiques (écart-type avec ou sans correction de Bessel), en particulier sur des distributions proches de celles vues à l'entraînement ; les performances se dégradent, comme attendu, à mesure que l'on s'éloigne de cette distribution d'entraînement.

Chapitre 10. Généraliser l'idée : estimer l'information mutuelle avec MIST

La même philosophie est ensuite appliquée à un problème nettement plus difficile : l'estimation de l'information mutuelle entre deux variables aléatoires, une mesure de la quantité d'information partagée entre elles (par exemple entre une image et sa légende), réputée difficile à estimer lorsque les distributions sont complexes.

Méthode et résultats

- Génération des données d'entraînement : à partir d'une procédure proposée par Grabowski et al. (2023), on part de distributions bivariées normales dont l'information mutuelle exacte est calculable, puis on leur applique des transformations non linéaires mais inversibles (normalizing flows), ce qui permet de générer des échantillons complexes tout en connaissant exactement leur information mutuelle réelle.
- Un unique réseau, fondé sur des mécanismes d'attention, est entraîné sur un grand nombre de ces problèmes synthétiques (tailles d'échantillon de 10 à 500, dimensions de 2 à 32, information mutuelle variant de 0 à 40 nats), pour produire un modèle baptisé MIST (Mutual Information by Supervised Training).
- Comparé aux estimateurs classiques (CCA, KSG, InfoNCE, InfoNet), MIST obtient un biais et une variance plus faibles, avec un avantage particulièrement marqué lorsque la dimensionnalité augmente : contrairement aux méthodes fondées sur l'estimation de densité (comme KSG), dont les besoins en échantillons croissent rapidement avec la dimension (malédiction de la dimensionnalité), les besoins de MIST restent globalement stables.
- Le modèle est également entraîné par régression quantile (quantile regression, via une fonction de perte dite pinball loss), ce qui lui permet de produire, en plus d'une estimation ponctuelle, un intervalle d'incertitude bien calibré — un avantage obtenu à faible coût supplémentaire par rapport à des méthodes de calibration a posteriori telles que le bootstrap.

Détails sur la calibration de l'incertitude et les limites de généralisation hors du domaine d'entraînement : voir Annexe B.2.

Chapitre 11. Portée, limites et message philosophique

L'intervenant résume sa démarche par une formule : « Statistics Upside Down » — au lieu de partir d'une question (« quelle est la bonne formule ? »), il propose de partir d'un problème d'apprentissage automatique (« comment apprendre automatiquement la meilleure formule ? »).

Idées clés

- Cette approche ne remet pas en cause les fondements de la statistique classique ; elle propose une alternative pratique lorsque la puissance de calcul et les données simulées sont disponibles en abondance.
- Elle nécessite de définir un prior (une distribution sur l'espace des problèmes possibles) : les auteurs assument ce choix en le comparant aux hypothèses tout aussi fortes, mais souvent implicites et non vérifiables, sur lesquelles reposent les estimateurs analytiques classiques.
- Les estimateurs ainsi appris ne sont fiables qu'à proximité de leur distribution d'entraînement ; leur qualité se dégrade lorsqu'on s'en éloigne fortement.
- Cette démarche brouille la frontière entre statistique classique et apprentissage profond, en traitant la conception d'un estimateur comme un problème d'optimisation résolu par descente de gradient plutôt que par démonstration mathématique.

Partie III — Atelier pratique : construire un agent RL

Le troisième temps de la journée était un atelier pratique animé par Miruna Pislar, ingénieure de recherche chez Google DeepMind, accompagnée de son collègue Seba et d'une équipe d'assistants (TAs).

Chapitre 12. Objectifs du tutoriel et environnement CliffWalking

Objectifs annoncés

- Implémenter l'algorithme REINFORCE (Policy Gradient) à partir de zéro.
- Comprendre par la pratique les principes de PPO puis de GRPO.
- Appliquer ces algorithmes au fine-tuning d'un petit modèle de langage (Qwen, 500 millions de paramètres).

L'animatrice insiste sur l'idée que la compréhension du RL passe par sa mise en pratique, et encourage les participants à solliciter les assistants présents plutôt qu'à dépendre exclusivement des assistants LLM.

L'environnement CliffWalking

- Une grille de 4 lignes sur 12 colonnes, où l'agent (représenté par un elfe) doit se déplacer d'un point de départ (une chaise) vers un objectif (un cookie), en évitant une falaise représentée par une rangée de cases.
- Quatre actions possibles, codées par des entiers : 0 = haut, 1 = droite, 2 = bas, 3 = gauche.
- Un état correspond à la position de l'agent dans la grille (ligne, colonne), convertie en un entier unique.
- Récompenses : −1 pour un déplacement normal, −100 en cas de chute dans la falaise (l'épisode se termine alors), 0 lorsque l'agent atteint l'objectif.
- La politique constitue le « cerveau » de l'agent : une fonction qui associe à chaque état une distribution de probabilité sur les actions possibles ; au début de l'entraînement, cette distribution est presque uniforme (comportement quasi aléatoire), puis elle se concentre progressivement sur les meilleures actions.
- Le retour total maximal atteignable dans cet environnement est de −13 (un déplacement vers le haut, puis douze déplacements vers la droite, le dernier pas rapportant une récompense nulle) : un score négatif mais optimal, puisqu'il minimise la pénalité cumulée.

Chapitre 13. De REINFORCE vers PPO, GRPO et le fine-tuning d'un LLM

Le tutoriel est structuré en deux parties progressives.

Partie 1 — Construire un agent RL « from scratch »

- Représentation des états de l'environnement CliffWalking.
- Définition d'une politique sous la forme d'un petit réseau de neurones.
- Interaction avec l'environnement : à chaque étape, l'état courant est fourni à la politique, qui choisit une action ; l'environnement renvoie alors un nouvel état et une récompense.
- Collecte de trajectoires complètes et calcul du retour associé.
- Mise à jour des paramètres de la politique par Policy Gradient (algorithme REINFORCE).

Partie 2 — Vers le fine-tuning d'un modèle de langage

- Cette seconde partie s'appuie sur les bases posées en partie 1 pour introduire PPO, GRPO, le RLHF et, plus largement, le post-entraînement des grands modèles de langage.
- Contrairement à l'environnement CliffWalking, l'entraînement d'un LLM ne dispose pas d'un environnement fournissant directement une récompense ; celle-ci doit être définie ou apprise séparément (juge humain, modèle de récompense, ou critère vérifiable selon les approches vues en partie I).

Cette progression pédagogique — d'un environnement de grille simple jusqu'au fine-tuning d'un modèle de langage — relie directement les notions théoriques présentées le matin (Policy Gradient, PPO, GRPO, RLHF) à une implémentation concrète, dans la continuité des chapitres 4 à 7.

Conclusion générale

Bien que couvrant des sujets en apparence distincts, les trois temps de cette deuxième journée partagent un même fil conducteur : la question de savoir dans quelle mesure certaines démarches, traditionnellement conçues « à la main » par des experts, peuvent être remplacées ou complétées par un processus d'apprentissage automatique.

Fils conducteurs de la journée

- En apprentissage par renforcement, l'agent découvre lui-même, par essais-erreurs, un comportement optimal, sans qu'on lui indique explicitement la bonne action à chaque étape.
- Dans l'exposé « Statistics Upside Down », des estimateurs statistiques eux-mêmes sont appris par un réseau de neurones plutôt que dérivés analytiquement, avec des gains mesurables de biais et de variance sur les cas étudiés.
- L'atelier pratique a permis de relier ces principes théoriques à une implémentation concrète, de l'algorithme REINFORCE jusqu'aux briques nécessaires au fine-tuning d'un grand modèle de langage par renforcement.
- Le fil qui relie ces trois interventions rejoint également, de façon plus large, le thème de la première journée : dans les deux cas, il s'agit de remplacer une construction manuelle (caractéristiques, formules statistiques) par un objectif d'optimisation appris directement à partir des données.

Ce document restitue les notions abordées dans un cadre pédagogique et objectif ; certains échanges avec le public, notamment en fin de tutoriel, n'ont pu être que partiellement restitués dans les notes disponibles.

Annexe — Approfondissements par chapitre

Cette annexe reprend, chapitre par chapitre, les développements, exemples et éléments chiffrés qui étayent les synthèses présentées dans le corps du document.

A.1 — Apprentissage supervisé et RL (complément du chapitre 1)

Aspect	Apprentissage supervisé	Apprentissage par renforcement
Nature des données	Paires (X, Y) fournies à l'avance	Générées par l'agent lui-même, au fil de ses interactions avec l'environnement
Signal d'apprentissage	Étiquette correcte connue (Y)	Récompense, souvent conçue par un humain, sans notion de « réponse correcte » unique
Nature du signal	Immédiat (associé à chaque exemple)	Parfois différé de plusieurs étapes
Objectif	Apprendre une fonction de X vers Y	Apprendre un comportement (politique) qui maximise le retour à long terme

A.2 — Le processus de décision markovien : exemple illustratif (complément du chapitre 2)

L'exemple du monde en grille présenté en séance comporte un état gagnant valant +100, deux états terminaux de pénalité (−100 chacun), une case « banane » valant −1, et une case « pièce » valant +1. Plusieurs chemins permettent d'atteindre l'état gagnant : un chemin passant par la banane obtient un retour total de 99 (100 − 1) si l'on additionne simplement les récompenses ; un chemin passant par la pièce ou un chemin direct obtiennent chacun un retour de 100.

C'est à ce stade qu'intervient le facteur d'actualisation γ : selon sa valeur, l'algorithme accorde plus ou moins d'importance à des récompenses obtenues rapidement plutôt que tardivement. Un γ proche de 0 privilégie fortement les récompenses immédiates ; un γ proche de 1 accorde presque autant de poids aux récompenses lointaines qu'aux récompenses immédiates. Ce mécanisme permet notamment de départager deux trajectoires de même retour total, mais de longueurs différentes, en favorisant la plus courte.

A.3 — Policy Gradient : le calcul du retour (complément du chapitre 4)

Une politique donne, à chaque pas de temps, une décision locale (quelle action prendre dans l'état courant), mais l'objectif de l'agent porte sur l'ensemble de la trajectoire : c'est la somme actualisée des récompenses futures, le retour, que l'on cherche à maximiser plutôt qu'une récompense isolée. Le Policy Gradient ajuste directement les paramètres du réseau représentant la politique dans la direction qui augmente l'espérance de ce retour.

La limite mentionnée en séance — l'ensemble d'une trajectoire recevant la même récompense — signifie que, dans sa version la plus simple, l'algorithme ne distingue pas les actions réellement décisives des actions neutres ou légèrement négatives au sein d'une trajectoire globalement réussie. Cette difficulté, dite d'attribution du crédit (credit assignment), motive en partie l'introduction des fonctions de valeur et des architectures Actor-Critic présentées au chapitre 6.

B.1 — Le compromis biais-variance (complément du chapitre 8)

Un bon estimateur doit conjuguer un faible biais (l'espérance de l'estimateur doit être proche de la vraie valeur) et une faible variance (l'estimateur doit rester stable d'un échantillon à l'autre). Ces deux exigences sont résumées par la décomposition classique de l'erreur quadratique moyenne :

$MSE = Biais^2 + Variance$

Rechercher un bon estimateur revient donc à minimiser conjointement le carré du biais et la variance, c'est-à-dire à minimiser l'erreur quadratique moyenne. L'écart-type échantillonné présente un biais non négligeable (généralement une sous-estimation) mais une variance relativement faible ; la question posée par l'intervenant est de savoir si un estimateur appris peut améliorer ce compromis dans son ensemble, plutôt que d'échanger un défaut contre un autre.

B.2 — MIST : calibration et limites (complément du chapitre 10)

Au-delà de l'estimation ponctuelle de l'information mutuelle, le modèle MIST est entraîné par régression quantile simultanée (prédiction du 10e, du 50e, du 90e percentile, etc., à l'aide d'une fonction de perte dite pinball loss), ce qui lui permet de produire une estimation accompagnée d'un intervalle d'incertitude, par exemple « information mutuelle = 2,5, avec un intervalle de confiance associé », plutôt qu'une seule valeur ponctuelle.

Sur le plan de la calibration, les courbes présentées en séance montrent qu'un modèle entraîné uniquement à minimiser l'erreur quadratique moyenne, puis recalibré a posteriori par une méthode de rééchantillonnage (bootstrap), reste bien calibré sur les valeurs faibles mais se dégrade sur les valeurs plus élevées ; le modèle entraîné directement par régression quantile obtient, lui, une calibration presque parfaite, avec un coût de mise en œuvre supplémentaire minime.

Les limites reconnues par l'intervenant sont les suivantes : la performance du modèle dépend du prior choisi sur l'espace des problèmes (la famille de distributions utilisée pour générer les données d'entraînement) et se dégrade à mesure que les distributions rencontrées en test s'éloignent de ce prior ; de plus, le modèle a tendance à sous-estimer l'information mutuelle dans les cas extrêmes, en raison de la plage dynamique finie du réseau de neurones utilisé. L'intervenant relativise néanmoins cette limite en notant que les estimateurs classiques reposent eux aussi sur des hypothèses fortes concernant la distribution sous-jacente, rarement vérifiables en pratique — la question n'étant donc pas d'éviter toute hypothèse, mais de choisir consciemment celles que l'on formule.

JOUR 3

Contexte long dans les modèles de langage, capital-risque et apprentissage continu

29 juillet 2026

Intervenants et thèmes principaux :

Federico Barbara — Contexte long et RoPE

Máté Mitk — Capital-risque pour fondateurs

Claire Lyle & Razvan Pascanu — Apprentissage continu

Avant-propos

Ce document restitue, dans un format pédagogique et objectif, la troisième journée de l'Eastern European Machine Learning Summer School (EEML) 2026, suivie à distance. Comme pour les journées précédentes, il ne s'agit pas d'une transcription du direct, mais d'une réorganisation thématique du contenu, reformulée dans un registre académique neutre.

La matinée a débuté par une brève présentation d'un sponsor local (l'entreprise monténégrine Coinis, spécialisée dans la génération publicitaire par IA), non reprise ici car de nature commerciale et sans lien direct avec le contenu pédagogique de l'école. La journée a ensuite comporté trois interventions principales : un exposé du chercheur Federico Barbara (Google DeepMind) sur la propagation de l'information dans les modèles de langage à contexte long ; une présentation de Máté Mitk (Credo Ventures) sur les fondements du capital-risque à destination de futurs fondateurs de startups ; puis deux interventions complémentaires sur l'apprentissage continu, la première par Claire Lyle et la seconde par un chercheur de Google DeepMind désigné dans la transcription sous le prénom de Razvan.

Une précision est nécessaire concernant la source de ce document : les notes fournies se terminaient par un long passage traitant du Reinforcement Learning et des estimateurs statistiques appris — un contenu qui correspond en réalité à la journée précédente et non à cette troisième journée. Ce passage n'a donc pas été repris ici, conformément au contenu effectivement observé dans la transcription de la journée 3. Par ailleurs, la transcription disponible ne couvre pas la fin de journée (une plage d'environ trois heures, correspondant vraisemblablement à des sessions en petits groupes, des posters ou un événement social, n'a pas été enregistrée dans les notes fournies) ; ce document se limite donc aux interventions effectivement transcrites.

Comme pour les documents précédents, le corps du texte présente une synthèse concise de chaque chapitre, tandis que les développements plus techniques sont regroupés en annexe, avec renvoi explicite depuis chaque chapitre.

Partie I — Propagation de l'information dans les modèles de langage à contexte long

Cette intervention a été assurée par Federico Barbara, chercheur chez Google DeepMind, dont les travaux ont notamment contribué à l'architecture du modèle Gemma 4.

Chapitre 1. Le problème du contexte long : entraîner court, généraliser long

Un modèle de langage prédit, à chaque position, une probabilité conditionnelle sur le prochain jeton (token) étant donné un contexte de longueur k. L'entraînement se fait nécessairement sur des séquences d'une longueur maximale fixe, mais l'objectif est que le modèle continue de fonctionner correctement sur des contextes beaucoup plus longs que ceux vus à l'entraînement.

Idées clés

- L'entraînement sur de longues séquences est coûteux (mémoire nécessaire pour les gradients et l'optimiseur), ce qui pousse à entraîner sur des contextes courts tout en espérant une bonne généralisation à des contextes longs — un problème de généralisation à part entière.

- L'attention dans les modèles de langage est causale (ou autorégressive) : chaque position ne peut porter son attention que sur les positions qui la précèdent, au moyen d'un masque triangulaire, afin d'éviter que le modèle ne « triche » en observant le jeton qu'il doit précisément prédire.
- La génération de texte procède par échantillonnage successif (autorégression) plutôt que par modélisation conjointe de toute la séquence : cette simplification, bien que coûtant en principe de l'expressivité, fonctionne étonnamment bien en pratique.

Détails et formalisation du masque causal via la fonction softmax : voir Annexe A.1.

Chapitre 2. Défaillances mécaniques : comptage, copie et effondrement de représentation

L'intervenant illustre, à partir d'exemples simples, des défaillances caractéristiques des modèles de langage sur des tâches en apparence triviales, et propose une explication mécanique à ces échecs plutôt qu'une explication liée au seul choix du tokenizer.

Idées clés

- Sur une tâche de comptage (additionner des « 1 » successifs), la précision du modèle se dégrade et finit par converger vers une prédiction constante (par exemple toujours « 100 »), quelle que soit la vraie somme, à mesure que la séquence s'allonge.
- Ce phénomène est relié à un effondrement de représentation (representation collapse) : lorsque le contexte s'allonge, les représentations internes associées à des séquences qui ne diffèrent que par un seul jeton supplémentaire deviennent quasiment identiques, ce qui empêche le modèle de distinguer ces séquences lors de l'échantillonnage — un problème aggravé par l'usage de calculs en précision numérique réduite.
- Sur une tâche de copie (reproduire un jeton donné plus tôt dans la séquence), la difficulté dépend fortement de la position du jeton à copier : contrairement à l'intuition, copier le tout dernier jeton s'avère plus difficile que copier un jeton situé au tout début de la séquence.
- Cette asymétrie s'explique par la structure du mécanisme d'attention causale : le nombre de chemins d'information reliant un jeton donné au dernier jeton de la séquence croît de façon très déséquilibrée en faveur des jetons situés en début de séquence, ce qui en fait, paradoxalement, les plus « favorisés » du point de vue de la propagation de l'information.

Détails, mesure formelle de la sensibilité (dérivées partielles, théorie spectrale des graphes) et rôle des connexions résiduelles : voir Annexe A.2.

Chapitre 3. Dispersion de l'attention et « attention sinks »

L'intervenant relie ces défaillances à un phénomène plus général de dispersion de l'attention (attention dilution), observable dès qu'une seule tête d'attention doit traiter un nombre croissant d'éléments.

Idées clés

- Mécaniquement, la fonction softmax normalise les coefficients d'attention de sorte que leur somme reste égale à 1 ; à mesure que le nombre d'éléments augmente, chaque coefficient individuel tend donc vers zéro, ce qui dilue l'attention portée à chaque élément.
- Ce phénomène peut se mesurer par l'entropie de la distribution d'attention, qui croît naturellement avec la longueur du contexte.
- Une analogie est proposée avec l'équation de la chaleur : chaque couche d'attention agit comme une étape de diffusion qui mélange progressivement l'information ; répétée sur de nombreuses couches,

cette diffusion tend à uniformiser les représentations, un résultat rattaché à la théorie spectrale des graphes.

- Pour contrer cet effet, les modèles de langage développent spontanément des « attention sinks » (puits d'attention) : certaines têtes d'attention concentrent une grande partie de leur attention sur le tout premier jeton de la séquence — un jeton dépourvu de signification propre —, ce qui revient, en pratique, à neutraliser cette tête (comportement proche d'une simple connexion résiduelle).
- Ce phénomène s'intensifie avec la taille des modèles : sur un grand modèle comportant environ 12 000 têtes d'attention au total, une analyse a montré qu'environ 80 % de ces têtes s'avèrent peu ou pas utiles, ce qui ouvre des perspectives importantes de compression des modèles sans perte notable de performance.

Chapitre 4. Les encodages positionnels rotatifs (RoPE) et leur adaptation dans Gemma 4

La seconde partie de l'exposé porte sur les encodages positionnels, présentés comme l'un des composants les plus déterminants pour la généralisation d'un modèle à des contextes plus longs que ceux vus à l'entraînement.

Idées clés

- L'encodage positionnel le plus utilisé aujourd'hui est le RoPE (Rotary Position Embedding) : il fait tourner, par blocs de deux dimensions, les vecteurs de requête et de clé à des vitesses (fréquences) différentes selon la dimension considérée, de sorte que le produit scalaire d'attention entre deux positions ne dépende que de leur distance relative.
- L'article original justifiait ce choix par une propriété de décroissance du produit scalaire avec la distance, censée reproduire un biais linguistique naturel (l'attention portée aux mots proches). L'intervenant montre cependant que cette propriété de décroissance ne se vérifie pas dans le cas général, mais seulement pour des choix particuliers de vecteurs.
- L'analyse empirique révèle que le modèle utilise préférentiellement les fréquences basses (rotation lente) pour transmettre une information stable sur de longues distances, et les fréquences hautes (rotation rapide) pour une attention très locale.
- Le problème de généralisation au contexte long s'explique alors ainsi : un modèle entraîné avec une fréquence de base donnée, puis testé sur un contexte beaucoup plus long que celui de l'entraînement, voit ses composantes de basse fréquence effectuer plus d'un tour complet de rotation, ce qui casse les motifs d'attention appris à l'entraînement.
- La solution retenue, intégrée dans Gemma 4, consiste à neutraliser (mettre à zéro) les fréquences les plus basses plutôt que de simplement augmenter la base numérique du RoPE comme le faisaient certaines approches antérieures — une correction validée par une analyse mécaniste plutôt que par un réentraînement à grande échelle de modèles géants.

Détails mathématiques sur la matrice de rotation par blocs et la mesure de la norme des fréquences utilisées : voir Annexe A.3.

Partie II — Notions de capital-risque pour futurs fondateurs

Cette intervention a été assurée par Máté Mitk, de Credo Ventures, un fonds de capital-risque investissant depuis 2010 dans des équipes fondatrices ayant au moins un cofondateur originaire d'Europe de l'Est.

Chapitre 5. Pourquoi et comment lever des fonds de capital-risque

Idées clés

- Le capital-risque répond à un problème précis : certaines entreprises ne peuvent pas croître de façon organique et progressive (contrairement à une entreprise familiale) car leur modèle n'atteint son plein potentiel qu'à partir d'une certaine échelle (l'exemple cité est Uber, dont le service n'a de sens qu'avec un grand nombre de chauffeurs déjà présents).
- Toute entreprise financée par capital-risque doit, en théorie, viser une issue exceptionnelle (un « outlier ») : l'ensemble du modèle économique des fonds de capital-risque repose sur un petit nombre de réussites majeures compensant les échecs, plus fréquents, des autres investissements.
- Une alternative existe : l'autofinancement (bootstrapping), qui évite la dilution du capital mais reste statistiquement rare pour atteindre une valorisation d'un milliard de dollars (« licorne ») ou plus.
- Les étapes classiques de levée de fonds progressent par montants et exigences croissants : un tour de pré-amorçage (quelques collaborateurs, un budget limité pour valider une hypothèse), un tour d'amorçage (une fois la technologie validée et les premiers clients pilotes identifiés), puis une série A (généralement conditionnée à un revenu récurrent annuel significatif) et les séries suivantes.

Chapitre 6. Évaluer une opportunité : questions clés et études de cas

L'intervenant propose un ensemble de questions destinées à évaluer si un projet mérite d'être financé par capital-risque, inspirées des sept questions attribuées à l'investisseur Peter Thiel.

Questions clés évoquées

- La solution proposée est-elle nettement meilleure (dans l'idéal, un ordre de grandeur) que ce qui existe déjà sur le marché ?
- Pourquoi maintenant ? Cette question s'examine sous deux angles : pourquoi l'entreprise n'a-t-elle pas pu être créée plus tôt (la technologie ou le marché n'étaient pas encore prêts), et pourquoi n'existe-t-il pas déjà un concurrent équivalent qui réussit (auquel cas il convient de comprendre pourquoi des tentatives antérieures ont échoué) ?
- L'équipe fondatrice est-elle la mieux placée pour résoudre ce problème précis ? Pour des produits à forte composante de recherche, la légitimité technique de l'équipe est un critère déterminant ; pour des produits plus commerciaux, la vitesse d'exécution devient le facteur clé.
- Le marché adressable est-il suffisamment grand ? L'intervenant illustre ce point par un calcul de coin de table (nombre d'utilisateurs potentiels × taux de pénétration réaliste × prix), en insistant sur le fait qu'une modélisation trop sophistiquée est peu utile à un stade précoce : ce qui compte est de démontrer que le problème adressé est suffisamment important.

Études de cas évoquées

- ElevenLabs (technologie de synthèse vocale par IA) : investissement réalisé alors que l'entreprise ne disposait que d'un seul GPU ; la validation reposait sur le caractère nettement plus naturel de la voix produite par rapport aux solutions existantes, et sur la conjonction d'une équipe combinant expertise technique en modèles audio et expérience commerciale.

- Une société de trading algorithmique (issue d'anciens chercheurs en IA appliquée au poker) ayant réorienté une expertise en modélisation de l'incertitude vers les marchés financiers, avec une équipe jugée exceptionnellement dense en talents, bien que la défendabilité à long terme d'un tel positionnement reste, de l'aveu de l'intervenant, difficile à garantir dans un marché aussi concurrentiel.

L'intervenant conclut en rappelant qu'au-delà du produit, la réussite d'une startup dépend aussi de la capacité à comprendre et à convaincre un marché, et que le choix des cofondateurs mérite une attention comparable à celle portée au produit lui-même, étant donné l'engagement de long terme qu'implique cette aventure.

Partie III — Apprentissage continu

Cette dernière partie de la journée a réuni deux interventions complémentaires sur l'apprentissage continu (continual learning) : la première par Claire Lyle (Google DeepMind, docteure d'Oxford), la seconde par un chercheur de Google DeepMind désigné dans la transcription sous le prénom de Razvan, dont le parcours (doctorat avec Yoshua Bengio à Montréal, travaux sur les réseaux récurrents) évoque celui du chercheur Razvan Pascanu, sans que son nom complet soit confirmé explicitement dans les notes disponibles.

Chapitre 7. Pourquoi apprendre en continu ? Motivations et défis fondamentaux

Motivations

- Le monde change, et les connaissances d'un modèle figé à un instant donné se périment (l'exemple donné est celui d'un modèle interrogé sur le monarque du Royaume-Uni, dont la réponse correcte évolue avec le temps).
- De plus en plus de systèmes apprennent de leur propre expérience (agents de RL, robots), ce qui génère naturellement des données dont la distribution change au fil de l'apprentissage — un robot apprenant à nager, par exemple, ne rencontre pas les mêmes situations en début et en fin d'entraînement.

Deux défis fondamentaux

- Se souvenir du passé : un défi documenté depuis les années 1990, qui touche les réseaux de neurones nettement plus que les systèmes humains.
- Conserver la plasticité, c'est-à-dire la capacité du réseau à continuer d'apprendre de nouvelles choses efficacement — une capacité qui, comme la plasticité cérébrale, tend à se dégrader avec l'expérience accumulée si rien n'est fait pour la préserver.

L'intervenante souligne également un défi méthodologique propre au domaine : construire des bancs d'essai (benchmarks) qui capturent une notion utile de non-stationnarité sans pour autant reproduire un environnement trop désordonné pour permettre des expériences contrôlées — d'où le recours fréquent à des séquences de tâches définies artificiellement (par exemple en découpant un grand jeu de données en sous-ensembles de classes présentés successivement).

Chapitre 8. L'oubli catastrophique

L'oubli catastrophique désigne la dégradation des performances d'un réseau sur une tâche déjà apprise, lorsqu'il est ensuite entraîné sur une nouvelle tâche sans qu'on le lui rappelle.

Explication et illustration

- Ce phénomène provient du fonctionnement même de la descente de gradient : à chaque étape, l'ensemble des paramètres du réseau est mis à jour, sans distinction entre les paramètres réellement nécessaires à la nouvelle tâche et ceux qui restent utiles à d'anciennes tâches.
- Une illustration présentée porte sur une version incrémentale du jeu de données MNIST (chiffres manuscrits) : en entraînant un réseau successivement sur les paires de chiffres 0-1, puis 2-3, etc., on observe que les gradients associés à des tâches différentes pointent dans des directions largement opposées, ce qui explique l'interférence entre tâches.
- Une lecture complémentaire, en termes de paysage de perte, montre qu'il n'existe aucune raison, a priori, pour qu'une trajectoire d'optimisation trouvant une bonne solution pour une tâche conduise également à une bonne solution pour une autre tâche non corrélée.

Trois grandes catégories de solutions

- La régularisation : pénaliser les mises à jour de paramètres jugés importants pour les tâches précédentes (en s'appuyant, par exemple, sur une approximation de la courbure du paysage de perte), afin de privilégier des directions bénéfiques aux anciennes et aux nouvelles tâches à la fois.
- Le rejeu de données (replay) : conserver et réutiliser des données des tâches précédentes pendant l'entraînement sur de nouvelles tâches — une solution simple, souvent très efficace, à condition que le stockage des données reste possible.
- La réinitialisation périodique : repartir d'un réseau réinitialisé et le réentraîner sur l'ensemble des données collectées jusqu'ici, une approche proche d'un nouvel apprentissage supervisé classique, efficace si l'on peut se permettre d'attendre la convergence sur un ensemble de données plus large.

Chapitre 9. La perte de plasticité

La plasticité désigne la capacité d'un réseau de neurones à continuer d'apprendre efficacement de nouvelles tâches. Contrairement à l'intuition, cette capacité, présente à l'initialisation, peut se dégrader au fil de l'entraînement — un phénomène distinct de l'oubli catastrophique.

Deux formes de perte de plasticité identifiées

- La première forme, la plus radicale, correspond à un effondrement complet de l'entraînabilité du réseau : dans une expérience où un réseau doit mémoriser des étiquettes réattribuées aléatoirement à intervalles réguliers, la perte associée à un second cycle d'apprentissage se stabilise à un niveau correspondant à une prédiction uniforme, avec une proportion importante de neurones ReLU définitivement inactifs (« morts »).
- La seconde forme, plus subtile, est liée à un phénomène de surapprentissage précoce : un réseau entraîné d'abord sur une partie seulement d'un jeu de données, puis sur l'ensemble complet, finit par généraliser moins bien qu'un réseau entraîné directement sur l'ensemble des données dès le départ — alors même que l'ajout des données supplémentaires aurait dû, en théorie, améliorer la généralisation.

Mécanismes et remèdes évoqués

- La première forme de perte de plasticité est liée à un déplacement de la distribution des pré-activations hors de la plage attendue par les non-linéarités (proche d'une distribution centrée, de variance unitaire) ; des changements de tâche très marqués peuvent, combinés aux statistiques adaptatives d'optimiseurs comme Adam, provoquer des mises à jour de paramètres démesurées immédiatement après un changement de tâche.
- Des mesures de contrôle simples — normalisation des caractéristiques, légère régularisation (weight decay) pour limiter la croissance de la norme des paramètres, taux d'apprentissage maîtrisé — permettent, combinées, de maintenir une plasticité stable sur de très nombreuses tâches successives.
- La seconde forme de perte de plasticité, liée au surapprentissage précoce, peut être largement atténuée par une réaugmentation temporaire (warm-up) du taux d'apprentissage lors de l'ajout de nouvelles données, une intervention qui permet au réseau de retrouver une bonne capacité d'apprentissage de caractéristiques plutôt que de rester bloqué dans un minimum trouvé prématurément.
- Il existe des indices que ces phénomènes affectent également les grands modèles de langage (par exemple une moindre facilité à affiner un modèle sur-entraîné au sens des lois d'échelle de Chinchilla), ce qui relie ces observations à des enjeux pratiques d'entraînement à grande échelle.

Chapitre 10. Solutions et implications pour les grands modèles de langage

Au-delà de l'apprentissage par mise à jour des poids, les grands modèles de langage disposent d'une autre forme d'adaptation : l'apprentissage en contexte (in-context learning), qui se produit au moment de l'inférence plutôt que pendant l'entraînement.

Idées clés

- En fournissant à un modèle plusieurs exemples dans son contexte, celui-ci est souvent capable d'ajuster ses réponses en conséquence, sans aucune mise à jour de ses poids — une forme d'adaptation distincte de l'apprentissage continu classique, mais qui n'est pas exempte des instabilités observées lors de l'entraînement par descente de gradient.
- Cette capacité reste cependant limitée : une expérience simple montre que si l'on indique explicitement à un modèle qu'une de ses réponses précédentes était incorrecte, seule une fraction des modèles actuels parvient effectivement à corriger sa réponse lorsqu'on l'interroge à nouveau.
- Des travaux récents montrent qu'il est possible d'entraîner spécifiquement des modèles à mieux exploiter les informations correctives présentes dans leur contexte, ce qui améliore, sans le résoudre totalement, ce problème.
- Ce chapitre rejoint directement la problématique du contexte long abordée par Federico Barbara en début de journée : à mesure que le contexte s'allonge, il devient également plus difficile pour un modèle de retrouver et d'exploiter correctement l'information pertinente qui s'y trouve.

Chapitre 11. Apprentissage continu, durabilité et efficacité

La seconde intervention sur l'apprentissage continu élargit la discussion en interrogeant les limites du paradigme actuel, dominé par la mise à l'échelle (scaling), et propose l'apprentissage continu comme piste de réponse à plusieurs de ces limites.

Motivations complémentaires évoquées

- Une motivation liée à la durabilité environnementale : la consommation énergétique cumulée des centres de données mondiaux serait comparable à celle d'un pays comme le Japon, et leur consommation d'eau douce soulève des enjeux similaires, ce qui interroge la viabilité d'une croissance fondée uniquement sur la mise à l'échelle des modèles.
- Une justification plus formelle, empruntée à un article de Benjamin Van Roy : dans la mesure où le monde qu'un agent cherche à modéliser contient nécessairement cet agent lui-même, aucun modèle, aussi grand soit-il, ne peut représenter le monde dans son intégralité ; le problème de l'apprentissage devient donc, par nature, non stationnaire et continu.
- L'intervenant nuance toutefois cette justification en mettant en garde contre une conclusion hâtive selon laquelle il suffirait de choisir une tâche suffisamment complexe pour garantir un apprentissage continu utile ; la complexité perçue d'une tâche ne coïncide pas nécessairement avec sa réelle difficulté d'apprentissage, ni avec la complexité de la politique optimale qui la résout.

Repenser l'efficacité de l'apprentissage

- L'intervenant invite à ne plus définir l'efficacité d'un système d'apprentissage uniquement par rapport à un objectif statique (converger vers un état de l'art fixé sur un jeu de données donné), mais par la vitesse à laquelle un système parvient à suivre un monde qui continue de changer.
- Il rapproche cette idée d'un travail de Thomas Griffiths sur l'intelligence humaine, dont la thèse est que les limitations de calcul et d'énergie propres aux humains ont façonné, plutôt que contraint

négativement, les stratégies cognitives qu'ils emploient — notamment le recours systématique à la décomposition de problèmes complexes en sous-tâches.

- Le célèbre 37e coup joué par AlphaGo contre Lee Sedol illustre cette idée par contraste : contrairement à un joueur humain, qui aborde le jeu via une décomposition en sous-objectifs, AlphaGo optimise directement la victoire globale par une recherche brute, ce qui lui permet d'accéder à des solutions hors du répertoire compositionnel typiquement humain — la compositionnalité humaine, bien qu'efficace, ayant elle-même un coût en termes de solutions inaccessibles.
- L'intervenant illustre enfin, par une analogie avec un jeu de tir à la corde, comment la descente de gradient standard réalise un compromis entre les signaux parfois contradictoires fournis par différents exemples ou différentes tâches ; lorsqu'un mode de la distribution de données est absent (as en apprentissage séquentiel), ce compromis disparaît temporairement, ce qui explique une partie des interférences observées entre tâches apprises successivement.

Conclusion générale

Bien que couvrant des domaines très différents — architecture des modèles de langage, financement des startups, apprentissage continu —, les interventions de cette troisième journée partagent un intérêt commun pour les limites concrètes des systèmes actuels, qu'il s'agisse de limites mécaniques, économiques ou statistiques.

Fils conducteurs de la journée

- L'exposé de Federico Barbara illustre comment des choix architecturaux en apparence techniques (masquage causal, encodage positionnel) déterminent directement les capacités et les limites concrètes des modèles de langage actuels, y compris sur des tâches en apparence triviales.
- L'intervention sur le capital-risque rappelle que la réussite d'une innovation technique dépend aussi de facteurs extérieurs à la technique elle-même : la taille du marché, le moment de lancement, et la composition de l'équipe fondatrice.
- Les deux interventions sur l'apprentissage continu convergent vers un même constat : la descente de gradient standard, bien adaptée à un cadre d'apprentissage statique et bien mélangé, se comporte mal dès que la distribution des données change au fil du temps — que ce soit par oubli des tâches passées ou par perte de la capacité à apprendre de nouvelles tâches.
- Un fil plus large relie l'ensemble de la journée aux journées précédentes : dans chaque cas, la compréhension fine des mécanismes internes des réseaux de neurones (géométrie des représentations, dynamique du gradient, comportement de l'attention) permet d'expliquer, et souvent de corriger, des comportements qui semblent d'abord mystérieux ou arbitraires.

Ce document restitue les notions abordées dans un cadre pédagogique et objectif ; certains échanges avec le public, ainsi qu'une partie de la fin de journée non transcrite, n'ont pu être que partiellement ou pas du tout restitués dans les notes disponibles.

Annexe — Approfondissements par chapitre

Cette annexe reprend, chapitre par chapitre, les développements techniques qui étayent les synthèses présentées dans le corps du document.

A.1 — Le masque causal et la fonction softmax (complément du chapitre 1)

Formellement, l'attention repose sur une matrice de scores obtenue en multipliant les matrices de requêtes (Q) et de clés (K), de dimensions n × d chacune, ce qui produit une matrice n × n. Pour rendre l'attention causale, les scores correspondant à des positions futures (le triangle supérieur de cette matrice) sont fixés à moins l'infini avant l'application de la fonction softmax, qui les convertit alors en une probabilité quasi nulle. Ce mécanisme garantit que la prédiction à une position donnée ne peut dépendre que de l'information disponible aux positions antérieures, condition nécessaire à un entraînement cohérent avec la tâche de génération autorégressive.

A.2 — Sensibilité et propagation de l'information (complément du chapitre 2)

Pour quantifier formellement l'asymétrie de propagation de l'information selon la position, l'intervenant propose de mesurer la dérivée partielle de la représentation finale (au dernier jeton) par rapport à chaque jeton d'entrée. Cette dérivée peut s'interpréter comme une somme pondérée sur l'ensemble des chemins reliant, à travers les différentes couches d'attention, un jeton donné au dernier jeton de la séquence — un résultat qui se rattache formellement à la théorie spectrale des graphes.

Un pic particulier de sensibilité est observé pour l'avant-dernier jeton de la séquence, expliqué par la présence des connexions résiduelles, qui ajoutent artificiellement un poids supplémentaire à la diagonale de la matrice d'attention (chaque position « voit » toujours, au minimum, sa propre représentation grâce à ces connexions).

A.3 — RoPE : détails mathématiques (complément du chapitre 4)

Le RoPE construit une matrice de rotation par blocs diagonaux de taille 2×2, chaque bloc correspondant à une fréquence de rotation différente : les blocs associés aux indices les plus bas tournent lentement (environ 1 radian par jeton), tandis que les blocs associés aux indices les plus élevés tournent à une vitesse d'environ 1/θ radian par jeton, où θ (theta) est un grand nombre de base (typiquement de l'ordre de 10 000, parfois davantage).

Cette matrice étant orthogonale, ses puissances successives correspondent simplement à des multiples de la rotation initiale, ce qui rend son application très efficace en pratique et garantit, par construction, que le produit scalaire d'attention entre une requête à la position i et une clé à la position j ne dépend que de la distance relative j − i.

L'analyse empirique présentée mesure la norme de chaque bloc de fréquence dans les requêtes et les clés apprises par un modèle entraîné : cette norme révèle une structure nette, certaines têtes d'attention utilisant préférentiellement les hautes fréquences (attention très locale, y compris une tête observée ne portant attention qu'à elle-même, ou une autre spécialisée dans la détection d'un caractère spécifique tel que l'apostrophe), d'autres préférant les basses fréquences pour transmettre une information stable sur de longues distances. Ce sont précisément ces composantes de basse fréquence qui, en subissant plus d'un tour complet de rotation lorsque le contexte dépasse largement la longueur d'entraînement, perdent leur

cohérence — d'où la solution retenue de les neutraliser plutôt que d'ajuster uniformément la base θ, comme le faisaient certaines méthodes antérieures (approches dites « NTK-aware »).

JOUR 4

Calcul haute performance, IA en biomédecine et en mathématiques, RL et estimation statistique

30 juillet 2026

Intervenants et thèmes principaux :

NCC Monténégro / EuroCC — Calcul haute performance

Maria Brbić (EPFL) — IA pour la biomédecine

UiPath — Agents d'automatisation informatique

Matia Tapušković (Oxford) — IA pour les mathématiques

Kyunghyun Cho (NYU) — Statistics Upside Down

Introduction et programme de la journée

Ce chapitre propose une synthèse organisée de la quatrième journée de l'école d'été EEML 2026, tenue à Cetinje, au Monténégro. Le programme a comporté une conférence d'ouverture consacrée au calcul haute performance, deux conférences principales portant respectivement sur l'intelligence artificielle appliquée à la biomédecine et sur l'apprentissage automatique appliqué aux mathématiques, une présentation d'un partenaire industriel sur les agents d'automatisation informatique, ainsi qu'un ensemble de notions fondamentales relatives à l'apprentissage par renforcement et aux méthodes d'estimation statistique apprises par réseaux de neurones.

Programme de la journée

- Ouverture — Le rôle des centres de compétence en calcul haute performance (NCC Monténégro / EuroCC)
- Conférence — L'intelligence artificielle au service de la biomédecine (Maria Brbić, EPFL)
- Présentation partenaire — Les agents d'automatisation informatique (UiPath)
- Conférence — L'apprentissage automatique au service des mathématiques (Matia Tapušković, Université d'Oxford)
- Notions fondamentales — L'apprentissage par renforcement, du cadre théorique à l'alignement des grands modèles de langage
- Tutoriel pratique — Implémentation progressive d'algorithmes de RL
- Conférence — « Statistics Upside Down » : apprendre des estimateurs statistiques (Kyunghyun Cho, NYU)

Ouverture : le calcul haute performance au service de la recherche

La journée a été ouverte par une présentation du centre national de compétences (NCC) en calcul haute performance du Monténégro, porté conjointement par l'Université de Donja Gorica et l'Université du Monténégro. Ce centre s'inscrit dans le réseau européen EuroCC, financé à l'origine par les programmes Horizon Europe puis Europe numérique, dans le cadre de l'initiative commune EuroHPC. Le budget de ce programme est estimé à environ 60 à 65 millions d'euros, pour plus de 35 pays participants.

Ces centres nationaux ont pour mission de donner accès aux chercheurs, aux entreprises et au secteur public à des ressources de supercalcul européennes (parmi lesquelles Jupiter, LUMI en Finlande ou Leonardo en Italie), ainsi que de proposer des formations à leur utilisation. L'accès est ouvert à la recherche académique comme à l'industrie, à la seule condition que l'usage ne soit pas directement commercial. Initialement centré sur le calcul haute performance, le programme EuroCC couvre désormais également l'analyse de données à grande échelle et l'intelligence artificielle, notamment via l'émergence des « usines d'IA » (AI factories) dans plusieurs pays européens.

L'intervenant a souligné qu'au Monténégro, l'usage du calcul haute performance était quasiment inexistant avant la mise en place du centre, la plupart des acteurs locaux considérant leurs besoins couvrables par une infrastructure informatique classique. La diffusion rapide de l'apprentissage automatique a depuis largement changé cette perception : une trentaine à une quarantaine d'entreprises locales utilisent aujourd'hui ces ressources, dans des domaines aussi variés que l'agriculture, la médecine, le tourisme, le patrimoine culturel ou le marketing numérique.

Conférence — L'intelligence artificielle au service de la biomédecine

Intervenante : Maria Brbić, professeure adjointe en informatique et sciences de la vie à l'École polytechnique fédérale de Lausanne (EPFL), Suisse.

Contexte : une révolution des données biologiques

La conférence a débuté par un état des lieux des avancées technologiques récentes en biologie moléculaire, en particulier le séquençage de l'ARN à l'échelle de la cellule unique (« single-cell RNA sequencing »). Cette technologie permet de mesurer l'expression des gènes dans des centaines de milliers, voire des millions de cellules individuelles au cours d'une même expérience, alors que les techniques antérieures ne donnaient accès qu'à une expression génique moyennée sur des populations cellulaires entières — une limite importante lorsque ces populations sont hétérogènes, par exemple dans le cas d'une tumeur mêlant cellules malades et cellules saines.

Au-delà du transcriptome, les technologies actuelles permettent également de mesurer d'autres modalités biologiques : le protéome, l'épigénome (via l'accessibilité de la chromatine, qui renseigne sur l'activité de régulation génétique), ainsi que l'organisation spatiale des cellules au sein des tissus. Cette diversification des modalités mesurables, couplée à l'essor des méthodes d'intelligence artificielle, ouvre selon l'intervenante un moment particulier pour tenter de relier ces différentes échelles d'observation — moléculaire, cellulaire, tissulaire — afin de mieux comprendre le fonctionnement du corps humain, sain ou malade.

Relier transcriptome et morphologie cellulaire

Le premier axe de travail présenté vise à établir un lien quantitatif entre le profil transcriptomique d'une cellule (l'expression d'environ 20 000 gènes) et sa morphologie nucléaire. Ce travail s'appuie sur une technologie développée en laboratoire, nommée IRIS, qui permet d'obtenir pour une même cellule à la fois une image à haute résolution et son profil d'expression génique complet, par imagerie de cellules encapsulées dans des gouttelettes microfluidiques.

Le nombre d'échantillons appariés (image et transcriptome pour une même cellule) restant limité — de l'ordre de 10 000 —, l'approche retenue consiste à entraîner séparément un encodeur puissant pour chaque modalité avant d'apprendre la relation entre les deux représentations. Pour l'encodage transcriptomique, l'équipe s'appuie sur des modèles de fondation existants pour la biologie unicellulaire (par exemple des « embeddings cellulaires universels » ou des modèles de type scGPT), ainsi que sur des modèles plus simples comme scVI. Pour la morphologie nucléaire, faute de modèle de fondation disponible publiquement, l'équipe a entraîné son propre encodeur : un transformeur de vision d'environ 300 millions de paramètres, pré-entraîné par auto-encodage masqué sur plus de 22 millions d'images de noyaux cellulaires, avec le soutien de ressources de calcul suisses (environ 10 000 GPU H100).

Prédire la réponse des cellules aux perturbations

Un second axe, présenté comme un objectif central du domaine, concerne la prédiction de la réponse d'une cellule à une perturbation — modification de l'expression d'un gène, administration d'un médicament, etc. L'intervenante a indiqué que les méthodes existantes obtiennent, sur des perturbations génétiques non vues à l'entraînement, des performances de corrélation nettement inférieures à celles rapportées sur des tâches plus favorables, ce qui traduit une difficulté persistante à généraliser à de nouvelles perturbations. Ce constat a conduit l'équipe à s'interroger plus largement sur la fiabilité des métriques utilisées pour évaluer ce type de modèles en biologie.

Mesurer la similarité des représentations : biais et étalonnage

Cette partie de la conférence portait sur l'hypothèse dite de la « représentation platonicienne » (Platonic Representation Hypothesis), proposée par Phillip Isola et ses collaborateurs en 2024, selon laquelle des réseaux de neurones entraînés avec des objectifs différents, sur des données et des modalités différentes, convergeraient vers une représentation statistique partagée de la réalité. Cette hypothèse s'appuie sur l'observation empirique que la similarité de représentation entre modèles de vision et modèles de langage tend à augmenter avec la taille des modèles, mesurée à l'aide de métriques telles que l'alignement de noyau centré (CKA) ou l'analyse de corrélation canonique (CCA).

L'équipe de Maria Brbić montre cependant que ces métriques de similarité globale sont affectées par deux biais systématiques liés à l'architecture des réseaux plutôt qu'à leur contenu représentationnel : un « effet de largeur », par lequel des réseaux plus larges présentent une similarité apparente plus élevée du seul fait de la dimension supérieure de leur espace de représentation, et un « effet de profondeur », lié au nombre de comparaisons effectuées entre couches, qui accroît statistiquement la probabilité d'observer une similarité élevée par pur hasard. Ces deux effets ont été démontrés y compris entre vecteurs indépendants, ce qui en confirme le caractère artefactuel.

Pour corriger ce biais, l'équipe propose une méthode d'étalonnage fondée sur la construction d'une distribution nulle empirique — obtenue en brisant volontairement la correspondance entre paires vision-langage — permettant de replacer chaque score de similarité observé dans son contexte statistique. Cette méthode, indépendante de la métrique utilisée, a été appliquée à l'hypothèse de la représentation platonicienne : après étalonnage, la tendance de convergence globale observée à l'échelle du modèle disparaît, tandis qu'une convergence locale, mesurée par la similarité des plus proches voisins, demeure. Ce résultat conduit l'intervenante à proposer une reformulation plus restreinte, qualifiée d'hypothèse de représentation « aristotélicienne », selon laquelle seules les relations de voisinage local entre points de données convergeraient de façon robuste entre modèles, et non la géométrie globale de leurs représentations.

Ce travail se prolonge par une méthode de diagnostic permettant d'estimer, avant tout entraînement d'alignement coûteux, la compatibilité probable de deux modèles à l'aide de scores calculés à partir des plus proches voisins mutuels dans leurs espaces pré-entraînés respectifs.

Aligner des modèles pré-entraînés avec peu de données appariées

La dernière partie de la conférence portait sur l'alignement de modèles unimodaux pré-entraînés lorsque les données multimodales appariées sont rares — une situation fréquente en biomédecine, où les grands ensembles de données appariées de plusieurs centaines de millions d'exemples, courants en vision-langage, n'existent généralement pas. L'approche proposée introduit un terme de régularisation qui vise à préserver, dans l'espace d'alignement appris, la structure de voisinage déjà présente dans les espaces pré-entraînés de chaque modalité, en minimisant la divergence de Jensen-Shannon entre les distributions de similarité avant et après alignement.

Cette régularisation, présentée comme simple à intégrer à n'importe quelle fonction d'alignement existante (contrastive, linéaire ou non linéaire), permet une amélioration moyenne de l'ordre de 68 % sur des tâches de classification et de recherche en régime de faible disponibilité de données appariées (de l'ordre de 80 000 échantillons, soit moins de 1 % des volumes habituellement utilisés dans le domaine).

Discussion et perspectives

Les échanges qui ont suivi la présentation ont notamment porté sur la place des a priori de symétrie dans les modèles biologiques, sur la difficulté de mesurer la similarité de représentations humaines (par exemple entre diagnostics médicaux), et sur les axes de recherche jugés encore peu explorés : l'étude conjointe des données protéomiques et transcriptomiques, ainsi que l'articulation entre données dynamiques (imagerie de cellules vivantes) et données statiques mais destructives (séquençage unicellulaire), en vue de mieux caractériser la dynamique spatio-temporelle des systèmes biologiques.

Présentation partenaire — Les agents d'automatisation informatique

Intervenant : Radu Erdustanciu, ingénieur en science appliquée chez UiPath.

Cette présentation, proposée par le sponsor industriel de l'école d'été, portait sur l'évolution des technologies d'automatisation des tâches informatiques répétitives, illustrée par l'agent « Otto » développé par UiPath. L'intervenant a retracé trois générations successives de cette automatisation : les robots RPA (Robotic Process Automation) classiques, fondés sur des règles rigides et des sélecteurs d'interface prédéfinis, fragiles au moindre changement d'interface ; puis l'introduction de la vision par ordinateur, qui permet à l'agent de percevoir l'écran mais sans en comprendre la tâche sous-jacente ; enfin, les agents actuels, capables de raisonner sur une tâche et d'émettre des actions de manière autonome, en observant l'écran par captures successives et en exécutant leurs actions via un pilote logiciel proche du système d'exploitation.

La performance de ces agents est évaluée à l'aide de plusieurs référentiels standards : OSWorld (une évaluation de bout en bout de l'usage informatique), ainsi que OSWorld-G et ScreenSpot-Pro, qui évaluent plus spécifiquement la capacité de l'agent à situer correctement l'action à réaliser sur l'écran (par exemple prédire l'endroit où cliquer).

L'intervenant a également abordé les contraintes pratiques de déploiement de ces systèmes : la nécessité d'un compromis entre la taille du modèle utilisé, son coût d'inférence et la latence perçue par l'utilisateur ; la taille de la fenêtre de contexte, réduite (de l'ordre de 30 000 à 60 000 jetons) pour les modèles d'exécution afin de limiter le coût, mais nettement plus importante pour les modèles de planification ; ainsi que les enjeux de confidentialité liés au traitement de données d'entreprise par des fournisseurs de modèles tiers, gérés contractuellement par des clauses de non-conservation des données.

Conférence — L'apprentissage automatique au service des mathématiques

Intervenant : Matia Tapušković, chargé de développement de carrière en mathématiques, Corpus Christi College, Université d'Oxford.

Mathématicien de formation, spécialisé en théorie des nombres, en géométrie et en physique mathématique, l'intervenant a proposé une lecture en trois temps de la relation entre apprentissage automatique et recherche mathématique, en comparant cette relation naissante à celle qui a historiquement uni les mathématiques et la physique.

Apprendre à partir d'exemples

Le premier exemple présenté concerne les polynômes de Kazhdan-Lusztig, des objets combinatoires associés aux intervalles du graphe de permutations et centraux en théorie des représentations. Une équipe de chercheurs (dont les travaux ont été publiés dans Nature en 2021) a entraîné un réseau de neurones sur

graphes (GNN) à prédire les coefficients de ces polynômes à partir des graphes d'intervalles non étiquetés, avec une précision élevée. L'analyse des gradients du modèle — une technique usuelle d'attribution en apprentissage automatique — a permis d'identifier les arêtes du graphe les plus déterminantes pour la prédiction, révélant une décomposition du graphe en deux sous-structures plus simples jusqu'alors non identifiée par les mathématiciens, en raison de la croissance combinatoire très rapide de ces objets. Cette observation a directement contribué, dans les mois qui ont suivi, à une preuve partielle de la conjecture d'invariance combinatoire de Lusztig et Dyer, restée ouverte pendant plusieurs décennies.

Le second exemple porte sur le rang des courbes elliptiques, une quantité arithmétique parmi les plus difficiles à calculer en théorie des nombres. En 2022, une équipe a appliqué une simple régression logistique à des vecteurs de 500 coefficients (les nombres a_p, associés au nombre de solutions de l'équation modulo différents nombres premiers) afin de prédire si le rang d'une courbe était nul ou égal à un, obtenant une précision de 90 à 97 %. Cherchant à comprendre l'origine de ce signal, un étudiant de premier cycle a moyenné ces coefficients sur des intervalles de courbes classées par un indicateur de complexité arithmétique (le conducteur), et a mis en évidence un motif oscillant inattendu, baptisé depuis « murmuration », qui n'avait jamais été repéré visuellement malgré des décennies d'étude de ces objets par des spécialistes du domaine. Ce phénomène a depuis été démontré rigoureusement pour certaines classes de formes modulaires et observé dans d'autres familles de fonctions spéciales.

Les grands modèles de langage face aux problèmes mathématiques

Le deuxième axe de la conférence portait sur l'usage direct de grands modèles de langage pour aborder des problèmes mathématiques ouverts, notamment via des systèmes de recherche évolutionnaire tels qu'AlphaEvolve, qui a par exemple permis de réfuter une variante de la conjecture des distances d'Erdős en établissant un lien avec un domaine mathématique a priori distinct. L'intervenant a insisté sur le rôle déterminant, dans ces succès, de la qualité de l'évaluateur utilisé pour juger les propositions générées — un évaluateur peu coûteux, fiable et difficile à « tromper » étant présenté comme la condition la plus importante du succès, davantage que la recherche elle-même.

La formalisation des preuves mathématiques

Le troisième axe portait sur la formalisation des démonstrations à l'aide d'assistants de preuve, en particulier le langage Lean. Un assistant de preuve permet d'exprimer définitions et énoncés sous forme de programmes, dont un noyau vérifie mécaniquement la correction logique — une vérification de forme, non de vérité empirique. La bibliothèque communautaire Mathlib, qui rassemble l'essentiel des mathématiques de premier cycle formalisées ainsi qu'une partie significative de mathématiques de recherche, représente environ 2,3 millions de lignes de code accumulées en neuf ans.

Plusieurs jalons récents illustrent l'accélération de ce domaine : lors des Olympiades internationales de mathématiques 2024, les systèmes AlphaProof et AlphaGeometry de DeepMind ont atteint le niveau médaille d'argent en s'appuyant sur le noyau de vérification de Lean comme évaluateur d'apprentissage par renforcement ; en 2025, certains systèmes ont obtenu le niveau médaille d'or en raisonnant uniquement en langage naturel, sans recours à une vérification formelle, un résultat obtenu en quelques heures mais nécessitant une validation humaine a posteriori. Plus récemment, un système a permis de résoudre en Lean, en une vingtaine d'heures, un problème connu sous le nom de « cap set problem », tandis que la formalisation complète du théorème d'empilement de sphères en dimension 8 (théorème de Viazovska) a été réalisée par un moteur de formalisation en quelques jours, contre plusieurs années de travail humain

pour construire une bibliothèque de référence comparable. Un résultat intermédiaire du théorème de modularité, sur lequel repose la démonstration du grand théorème de Fermat, a par ailleurs été formalisé en environ 250 000 lignes de code en deux semaines, sous la supervision d'un unique doctorant.

L'intervenant a souligné que si la vérification formelle des démonstrations bénéficie clairement de l'apport de l'IA, la formulation même des définitions et des énoncés — c'est-à-dire s'assurer qu'un énoncé formel capture fidèlement ce que les mathématiciens entendent par une conjecture — demeure la difficulté la plus importante, qualifiée de problème de la signification (« meaning problem »), commun à de nombreuses applications de l'IA.

Discussion : quel rôle pour les LLM dans la recherche mathématique ?

Les échanges avec le public ont porté sur plusieurs questions ouvertes : l'importance relative de la formulation de conjectures par rapport à leur démonstration — l'intervenant estimant que les deux activités sont indissociables, une conjecture nouvelle émergeant le plus souvent d'une reformulation issue de tentatives de démonstration antérieures ; la capacité des modèles de langage à développer une intuition nouvelle par la lecture d'un large corpus de littérature, plutôt qu'à réellement innover ; et l'absence, à ce jour, d'exemple documenté de construction d'une théorie mathématique entièrement nouvelle par un système d'IA, la contribution de ces outils restant pour l'instant concentrée sur l'exploration de pistes déjà balisées et sur la vérification formelle.

Notions fondamentales — L'apprentissage par renforcement

Synthèse personnelle établie à partir du cours consacré à l'apprentissage par renforcement (RL) et à son application à l'alignement des grands modèles de langage.

Le processus de décision markovien (MDP)

Un problème d'apprentissage par renforcement est formalisé comme un processus de décision markovien, défini par un ensemble d'états, un ensemble d'actions, une fonction de transition, une fonction de récompense et un facteur d'actualisation γ (gamma). L'objectif de l'agent est de maximiser l'espérance du retour cumulé J(θ) = E[R]. Le facteur γ détermine l'importance accordée aux récompenses futures : une valeur proche de 0 privilégie la récompense immédiate, tandis qu'une valeur proche de 1 accorde un poids important aux récompenses à long terme.

Bandits manchots et dilemme exploration-exploitation

Le problème des bandits manchots constitue une version simplifiée du RL, dans laquelle l'agent choisit à chaque étape un « bras » et observe la récompense associée, sans notion d'état. Il illustre le dilemme fondamental entre exploration (tester de nouvelles actions pour mieux les évaluer) et exploitation (répéter l'action jugée la meilleure jusqu'ici). Une méthode classique pour arbitrer ce compromis est la stratégie ε-greedy : avec une probabilité ε, l'agent choisit une action aléatoire ; sinon, il choisit la meilleure action connue.

Gradient de politique et l'algorithme REINFORCE

Plutôt que d'apprendre des valeurs, l'approche par gradient de politique apprend directement une politique π_θ(a|s), c'est-à-dire une distribution de probabilité sur les actions, et ajuste ses paramètres θ par montée de gradient afin de maximiser le retour attendu. L'algorithme REINFORCE met à jour la politique en multipliant le gradient du logarithme de la politique par le retour total obtenu. Sa limite principale est un problème d'attribution du crédit (« credit assignment ») : toutes les actions d'un épisode reçoivent le même

signal, y compris celles qui n'ont pas contribué à un résultat favorable, dès lors que l'épisode se termine bien.

Fonctions de valeur et programmation dynamique

Pour résoudre ce problème d'attribution, on introduit deux fonctions de valeur : la valeur d'un état V(s) et la valeur d'un couple état-action Q(s,a), qui permettent d'identifier plus précisément quelle action est réellement responsable d'une récompense. Lorsque le modèle de l'environnement (transitions et probabilités) est entièrement connu, la programmation dynamique permet de calculer exactement V(s) ; cette approche, bien qu'efficace, reste peu réaliste pour des problèmes de grande taille.

Monte Carlo et différences temporelles

Lorsque le modèle de l'environnement est inconnu, deux familles de méthodes permettent d'estimer les valeurs à partir de l'expérience. Les méthodes de Monte Carlo attendent la fin de l'épisode pour calculer le retour réellement observé : elles produisent des estimations non biaisées, mais à forte variance. Les méthodes de différence temporelle (TD) mettent à jour l'estimation après chaque pas, à partir de la quantité $R + \gamma V(s')$, sans attendre la fin de l'épisode : elles présentent une variance plus faible, au prix d'un biais plus important. La programmation dynamique, Monte Carlo et TD se distinguent ainsi par l'horizon sur lequel elles s'appuient : le modèle complet pour la première, l'épisode entier pour la deuxième, un seul pas pour la troisième.

Apprentissage par renforcement basé sur un modèle

Une autre famille d'approches consiste à apprendre explicitement un modèle de l'environnement — une fonction de transition $P(s'|s,a)$ et une fonction de récompense $R(s,a)$ — puis à planifier les actions à partir de ce modèle appris, comme le font les algorithmes Dreamer ou MuZero. Cette approche permet de réduire fortement la quantité de données nécessaires et de raisonner sur la sécurité des actions envisagées, mais elle est sensible à l'exactitude du modèle appris : un modèle erroné conduit à une planification de mauvaise qualité.

Q-learning, rejeu d'expérience et réseau cible

Le Q-learning apprend directement la fonction Q(s,a) plutôt que V(s), la politique optimale étant alors obtenue en choisissant l'action qui maximise Q pour un état donné ; il s'agit d'un algorithme hors politique (« off-policy »). Deux techniques ont permis de stabiliser son entraînement dans le cadre du Deep Q-Network (DQN) : le rejeu d'expérience (« experience replay »), qui consiste à stocker les transitions observées et à les rejouer plusieurs fois afin de briser la corrélation temporelle des données d'entraînement, et le réseau cible (« target network »), une copie du réseau gelée puis mise à jour seulement toutes les N itérations, qui limite les oscillations de l'apprentissage.

Fonction d'avantage et architecture Actor-Critic

La fonction d'avantage $A(s,a) = Q(s,a) - V(s)$ répond à la question de savoir si une action donnée s'est révélée meilleure ou moins bonne que ce qui était attendu dans cet état ; son usage constitue une amélioration importante par rapport à REINFORCE. L'architecture Actor-Critic s'appuie sur deux réseaux : l'acteur, qui choisit les actions, et le critique, qui estime les valeurs et sert exclusivement à guider l'apprentissage de l'acteur.

Exploration par entropie

Lorsqu'une politique devient trop déterministe, elle cesse d'explorer de nouvelles actions. Pour l'éviter, un terme d'entropie $+\beta H(\pi)$ est ajouté à la fonction objectif, encourageant une politique plus diversifiée. Le coefficient β est généralement élevé en début d'entraînement, pour favoriser l'exploration, puis diminué progressivement à mesure que l'apprentissage progresse.

Proximal Policy Optimization (PPO)

L'algorithme TRPO, prédécesseur de PPO, impose une contrainte de divergence de Kullback-Leibler coûteuse à calculer. PPO remplace cette contrainte par un mécanisme d'écrêtage (« clipping ») du ratio entre la nouvelle et l'ancienne politique, borné dans l'intervalle $[1-\varepsilon, 1+\varepsilon]$. Cette simplification rend l'entraînement nettement plus stable, ce qui explique l'adoption très large de PPO comme algorithme de référence pour l'alignement des grands modèles de langage.

RLHF : l'apprentissage par renforcement à partir du retour humain

L'entraînement d'un grand modèle de langage par retour humain (RLHF) suit typiquement une séquence en quatre étapes : le pré-entraînement, le réglage fin supervisé (SFT), l'entraînement d'un modèle de récompense représentant les préférences humaines, puis l'optimisation de la politique du modèle par PPO à l'aide de ce modèle de récompense.

DeepSeek-R1 et les récompenses vérifiables

Le modèle DeepSeek-R1 introduit une alternative à cette chaîne, en se passant entièrement de modèle de récompense appris à partir de préférences humaines. Il s'appuie à la place sur des récompenses vérifiables automatiquement — par exemple la réussite de tests unitaires en programmation ou l'exactitude d'un résultat en mathématiques — ce qui permet au modèle d'apprendre directement par renforcement, sans étape intermédiaire de modélisation des préférences humaines.

GRPO

DeepSeek remplace également PPO par l'algorithme GRPO (Group Relative Policy Optimization), qui se passe du réseau critique : plusieurs réponses sont générées pour un même prompt, puis comparées entre elles ; leur récompense est normalisée (moyenne et variance au sein du groupe), avant de mettre à jour directement la politique. Cette approche réduit sensiblement le coût de calcul de l'entraînement.

Tutoriel pratique

Un tutoriel pratique a permis d'illustrer, par une implémentation progressive, la traduction concrète des notions théoriques précédentes en code : mise en place d'environnements simples (Grid World, Cliff Walking), implémentation d'un algorithme de gradient de politique puis de REINFORCE, implémentation de PPO, et enfin réglage fin d'un petit modèle de langage (Qwen, environ 500 millions de paramètres) à l'aide de ces méthodes.

Conférence — « Statistics Upside Down »

Intervenant : Kyunghyun Cho, New York University (NYU).

Cette conférence défendait une idée centrale : plutôt que de concevoir manuellement des estimateurs statistiques à partir de considérations théoriques, il est possible d'entraîner un réseau de neurones à apprendre directement un estimateur à partir de données synthétiques, en optimisant une fonction de perte adaptée à la quantité à estimer.

Exemple 1 — Apprendre à estimer l'écart-type

L'estimateur usuel de l'écart-type est biaisé, notamment en raison de la non-linéarité introduite par la racine carrée. L'approche proposée consiste à générer un grand nombre d'échantillons synthétiques, à en calculer l'écart-type exact, puis à entraîner un réseau — un ensemble reçu en entrée, l'écart-type attendu en sortie, avec une perte de type erreur quadratique moyenne — à produire un meilleur estimateur que les formules classiques. L'architecture retenue est un Set Transformer, choisie car elle est invariante à l'ordre des échantillons présentés, une propriété essentielle puisque l'ordre des observations d'un échantillon n'a pas de sens statistique.

Exemple 2 — Estimer l'information mutuelle

Le même principe est appliqué à l'estimation de l'information mutuelle, à travers une méthode nommée MIST (Mutual Information by Supervised Training) : générer des problèmes synthétiques puis apprendre directement un estimateur. Les résultats présentés indiquent que MIST surpasse plusieurs estimateurs classiques (CCA, KSG, InfoNCE, InfoNet), avec un biais et une variance plus faibles ainsi qu'une meilleure généralisation selon les dimensions testées.

Régression quantile et estimation d'incertitude

Enfin, la régression quantile a été présentée comme une alternative permettant au réseau d'apprendre directement les quantiles d'une distribution plutôt qu'une simple moyenne. Cette approche fournit naturellement une estimation de l'incertitude associée à une prédiction, avec une calibration présentée comme nettement meilleure que celle obtenue par des méthodes de rééchantillonnage telles que le bootstrap.

Synthèse générale de la journée

- Le réseau européen EuroCC / EuroHPC met à disposition des chercheurs et des entreprises des ressources de calcul haute performance, avec un accès conditionné par un usage non commercial pour l'industrie.
- En biomédecine, les progrès conjoints de l'IA et des technologies de mesure à l'échelle de la cellule unique ouvrent la voie à des modèles multimodaux capables de relier expression génique, morphologie et organisation spatiale des cellules, mais la fiabilité des métriques d'évaluation employées mérite une attention particulière.
- Les agents d'automatisation informatique évoluent de règles rigides vers des systèmes capables de percevoir et raisonner sur une interface, sous contrainte d'un compromis entre taille du modèle, coût d'inférence et latence.
- En mathématiques, l'apprentissage automatique contribue déjà à des découvertes concrètes (invariance combinatoire, murmurations des courbes elliptiques) et la formalisation des preuves progresse rapidement, sans qu'un exemple documenté de construction autonome d'une théorie mathématique nouvelle par un système d'IA n'ait encore été observé.
- L'apprentissage par renforcement, du cadre du processus de décision markovien jusqu'à PPO et GRPO, constitue le socle méthodologique de l'alignement des grands modèles de langage, avec une évolution notable vers des récompenses vérifiables automatiquement plutôt que des modèles de préférences humaines.
- Les réseaux de neurones peuvent être entraînés à apprendre directement des estimateurs statistiques — écart-type, information mutuelle, quantiles — parfois plus performants que les formules analytiques conçues manuellement, avec un bénéfice notable en matière de calibration de l'incertitude.

JOUR 5

Engagement communautaire, IA pour la médecine, recherches régionales et apprentissage efficace en calcul

31 juillet 2026

Intervenants et thèmes principaux :

Suad Glass — Association ANT et bénévolat

Elma Dervishi — IA pour la médecine

Recherches régionales : anomalies, graphes, jumeaux numériques

Dan Alistarh (IST Austria) — Compression de modèles

Avant-propos

Ce document restitue, dans un format pédagogique et objectif, la cinquième journée de l'Eastern European Machine Learning Summer School (EEML) 2026, suivie à distance. Comme pour les journées précédentes, il ne s'agit pas d'une transcription du direct, mais d'une réorganisation thématique du contenu, reformulée en français dans un registre académique neutre — la transcription source étant, cette fois, disponible directement en anglais plutôt qu'auto-traduite.

La journée s'est ouverte sur une intervention de Suad Glass, représentant de l'association bosnienne ANT (Association for Advancement of Science, Technology and Innovation), qui a présenté une « démonstration mathématique » de l'intérêt du bénévolat avant de détailler les projets de son organisation. Elma Dervishi (chercheuse à l'université de Vienne) a ensuite présenté ses travaux sur l'usage de l'IA en médecine, à partir de données de santé autrichiennes. La matinée s'est poursuivie avec trois présentations courtes de recherches menées localement dans la région (Monténégro et Albanie) : détection d'anomalies, analyse spectrale de graphes, et jumeaux numériques portuaires. L'après-midi a été consacrée à un exposé de Dan Alistarh (IST Austria, chercheur ayant également travaillé chez Anthropic) sur l'apprentissage informatiquement efficace, centré sur la compression de modèles (élagage et quantification).

Comme pour les documents précédents, le corps du texte présente une synthèse concise de chaque chapitre, tandis que les développements plus techniques — en particulier les dérivations mathématiques de la deuxième moitié de la journée — sont regroupés en annexe, avec renvoi explicite depuis chaque chapitre.

Partie I — Engagement communautaire et présentation de l'association ANT

Cette intervention a été assurée par Suad Glass, représentant de l'association ANT (Association for Advancement of Science, Technology and Innovation), organisation bosnienne partenaire de l'école d'été, qui avait notamment coorganisé l'édition EEML de l'année précédente en Bosnie-Herzégovine.

Chapitre 1. Une « démonstration mathématique » de l'intérêt du bénévolat

Sur un ton volontairement humoristique, l'intervenant construit une analogie entre trois notions d'apprentissage automatique et d'optimisation — la descente de gradient, l'équilibre de Nash et une fonction de coût personnelle — pour argumenter que l'engagement bénévole constitue un optimum global que l'individu ne peut atteindre en optimisant seul, égoïstement, son propre confort.

Les trois étapes de l'analogie

- La descente de gradient est présentée comme un algorithme « glouton » (greedy) : à chaque étape, elle choisit la direction localement la meilleure, ce qui peut la piéger dans un minimum local sans qu'elle ait conscience qu'une solution globalement meilleure existe ailleurs — une première intuition selon laquelle une stratégie purement individuelle et locale ne mène pas nécessairement au meilleur résultat possible.
- L'équilibre de Nash est ensuite introduit à l'aide d'un exemple de vie courante (deux colocataires devant faire la vaisselle) : si chacun raisonne égoïstement selon sa seule fonction de coût, la stratégie individuellement rationnelle pour chacun consiste à ne jamais faire la vaisselle — ce qui conduit les deux colocataires vers l'équilibre le plus coûteux pour l'ensemble (aucune vaisselle faite), alors qu'une coopération aurait permis un résultat globalement meilleur pour les deux.

- Enfin, en s'appuyant sur la représentation populaire selon laquelle le confort personnel dépend du temps, de l'argent et de l'énergie disponibles à différents âges de la vie, l'intervenant propose d'ajouter une variable supplémentaire à cette fonction de confort individuel : la contribution de la communauté environnante, elle-même déterminée en partie par les actions d'autrui.

La conclusion proposée est que, de la même façon qu'il faut parfois s'écarter d'une trajectoire de descente de gradient purement locale pour atteindre un meilleur optimum, il est nécessaire de « sacrifier » une partie de son temps, de son argent et de son énergie personnels — par le bénévolat — afin d'accéder à un niveau de bien-être collectif et individuel plus élevé que celui atteignable par la seule optimisation égoïste.

Chapitre 2. L'association ANT : projets et impact en Bosnie-Herzégovine

L'intervenant présente ensuite l'historique et les activités concrètes de son association, fondée en 2017 par un groupe de jeunes scientifiques bosniens dispersés à travers le monde, et comptant aujourd'hui environ 150 membres, dont plus de 40 titulaires d'un doctorat.

Principaux projets présentés

- Un programme destiné aux lycéens, réunissant de jeunes Bosniens autour de conférences données par des chercheurs bosniens ayant réussi à l'international, dans le but de les aider à découvrir des domaines d'études qui les intéressent réellement.
- Un programme de recherche de niveau licence/master, mettant en relation des étudiants avec des chercheurs membres de l'association autour de petits projets de recherche d'environ six mois — souvent la première expérience de recherche scientifique réelle pour ces étudiants, et parfois déterminante dans l'obtention ultérieure d'une place en master ou en doctorat à l'étranger.
- Une plateforme de recensement de la diaspora scientifique bosnienne (un pays dont environ la moitié de la population résiderait à l'étranger), construite par extraction de données plutôt que par inscription volontaire, ayant permis d'identifier plus de 3 400 chercheurs et plus de 45 000 publications associées.
- La rédaction de documents stratégiques nationaux, notamment sur la numérisation et l'intelligence artificielle en Bosnie-Herzégovine.
- La coorganisation, l'année précédente, de l'édition EEML tenue en Bosnie, avec plus de 300 participants et environ 900 candidatures.

L'intervenant conclut en insistant sur le fait que l'ampleur du temps et de l'effort nécessaires à l'organisation d'un tel événement n'est généralement pas perçue par les participants, et invite chacun à identifier, dans sa propre communauté, une cause à laquelle contribuer même modestement.

Partie II — Intelligence artificielle pour la médecine

Cette intervention a été assurée par Elma Dervishi, chercheuse postdoctorale à l'université de Vienne (alumni de l'université du Monténégro), venue remplacer au pied levé un intervenant initialement prévu. Ses travaux, menés au Complexity Science Hub de Vienne, portent sur l'analyse de larges bases de données médicales autrichiennes à l'aide de réseaux (graphes).

Chapitre 3. Réseaux de comorbidité et trajectoires de maladies

Le point de départ du projet est un constat démographique : l'allongement de l'espérance de vie ne se traduit pas par davantage d'années en bonne santé, mais par davantage d'années de dépendance et de comorbidités. L'intervenante a eu accès, via le ministère autrichien de la Santé, à une base de données couvrant 45 millions d'admissions hospitalières sur environ 9 millions d'individus, sur une période de 20 ans.

Idées clés

- Plutôt que d'étudier chaque maladie isolément, l'équipe construit des réseaux de comorbidité (comorbidity networks) : deux maladies sont reliées par un lien si elles apparaissent conjointement chez un même patient plus souvent que ne le voudrait le hasard. Ces liens n'encodent qu'une corrélation statistique, sans indication de causalité ni de direction.
- En répétant cette construction pour différentes tranches d'âge (enfants, adolescents, adultes, personnes âgées), on observe que la complexité de ces réseaux augmente fortement avec l'âge, révélant des maladies centrales caractéristiques de chaque étape de la vie (par exemple l'hypertension chez les femmes autour de la quarantaine).
- En exploitant la dimension temporelle des données (un même patient suivi sur 20 ans), il devient possible d'orienter certains liens et de parler, avec prudence, de trajectoires de maladies : par exemple, une cohorte de patients obèses dans la vingtaine présentant, dix ans plus tard, un risque plus élevé de dépression — sans qu'il soit établi de mécanisme causal direct.
- Un algorithme de détection de communautés non supervisé, tolérant le chevauchement entre communautés (une même maladie pouvant appartenir à plusieurs groupes, reflétant sa diversité clinique selon les patients), est utilisé pour identifier des centaines de groupes de maladies et des trajectoires plus ou moins sévères, mesurées notamment par la mortalité et la durée d'hospitalisation associées.

Détails sur les biais des données médico-administratives et sur l'exemple des trajectoires divergentes liées aux troubles du sommeil : voir Annexe A.1.

Chapitre 4. Validation moléculaire et repositionnement de médicaments

Consciente que des données hospitalières autrichiennes présentent des biais propres (sous-diagnostic de certaines maladies, biais de remboursement, etc.), l'équipe a cherché à valider ses résultats à un niveau biologique indépendant, en les confrontant à des bases de données de profils moléculaires des maladies.

Idées clés

- Après un important travail d'harmonisation de plusieurs bases de données moléculaires hétérogènes (nomenclatures différentes pour une même maladie, couverture inégale selon les types de maladies), l'équipe a pu confirmer qu'une partie substantielle des associations statistiques observées dans les données hospitalières se retrouve également au niveau des profils moléculaires — un signal que ces

trajectoires reflètent, au moins en partie, une réalité biologique et non seulement un artefact des données.

- Un phénomène de biais de littérature est également mis en évidence : les maladies les plus étudiées dans la littérature scientifique (via PubMed) sont mécaniquement mieux représentées dans les bases de données moléculaires ; la combinaison de plusieurs bases de données permet cependant d'atténuer partiellement ce biais.
- En s'appuyant sur une base de données de médicaments approuvés (DrugBank) croisée avec les profils moléculaires des trajectoires de maladies, l'équipe identifie des candidats potentiels de repositionnement de médicaments (drug repurposing) — par exemple 55 candidats pour l'endométriose, contre 9 médicaments déjà approuvés pour cette seule maladie prise isolément.
- Une étape de validation complémentaire, utilisant un agent conversationnel spécialisé en biomédecine (TxAgent, fondé sur un modèle de langage open source), a permis d'écarter automatiquement des candidats non pertinents sur le plan clinique (l'exemple donné étant l'éthanol, statistiquement associé à la dépendance à l'alcool dans les données mais évidemment inadapté comme traitement) — tout en reconnaissant explicitement, en réponse à une question du public, les limites de fiabilité des modèles de langage pour ce type de validation.

Détails sur l'usage de stades de sévérité et leur validation au niveau des réseaux d'interaction protéine-protéine (PPI) : voir Annexe A.2.

Partie III — Recherches régionales en vitrine

Cette partie de la matinée a réuni trois présentations courtes (20 minutes chacune, sans session de questions dédiée), mettant en avant des recherches entièrement conduites et développées dans la région.

Chapitre 5. Détection d'anomalies : modération de commentaires et fibrillation auriculaire

Cette intervention a été assurée par Alexander Pllumaj, doctorant à l'université du Monténégro, sur ses travaux de thèse consacrés à la détection d'anomalies.

Définitions et premier cas d'usage : modération de commentaires

- Trois types d'anomalies sont distingués : ponctuelle (une valeur toujours anormale, quel que soit le contexte), contextuelle (une valeur normale dans un contexte mais anormale dans un autre, par exemple une température élevée selon la saison), et collective (un ensemble de points, individuellement normaux, qui forme une anomalie une fois considéré globalement).
- Le premier cas d'usage visait à modérer automatiquement les commentaires d'un portail d'actualités local en les traitant comme des anomalies (discours haineux) par rapport à des commentaires normaux. Cette approche s'est révélée inadaptée : sur plus de 4,5 millions de commentaires analysés, près de 40 % avaient été bannis par les modérateurs humains — un taux bien trop élevé pour que le discours haineux constitue une anomalie statistique au sens propre.
- L'analyse a également révélé un biais et des erreurs de modération humaine significatifs dans les données d'origine, ce qui a conduit l'équipe à faire annoter un sous-ensemble de 5 000 commentaires par une linguiste professionnelle afin de constituer une vérité de terrain fiable.
- Les détecteurs d'anomalies se sont révélés peu performants (proches d'un modèle aléatoire), notamment parce que les deux classes de commentaires occupent des régions largement superposées dans l'espace des représentations. Un modèle de classification supervisée classique (régression logistique sur des embeddings BERTić, un modèle BERT adapté aux langues slaves du Sud) a en revanche atteint un score satisfaisant d'environ 0,85, ce qui a conduit l'équipe à abandonner l'approche par détection d'anomalies au profit d'une classification directe.

Second cas d'usage : détection de fibrillation auriculaire

- Le second projet vise à détecter des anomalies cardiaques (en particulier la fibrillation auriculaire) à partir de signaux ECG à canal unique, enregistrés par un capteur portable grand public (Polar H10), nettement moins riches que les 12 dérivations d'un électrocardiogramme clinique.
- Sur un jeu de données de 1 520 enregistrements annotés par un médecin (dont 22 cas de fibrillation auriculaire), des modèles à une seule classe (Mahalanobis, Isolation Forest, One-Class SVM) obtiennent des scores autour de 0,88.
- Une caractéristique appelée « cohérence de l'onde P » (Pwave consistency) — complémentaire aux irrégularités d'intervalles RR habituellement utilisées par les dispositifs grand public — s'est révélée fortement corrélée à la fibrillation auriculaire sur ce dispositif, suggérant une piste d'amélioration pour la détection sur appareils portables, à valider sur un échantillon plus large.
- Face à la faible taille du jeu de données propre, l'équipe a exploré l'apprentissage par transfert à partir d'une base de données clinique ouverte bien plus large (PTB-XL, environ 22 000 enregistrements à 12 dérivations) : un réseau convolutif résiduel est pré-entraîné sur cette base, puis affiné en deux temps (couches convolutives gelées, puis dégelées) sur les données du capteur

portable, ce qui améliore sensiblement la reconnaissance de la fibrillation auriculaire malgré la faible quantité de données disponibles.

Chapitre 6. Analyse spectrale des graphes orientés acycliques

Cette intervention a été assurée par Isidora Stanović, de la faculté de génie électrique de l'université du Monténégro, spécialiste du traitement du signal appliqué aux graphes.

Idées clés

- Les graphes orientés acycliques (DAG, Directed Acyclic Graphs) sont omniprésents en apprentissage automatique (graphes de calcul, réseaux bayésiens causaux, modèles autorégressifs). L'outil central pour en étudier le contenu fréquentiel est la transformée de Fourier sur graphe (Graph Fourier Transform, GFT), fondement des réseaux de neurones spectraux sur graphes.
- Le problème spécifique des DAG est que leur matrice d'adjacence, une fois les sommets triés topologiquement, devient strictement triangulaire supérieure — donc nilpotente, avec toutes ses valeurs propres égales à zéro. La transformée de Fourier sur graphe s'effondre alors : il devient impossible de distinguer les différentes fréquences (modes) du graphe, bien que la propagation de l'information dans le graphe reste, elle, parfaitement définie.
- Les approches existantes pour contourner ce problème (changement de base via un opérateur laplacien hermitien, ou ajout d'arêtes pour forcer la diagonalisabilité) modifient la dynamique ou la sortie du système étudié — ce que l'équipe cherche précisément à éviter.
- La solution proposée, appelée zero padding, s'inspire directement de la transformée de Fourier discrète classique : de même qu'on suppose un signal périodique et qu'on lui ajoute des zéros pour éviter le repliement spectral (aliasing), l'équipe ajoute une arête reliant le dernier au premier sommet du graphe (pour créer une périodicité), puis insère des sommets supplémentaires de valeur nulle (le nombre de sommets ajoutés dépendant de l'ordre du filtre de graphe utilisé).
- Pour un graphe en forme de chemin simple, cette méthode restaure des valeurs propres situées sur le cercle unité, permettant de retrouver une notion cohérente de fréquence (les rotations lentes correspondant aux basses fréquences, les rotations rapides aux hautes fréquences) — tout en garantissant mathématiquement que la sortie du système zero-paddé reste strictement identique à celle du DAG d'origine sur ses sommets originaux.
- Pour un DAG quelconque (non réductible à un simple chemin), une étape préalable de connexion par un chemin hamiltonien est nécessaire avant d'appliquer le zero padding ; sur des graphes-test de 7 et 8 sommets, cette approche complète permet de restaurer une matrice diagonalisable dans plus de 98 % des cas testés.

Détails et exemple d'application au débruitage d'un signal porté par un graphe : voir Annexe B.1.

Chapitre 7. Jumeaux numériques pour la surveillance côtière portuaire

Cette intervention a été assurée par Manuela Zanelli, enseignante-assistante à l'université Alexandër Moisiu de Durrës (Albanie), sur ses travaux de recherche appliqués au port de Durrës, menés après plusieurs années d'expérience dans l'industrie portuaire.

Idées clés

- Un jumeau numérique (digital twin) est un modèle virtuel d'un actif physique, combinant capteurs, intégration de données (technologies cloud), modélisation 3D/hydrodynamique et algorithmes

d'apprentissage automatique (le LSTM étant cité comme particulièrement adapté aux données séquentielles typiques de ce domaine), dans une boucle de rétroaction.

- Les jumeaux numériques peuvent être passifs (simple visualisation des données captées, sans action en retour) ou actifs (boucle fermée, avec décisions prises à partir des données) ; leur maturité progresse typiquement du descriptif (état actuel) au diagnostique, puis au prédictif, et enfin à l'autonome.
- Le projet présenté applique cette approche à quatre scénarios côtiers du port de Durrës : tempêtes et submersions, érosion côtière, élévation du niveau de la mer, et surveillance fragmentée des différents systèmes existants ; à ce stade, le jumeau numérique développé reste passif, destiné à informer des opérateurs humains plutôt qu'à déclencher des actions automatiques.
- Les principaux défis identifiés pour la généralisation de cette approche sont la fiabilité des données, le manque d'expertise technique locale spécialisée en jumeaux numériques (particulièrement marqué en Albanie), la connectivité en temps réel, et les enjeux de cybersécurité et de gouvernance des données.

Partie IV — Apprentissage informatiquement efficace

Cette intervention de l'après-midi a été assurée par Dan Alistarh, professeur à IST Austria, dont le parcours inclut un passage récent chez Anthropic, et dont les travaux portent sur la parcimonie (sparsity), la quantification et plus généralement l'optimisation des réseaux de neurones.

Chapitre 8. La « bitter lesson » et l'explosion du besoin en calcul

L'intervenant introduit son propos par la « bitter lesson » (leçon amère) formulée par Richard Sutton (lauréat du prix Turing) : sur les 70 dernières années de recherche en IA, ce sont les méthodes générales tirant parti d'une grande quantité de calcul qui se sont avérées, de loin, les plus efficaces — bien davantage que les méthodes intégrant des connaissances spécifiques au domaine.

Idées clés

- Le calcul nécessaire pour entraîner un modèle de langage à l'état de l'art a été multiplié par environ 50 000 sur les cinq dernières années (doublant environ tous les 3 à 6 mois), et celui nécessaire à l'inférence par environ 300 sur la même période, alors que la puissance des GPU les plus avancés n'a progressé, sur cette période, que d'un facteur d'environ 20 — creusant un écart de plusieurs milliers entre besoin et capacité matérielle, comblé par la multiplication de centres de données massifs.
- Cette dynamique s'explique en grande partie par les lois d'échelle (scaling laws, dites « chinchilla »), des relations empiriques permettant de prédire la performance d'un grand modèle à partir d'expériences réalisées à petite échelle, et qui montrent une amélioration continue de la performance à mesure que le calcul augmente — ce qui a incité une grande partie de l'industrie à privilégier la croissance du calcul disponible comme stratégie principale.
- Cette course au calcul a un coût environnemental mesurable, mais dont l'ampleur reste, selon l'intervenant, difficile à évaluer précisément par manque d'études publiques détaillées ; une étude de Google portant sur une requête moyenne adressée à l'un de ses modèles rapporte des ordres de grandeur relativement faibles par requête individuelle (une fraction de watt-heure, quelques dizaines de milligrammes de CO_2, une fraction de millilitre d'eau), tout en soulignant que ces coûts, multipliés par des centaines de millions de requêtes quotidiennes, deviennent significatifs à l'échelle globale.
- Cette même étude de Google indique qu'une meilleure efficacité logicielle — en particulier la compression de modèles (quantification et décodage spéculatif) — a contribué de façon majeure (environ un facteur 10 sur un facteur global de réduction de coût de 32) à l'amélioration de l'efficacité de leurs infrastructures d'inférence sur la dernière année, ce qui motive directement le reste de l'exposé.

Détails et repères chiffrés sur la taille des modèles récents et leur coût d'entraînement : voir Annexe C.1.

Chapitre 9. Fondements mathématiques de la compression de modèles

L'intervenant présente ensuite les bases mathématiques de la compression de modèles, en s'appuyant sur des travaux fondateurs des années 1990 (Optimal Brain Damage, Optimal Brain Surgeon), restés largement d'actualité malgré leur ancienneté.

Idées clés

- Le problème général consiste à trouver, à partir d'un réseau déjà entraîné (poids W^*), une version compressée dont la perte reste proche de celle du modèle original — que la compression prenne la forme d'un élagage (mise à zéro de certains poids) ou d'une quantification (réduction de la précision numérique des poids).

- En développant la fonction de perte du modèle compressé par une approximation de Taylor autour du point optimal W*, et en supposant le gradient du modèle original nul (puisqu'il a déjà convergé), l'impact de la compression sur la perte se réduit essentiellement à un terme quadratique impliquant la matrice hessienne de la perte — ce qui transforme le problème de compression en un problème d'optimisation quadratique sous contrainte.
- La résolution de ce problème par la méthode des multiplicateurs de Lagrange conduit, pour l'élagage, à retirer en priorité les poids dont l'impact sur la perte (mesuré par leur magnitude au carré, pondérée par l'inverse de la hessienne) est le plus faible — et, dans le cas simplifié où la hessienne est diagonale (poids non corrélés), cette solution se réduit exactement à la méthode heuristique consistant à élaguer les poids de plus faible magnitude.
- Le même raisonnement, appliqué à une contrainte de quantification plutôt que d'élagage, conduit à la méthode dite d'arrondi au plus proche (round-to-nearest) dans le cas simplifié de poids non corrélés — la version corrélée, prenant en compte la hessienne complète, permettant de compenser l'erreur introduite sur un poids en ajustant légèrement les autres poids restants.

Détails, formalisation complète de la dérivation et illustration géométrique de la correction inter-poids : voir Annexe C.2.

Chapitre 10. Le mur du passage à l'échelle et la solution GPTQ

Ce cadre mathématique, bien que satisfaisant sur le plan théorique, devient totalement impraticable dès lors que l'on considère des modèles comportant plusieurs milliards de paramètres : le calcul, le stockage et l'inversion de la matrice hessienne complète deviennent physiquement impossibles (l'intervenant cite l'exemple de ResNet-50, dont la hessienne occuperait à elle seule 25 pétaoctets de stockage).

La solution GPTQ

- Face à l'impossibilité de traiter le réseau dans son ensemble, la méthode GPTQ (développée par l'équipe de l'intervenant) adopte une stratégie de type « diviser pour régner » : le réseau est découpé couche par couche, et pour chaque couche, le problème est reformulé comme une régression visant à trouver des poids compressés qui reproduisent, sur un ensemble de données de calibration, la même sortie que les poids originaux.
- L'observation clé qui rend cette approche praticable est que, pour ce problème de régression couche par couche, la hessienne ne dépend que des activations d'entrée de la couche (et non des poids) : elle est donc constante et peut être précalculée une seule fois lors d'une simple passe avant sur les données de calibration.
- L'algorithme traite ensuite la matrice de poids d'une couche colonne par colonne : chaque colonne est quantifiée, l'erreur introduite est mesurée, puis toutes les colonnes restantes sont ajustées pour compenser cette erreur en s'appuyant sur les corrélations encodées dans la hessienne précalculée — un procédé réalisable en une seule passe (« one-shot »), sans nécessiter de réentraînement complet ni de rétropropagation sur l'ensemble du modèle.

Détails et exemple géométrique du calcul colonne par colonne : voir Annexe C.3.

Chapitre 11. Résultats, impact pratique et limites théoriques de la quantification

Résultats empiriques et impact pratique

- Appliquée à des modèles de la famille OPT (jusqu'à 175 milliards de paramètres), la méthode GPTQ en quantification 4 bits maintient une perplexité quasiment inchangée par rapport au modèle original sur

les grands modèles, là où l'arrondi naïf au plus proche dégrade fortement et de façon imprévisible la performance de certains modèles.

- Sur le plan pratique, la compression à 3 bits par poids d'un modèle comme OPT-175B (initialement réparti sur huit GPU) permet de le faire tenir sur un seul GPU, avec un gain de vitesse d'environ 3,5 fois pour la génération de texte — la génération étant, en pratique, limitée par le temps de transfert des poids depuis la mémoire plutôt que par le temps de calcul proprement dit.
- Une étude plus récente et à plus grande échelle (menée avec Red Hat, portant sur plus d'un million d'évaluations) confirme qu'une quantification à 8 bits est aujourd'hui quasiment sans perte de performance, tandis qu'une quantification à 4 bits entraîne une dégradation généralement limitée à environ 1 % sur des tâches simples, mais plus marquée sur des tâches de raisonnement complexe.

Limites théoriques et perspectives

- Des travaux théoriques plus récents (« théorème de linéarité ») montrent que, sous certaines hypothèses, l'augmentation de la perplexité causée par la quantification est approximativement une fonction linéaire de l'erreur relative introduite couche par couche — ce qui permet de prédire assez fidèlement l'impact d'une quantification avant même de l'appliquer, tant que l'erreur reste modérée (typiquement au-dessus d'environ trois bits par paramètre) ; au-delà de ce seuil, les prédictions deviennent trop optimistes par rapport à la dégradation réellement observée.
- Un phénomène récemment documenté concerne les modèles de raisonnement quantifiés : ceux-ci ont tendance à générer davantage de jetons de raisonnement avant de produire une réponse (« inflation de jetons »), ce qui peut masquer une dégradation de la qualité intrinsèque du modèle et, dans certains cas, annuler une partie du gain de rapidité obtenu par la quantification.
- L'intervenant conclut en identifiant comme axe de recherche ouvert la possibilité d'entraîner directement des modèles en précision réduite (plutôt que de quantifier un modèle déjà entraîné), ce qui nécessiterait de repenser certains aspects fondamentaux de l'optimisation (rétropropagation sur des valeurs discrètes, conception du matériel et des optimiseurs associés).

Conclusion générale

Cette cinquième journée, plus hétérogène que les précédentes dans ses sujets, relie néanmoins des échelles très différentes d'un même souci : celui de l'usage réfléchi de ressources limitées, qu'il s'agisse du temps individuel consacré à une communauté, des données de santé disponibles pour la recherche médicale, ou du calcul nécessaire à l'entraînement et au déploiement des modèles d'intelligence artificielle.

Fils conducteurs de la journée

- L'intervention d'ouverture, bien que non technique dans son objectif, réutilise des concepts d'optimisation (minima locaux, équilibres non coopératifs) pour illustrer une idée plus large : une stratégie individuellement rationnelle n'est pas toujours globalement optimale — un thème qui resurgit, sous une forme très différente, dans la seconde moitié de la journée à propos de la compression de modèles.
- Les travaux présentés en IA médicale illustrent comment une lecture en réseau de grandes bases de données administratives, combinée à une validation biologique indépendante, permet d'extraire une information exploitable malgré des données bruitées, biaisées et jamais causales par nature.
- Les trois présentations régionales montrent, chacune dans son domaine (modération de contenu, traitement du signal sur graphes, jumeaux numériques portuaires), qu'une recherche de qualité internationale peut être conduite localement, souvent en confrontant une méthode standard à ses limites concrètes (détection d'anomalies inadaptée à un problème trop fréquent, effondrement spectral propre aux graphes acycliques, manque d'expertise technique locale) avant d'y apporter une solution adaptée.
- L'exposé de clôture relie directement la théorie de l'optimisation présentée en tout début de journée (via l'analogie de la descente de gradient) à un problème très concret et actuel : comment continuer à bénéficier des gains de performance liés à l'augmentation du calcul sans que son coût matériel, énergétique et économique ne devienne insoutenable.

Ce document restitue les notions abordées dans un cadre pédagogique et objectif ; certains échanges informels avec le public, ainsi que la teneur exacte de quelques questions difficilement audibles dans la transcription, n'ont pu être que partiellement restitués.

Annexe — Approfondissements par chapitre

Cette annexe reprend, chapitre par chapitre, les développements techniques qui étayent les synthèses présentées dans le corps du document.

A.1 — Biais des données médico-administratives (complément du chapitre 3)

L'intervenante souligne que les données de réclamations hospitalières (medical claims data) sont collectées à des fins de remboursement d'assurance et non de recherche, ce qui introduit des biais spécifiques : une maladie non remboursée directement (comme certaines formes d'obésité, diagnostiquée seulement dans les cas les plus sévères en Autriche) sera mécaniquement sous-représentée dans les données, indépendamment de sa prévalence réelle dans la population.

L'exemple des trajectoires divergentes illustre l'intérêt de l'approche par trajectoires plutôt que par simple corrélation statistique : deux patients aux profils très similaires dans la vingtaine et la trentaine peuvent ensuite diverger fortement, l'un évoluant vers un groupe de maladies sévères, l'autre restant sur une trajectoire plus bénigne. Un exemple mis en avant par les médecins collaborateurs du projet concerne les troubles du sommeil chez les hommes dans la vingtaine et la trentaine, identifiés comme un possible événement critique précédant des trajectoires plus sévères — ce qui suggérerait des pistes de prévention proactive si ce signal se confirme à plus large échelle.

A.2 — Stades de sévérité et validation moléculaire (complément du chapitre 4)

Pour quantifier la sévérité d'une trajectoire, l'équipe introduit la notion de stade : chaque nouvelle maladie acquise par un patient au cours du temps fait progresser son stade, un stade plus élevé correspondant à une trajectoire plus sévère. Cette notion, construite uniquement à partir des données hospitalières, se retrouve également au niveau moléculaire : les maladies associées aux stades les plus avancés occupent, dans les réseaux d'interaction protéine-protéine (PPI), des positions plus centrales (davantage de connexions), ce qui corrobore, à un niveau biologique indépendant, la progression de sévérité observée dans les données cliniques.

B.1 — Zero padding et débruitage sur graphe (complément du chapitre 6)

L'analogie avec le traitement du signal classique est explicite : de même qu'en traitement du signal discret on suppose la périodicité d'un signal fini pour en calculer la transformée de Fourier, et qu'on y ajoute des zéros pour éviter que les premiers et derniers échantillons ne s'entremêlent artificiellement (repliement spectral), l'équipe transforme le DAG en graphe cyclique en ajoutant une arête du dernier sommet vers le premier, puis insère un nombre de sommets fictifs de valeur nulle égal à l'ordre du filtre de graphe utilisé, ce qui retarde suffisamment la boucle de rétroaction pour éviter toute contamination artificielle du signal.

Le DAG original reste, dans cette construction, un sous-graphe inchangé du graphe augmenté : ses sommets, ses arêtes et sa dynamique de propagation restent identiques, seule l'analyse spectrale se fait sur le graphe élargi. Les valeurs propres du graphe zero-paddé se répartissent alors sur le cercle unité, avec un angle de phase directement interprétable comme une fréquence (rotation lente pour les basses fréquences, rapide pour les hautes fréquences), permettant de retrouver un ordre de fréquence cohérent et exploitable pour, par exemple, filtrer ou débruiter un signal porté par les sommets du graphe — une expérience illustrative montre une amélioration du rapport signal sur bruit d'environ 13 décibels (de −6,99 dB à 6,21 dB) sur un exemple de filtrage simple.

C.1 — Repères chiffrés sur les grands modèles récents (complément du chapitre 8)

À titre d'illustration de la course au calcul décrite en introduction de l'exposé, l'intervenant cite le modèle Llama 4 Maverick (400 milliards de paramètres au total, 17 milliards de paramètres actifs, entraîné sur environ 22 000 milliards de jetons pour environ 6 millions d'heures-GPU) ainsi que la variante plus grande Behemoth (2 000 milliards de paramètres au total, 300 milliards actifs, environ 30 000 milliards de jetons), dont l'entraînement aurait été interrompu prématurément. Il note que des modèles ouverts plus récents, tels que Kimi K2, présentent des ordres de grandeur de calcul similaires, illustrant la poursuite de cette même tendance à l'échelle du secteur.

C.2 — Dérivation complète de l'élagage et de la quantification optimaux (complément du chapitre 9)

En notant W^* les poids optimaux d'un modèle entraîné et $\hat{W} = W^* + \delta$ les poids compressés (où δ est une perturbation contrainte, par exemple imposant qu'un poids donné devienne nul pour l'élagage), le développement de Taylor de la perte autour de W^* s'écrit : $\text{perte}(\hat{W}) \approx \text{perte}(W^*) + \nabla\text{perte}(W^*)^T\delta + \frac{1}{2}\delta^T H\delta$, où H est la matrice hessienne de la perte. Le terme de premier ordre étant négligé (le gradient à l'optimum étant proche de zéro), minimiser la différence de perte entre le modèle compressé et le modèle original revient à minimiser le terme quadratique restant, sous la contrainte structurelle imposée par le type de compression choisi.

La résolution de ce problème quadratique sous contrainte par la méthode des multiplicateurs de Lagrange conduit, pour l'élagage d'un poids i, à un impact sur la perte proportionnel à $w_i^2/(2\times[H^{-1}]_{ii})$, et à une mise à jour compensatoire des poids restants proportionnelle à $-w_i/[H^{-1}]_{ii}$ multipliée par la colonne i de l'inverse de la hessienne. Géométriquement, corriger les autres poids en tenant compte de leur corrélation avec le poids supprimé (encodée dans la hessienne) permet d'atteindre une courbe de niveau de la perte strictement meilleure que si l'on se contentait d'éliminer ce poids isolément, sans ajustement des autres — cette correction croisée étant précisément ce qui distingue Optimal Brain Surgeon d'un simple élagage par magnitude.

Pour la quantification, le raisonnement est identique mais la contrainte impose que le poids compressé appartienne à une grille (latis) de valeurs quantifiées prédéfinie ; la formule d'impact sur la perte devient alors $(w_i - q(w_i))^2/(2\times[H^{-1}]_{ii})$, où $q(w_i)$ désigne la valeur quantifiée la plus proche de w_i, et la mise à jour compensatoire des autres poids suit une formule analogue à celle de l'élagage.

C.3 — GPTQ : traitement colonne par colonne (complément du chapitre 10)

Pour une couche de poids W et une entrée X (obtenue par une simple passe avant sur des données de calibration), le problème résolu par GPTQ est de trouver des poids compressés $\hat{W}$ minimisant la norme $\|WX - \hat{W}X\|^2$ sous contrainte de quantification. La hessienne de ce problème de régression, égale à XX^T (ou X^TX selon la convention), ne dépend que des données d'entrée X et non des poids eux-mêmes : elle est donc constante et peut être calculée une seule fois, avant tout traitement des poids.

L'algorithme parcourt ensuite la matrice de poids colonne par colonne : à chaque étape, la colonne courante est quantifiée, l'erreur de sortie ainsi introduite est mesurée, puis toutes les colonnes non encore traitées sont mises à jour pour compenser cette erreur, en utilisant les corrélations encodées dans la hessienne précalculée entre la colonne courante et les colonnes restantes. Ce traitement séquentiel, couche par couche puis colonne par colonne, ramène un problème initialement impraticable à l'échelle du

modèle complet à une succession de problèmes de taille gérable, résolubles en une seule passe sur les données de calibration.

JOUR 6

Écosystème IA local, apprentissage profond géométrique, trajectoires de carrière et éthique de l'IA

1er août 2026 — dernier jour

Intervenants et thèmes principaux :

Mariana Neshovska — AI Albania

Petar Veličković (Google DeepMind) — Apprentissage profond géométrique

Dorothy Chou (Google DeepMind) — Réécrire les règles

Magd — Éthique de l'IA

Avant-propos

Ce document restitue, dans un format pédagogique et objectif, la sixième et dernière journée de l'Eastern European Machine Learning Summer School (EEML) 2026, suivie à distance. Comme pour les journées précédentes, il ne s'agit pas d'une transcription du direct, mais d'une réorganisation thématique du contenu, reformulée en français dans un registre académique neutre.

La journée s'est ouverte sur une présentation de Mariana Neshovska (AI Albania) consacrée à la construction d'un écosystème local d'intelligence artificielle en Albanie. Elle s'est poursuivie par un long exposé de Petar Veličković (Google DeepMind, université de Cambridge) sur l'apprentissage profond géométrique, retraçant l'histoire des symétries en mathématiques pour en tirer une grille de lecture unifiée des architectures de deep learning modernes. L'après-midi a débuté par une intervention plus personnelle et inspirante de Dorothy Chou (Google DeepMind), invitant les participants à interroger les règles implicites qui structurent les trajectoires de carrière dans ce domaine. La journée s'est close sur un exposé volontairement provocateur de Magd (chercheur, ancien de l'équipe éthique de Google), intitulé « pourquoi je ne recommande pas de travailler sur l'éthique de l'IA », consacré aux réalités concrètes — techniques, professionnelles et politiques — de ce champ de recherche.

Comme pour les documents précédents, le corps du texte présente une synthèse concise de chaque chapitre, tandis que les développements plus techniques — en particulier les dérivations mathématiques de la partie consacrée à l'apprentissage profond géométrique — sont regroupés en annexe, avec renvoi explicite depuis chaque chapitre.

Partie I — Construire un écosystème local d'intelligence artificielle

Chapitre 1. AI Albania : bâtir une communauté de recherche là où elle n'existait pas

Cette intervention a été assurée par Mariana Neshovska, professeure d'informatique à l'université de New York Tirana et fondatrice d'AI Albania, premier centre à but non lucratif dédié à l'intelligence artificielle en Albanie.

Idées clés

- L'intervenante part d'un constat : plusieurs personnalités albanaises internationalement reconnues (dont la chercheuse Mira Murati, ancienne directrice technique d'OpenAI) ont dû quitter le pays pour développer leur carrière, faute d'écosystème de recherche, de puissance de calcul et de communauté scientifique locale suffisants.
- Son propre parcours illustre ce constat : doctorante albanaise sans laboratoire de recherche ni calcul disponible dans son université d'origine, elle a découvert EEML par hasard, y a obtenu une bourse, et cette expérience a directement motivé la création, en 2023, d'AI Albania — d'abord sous la forme d'un atelier albanais d'apprentissage automatique organisé avec des chercheurs de Google DeepMind.
- AI Albania revendique aujourd'hui plus de 250 membres, 30 partenaires institutionnels, plus de 25 projets réalisés, organisés en neuf « clusters » thématiques (quantique, IA agentique, éthique de l'IA, etc.).
- Le projet phare actuellement en cours, ASDRN (Albanian Standard Dataset Registry for Emerging NLP), vise à construire les premiers jeux de données standardisés pour la langue albanaise — une langue à

faibles ressources numériques malgré ses 7,5 millions de locuteurs dans le monde — posant ainsi les bases d'un futur modèle de langage albanais ouvert, avec le soutien de programmes de recherche de Microsoft et de Google.

- D'autres initiatives incluent un hackathon régional annuel réunissant des participants de toute la région balkanique, un programme de ressources pédagogiques pour les enseignants, et une étude de perception de l'IA par les enseignants du primaire et du secondaire, menée en collaboration avec le laboratoire de démocratie délibérative de Stanford.

L'intervenante conclut en formulant l'ambition de son organisation : permettre à la prochaine génération de talents albanais de construire une carrière internationalement reconnue sans avoir à quitter le pays — condition qu'aucun des exemples cités en introduction n'avait pu remplir.

Partie II — Apprentissage profond géométrique

Cette intervention a été assurée par Petar Veličković, chercheur senior chez Google DeepMind et enseignant affilié à l'université de Cambridge, coauteur du livre de référence sur l'apprentissage profond géométrique (Geometric Deep Learning).

Chapitre 2. Symétrie, géométrie et groupes : le programme d'Erlangen

L'intervenant retrace, avant d'aborder le deep learning, l'histoire de la notion de symétrie en mathématiques, pour en tirer une méthode transposable à l'étude des architectures de réseaux de neurones.

Repères historiques

- Le terme même de symétrie remonte à Platon (« symmetria », « même mesure »), tandis que la géométrie, pendant plus de deux mille ans, s'est confondue avec la géométrie euclidienne et son postulat des parallèles (par un point extérieur à une droite, il passe exactement une parallèle à cette droite).
- Au XIXe siècle, plusieurs mathématiciens (Lobatchevski, Bolyai, puis Riemann) découvrent, indépendamment, des géométries entièrement cohérentes où ce postulat ne tient plus (géométrie hyperbolique, où plusieurs parallèles sont possibles ; géométrie elliptique, où aucune ne l'est) — bouleversant la croyance en une géométrie euclidienne unique et nécessaire.
- Face à cette prolifération de géométries, Felix Klein propose en 1872, dans son « programme d'Erlangen », de les organiser non plus par leurs objets mais par leurs symétries : ce qui définit une géométrie, ce sont les transformations sous lesquelles ses propriétés restent invariantes.
- Ce programme a eu une influence considérable bien au-delà des mathématiques : il est à l'origine de la théorie des catégories (Eilenberg et Mac Lane citent explicitement Klein), et a inspiré en physique le théorème de Noether (reliant symétries et lois de conservation) puis le modèle standard des particules élémentaires.

L'intervenant propose alors une analogie directe : de même que la géométrie du XIXe siècle a connu une prolifération d'objets divers avant d'être unifiée par la théorie des groupes, l'apprentissage profond des années 2020 connaît une prolifération d'architectures spécialisées (CNN, GNN, LSTM, transformeurs…) qui peuvent, elles aussi, être organisées et comprises à travers les symétries qu'elles respectent — c'est tout l'objet du « plan directeur » de l'apprentissage profond géométrique (Geometric Deep Learning, GDL).

Chapitre 3. Le plan directeur du GDL : invariance et équivariance

Avant de construire ce plan directeur, l'intervenant répond à une objection fréquente : à l'ère des transformeurs, qui semblent se passer de toute contrainte géométrique explicite, étudier les symétries serait-il devenu une « distraction pour matheux » ? Il propose quatre raisons de continuer à s'y intéresser malgré tout : mieux comprendre les données naturelles (intrinsèquement structurées), mieux comprendre les contraintes cachées des transformeurs eux-mêmes, savoir pourquoi certaines architectures (CNN notamment) prennent nécessairement la forme qu'elles ont, et savoir construire des réseaux sur des structures de données non standard (sphères, maillages, etc.).

Définitions fondamentales

- Une transformation de symétrie d'un objet est une application inversible qui préserve la structure de cet objet — par exemple, une rotation de 120° d'un triangle équilatéral le laisse identique à lui-même.

- Une fonction est dite invariante à une symétrie si son résultat ne change pas lorsqu'on applique cette symétrie à son entrée (exemple : un classifieur chat/chien doit donner la même réponse quelle que soit l'orientation de la photo).
- Une fonction est dite équivariante à une symétrie si, lorsqu'on applique cette symétrie à l'entrée, la sortie se transforme de façon prévisible et correspondante (par exemple : décaler un objet dans une image doit décaler de façon identique la prédiction de sa position).
- L'outil mathématique central pour formaliser ces notions est le groupe (un ensemble muni d'une opération associative, avec un élément neutre et un inverse pour chaque élément), auquel on associe une représentation — une façon de traduire chaque transformation abstraite du groupe en une matrice concrète, exploitable par un réseau de neurones.

Le plan directeur du GDL consiste alors à spécifier, pour tout problème donné, un domaine (l'ensemble des positions où vivent les données : grille, ensemble, graphe…), un signal (les données elles-mêmes, définies sur ce domaine), un groupe de symétrie pertinent, et une représentation de ce groupe — à partir de quoi on peut construire une architecture alternant couches équivariantes, non-linéarités équivariantes, et une opération d'invariance finale si une seule prédiction globale est requise.

Détails et formalisation complète de l'invariance et de l'équivariance (diagrammes commutatifs) : voir Annexe A.1.

Chapitre 4. Graphes et transformeurs : les LLM sont des réseaux de passage de messages

L'intervenant applique d'abord ce cadre aux graphes — des ensembles de nœuds reliés par des arêtes — avant de démontrer, en direct, que l'architecture transformeur n'est rien d'autre qu'un cas particulier de réseau de neurones sur graphe.

Idées clés

- La contrainte de symétrie naturelle des graphes est l'invariance (ou l'équivariance) par permutation : l'ordre dans lequel on numérote les nœuds d'un graphe est arbitraire, et un modèle correct ne doit pas dépendre de ce choix.
- Cette contrainte est satisfaite en rendant chaque calcul local : chaque nœud met à jour sa représentation en fonction de ses seules caractéristiques et de celles de ses voisins, agrégées par une fonction elle-même invariante par permutation (somme, moyenne, maximum…) — c'est le principe général du passage de messages (message passing) qui sous-tend l'ensemble des réseaux de neurones sur graphes (GNN).
- En représentant les jetons (tokens) d'une séquence comme les nœuds d'un graphe, et le masque causal des transformeurs comme la structure de voisinage de ce graphe (un jeton n'étant connecté qu'aux jetons qui le précèdent, afin d'éviter toute « triche » lors de la prédiction du jeton suivant), l'intervenant démontre par une réécriture algébrique que le mécanisme d'attention (numérateur et dénominateur du softmax) correspond exactement à un message, une agrégation par somme, et une fonction de mise à jour — autrement dit, un transformeur causal est un réseau de neurones sur graphe.
- Cette lecture explique directement pourquoi les transformeurs, malgré leur réputation de modèles « génériques », intègrent en réalité de fortes contraintes structurelles (partage de paramètres entre positions, interactions limitées à des paires de jetons) — ce qui rejoint les analyses présentées la veille par Federico Barbara sur les phénomènes de sur-mélange et d'effondrement de représentation dans les modèles à contexte long.

Détails et dérivation algébrique complète reliant l'attention aux passages de messages : voir Annexe A.2.

Chapitre 5. Grilles et convolutions : pourquoi les CNN sont incontournables

En restreignant la symétrie de permutation à la seule translation (le voisinage de chaque position d'une grille étant toujours identique, par exemple « un pixel à gauche, un pixel à droite »), l'intervenant montre que la classe de fonctions équivariantes qui en résulte se réduit exactement aux convolutions.

Idées clés

- Un opérateur linéaire équivariant par translation prend nécessairement la forme d'une matrice circulante — un ensemble fixe de coefficients qu'on fait glisser le long du signal.
- C'est un résultat classique du traitement du signal : toute fonction linéaire équivariante par décalage circulaire s'exprime nécessairement comme une convolution. Il n'existe donc, sous cette contrainte précise, aucun autre modèle valide qu'un réseau convolutif pour traiter une image avec une symétrie de translation.
- Ce résultat se généralise directement aux grilles multidimensionnelles (filtres 2D des CNN classiques), et une observation similaire, fondée sur l'invariance au changement de vitesse d'échantillonnage d'un signal temporel, explique pourquoi les réseaux récurrents à portes (LSTM, GRU) intègrent nécessairement des mécanismes de porte pour rester robustes à ce type de déformation.

Chapitre 6. Domaines exotiques : sphères, graphes géométriques et applications sportives

L'intervenant étend ensuite le cadre à des domaines plus exotiques : la sphère, les graphes intégrant des coordonnées spatiales en 3D, et des applications sportives concrètes.

Convolutions sur la sphère

- Certaines données (signaux météorologiques, mesures astrophysiques) vivent naturellement à la surface d'une sphère, où la symétrie pertinente n'est plus la translation mais la rotation en trois dimensions.
- En appliquant la même logique de convolution généralisée à ce nouveau groupe de symétrie, on obtient les réseaux convolutifs sphériques — une architecture ayant remporté le prix du meilleur article à la conférence ICLR en 2018 — dont les couches successives opèrent sur l'espace des rotations 3D (le groupe SO(3)) plutôt que sur la sphère elle-même.

Graphes géométriques et molécules

- Pour des données comme les molécules, où les atomes possèdent à la fois des caractéristiques et des coordonnées spatiales, la symétrie pertinente combine permutation des nœuds et transformations rigides de l'espace 3D (rotations, translations, réflexions), formant le groupe euclidien E(3).
- Un réseau respectant cette symétrie peut, par exemple, ne faire dépendre ses caractéristiques scalaires que des distances entre atomes (invariantes par construction à ces transformations), tandis que la mise à jour des coordonnées elles-mêmes doit rester équivariante à ces mêmes transformations.

Application au football (TacticAI)

- En football, une symétrie approximative — le groupe diédral D2, correspondant aux symétries horizontale et verticale du terrain — permet de traiter les corners joués dans les quatre coins du terrain comme des variantes d'une même situation.

- Exploitée dans le modèle TacticAI (développé avec le club de Liverpool FC, publié dans Nature Communications), cette contrainte améliore significativement l'efficacité des données disponibles, une ressource rare en football professionnel (peu de matchs joués chaque saison) ; le modèle est aujourd'hui utilisé par plusieurs clubs professionnels, notamment pour l'analyse de corners et, plus récemment, pour la prédiction d'actions de jeu ouvert.

Chapitre 7. Variétés et jauges : d'AlphaFold aux maillages

Le dernier domaine abordé est celui des variétés (manifolds) — des surfaces courbes plus générales qu'une simple sphère, comme celles rencontrées en modélisation de protéines ou en aérodynamique — qui nécessitent l'introduction d'une nouvelle forme de symétrie, la symétrie de jauge (gauge symmetry).

Idées clés

- Une variété est un objet qui ressemble localement, au voisinage de chaque point, à un plan (son espace tangent), même si elle est globalement courbée.
- Contrairement à une grille, il n'existe pas de moyen canonique et continu de choisir un système de coordonnées (une jauge) en tout point d'une variété courbe — un résultat connu sous le nom de théorème de la boule chevelue (hairy ball theorem) : on ne peut pas « peigner » une sphère sans créer au moins un épi (une singularité).
- Un modèle correct sur une variété doit donc être équivariant à tout changement local de jauge, ce qui se ramène en pratique, grâce au transport parallèle (le fait de faire pivoter un vecteur d'un point à un autre le long de la surface), à une contrainte d'équivariance locale par rotation, relativement simple à mettre en œuvre malgré l'apparente complexité du problème général.
- Ce même principe — maintenir un référentiel local et prédire des coordonnées par rapport à ce référentiel — est au cœur du fonctionnement d'AlphaFold 2, première architecture équivariante ayant contribué à l'attribution d'un prix Nobel : chaque acide aminé d'une protéine se voit associer un référentiel local, à partir duquel sont prédites les positions de tous ses atomes.

Détails sur le transport parallèle et la dérivation de la couche équivariante de jauge : voir Annexe A.3.

Partie III — Réécrire les règles de la trajectoire professionnelle

Cette intervention, de nature plus personnelle et inspirante que technique, a été assurée par Dorothy Chou, conseillère stratégique chez Google DeepMind, à partir de vingt années d'expérience dans l'industrie technologique (Google, Dropbox, Uber, puis DeepMind).

Chapitre 8. Trois mythes hérités, et comment les réécrire

L'intervenante identifie trois croyances implicites, largement partagées par les jeunes chercheurs de la région, qu'elle invite chacun à interroger plutôt qu'à accepter telles quelles.

Mythe 1 — La réussite se joue en battant les autres

- S'appuyant sur son propre parcours (notamment un épisode où elle a été critiquée, en interne chez Google, pour avoir partagé la responsabilité d'un projet stratégique plutôt que de la garder pour elle seule), l'intervenante avance que la collaboration, et non la compétition individuelle, est le facteur déterminant de réussite dans ce domaine.
- Elle cite la première cause de mortalité des startups — non pas le manque de marché ou de financement, mais la rupture entre cofondateurs — ainsi que l'exemple d'AlphaFold, présenté comme le fruit de décennies de données ouvertes et de collaborations croisées plutôt que d'un génie solitaire.

Mythe 2 — Il faut attendre d'être pleinement qualifié pour se lancer

- L'intervenante oppose l'exemple d'une fondatrice qu'elle a personnellement soutenue, ancienne ingénieure senior chez DeepMind portant un produit fonctionnel et des utilisateurs payants, mais n'ayant pas réussi à lever les fonds nécessaires, à des exemples médiatisés de personnes levant des sommes considérables sur la seule base d'un projet de diapositives.
- Sa conclusion est que les qualifications formelles pèsent souvent moins, dans les décisions de financement ou de recrutement, que la clarté de conviction et la ténacité de la personne — et qu'un refus doit être lu comme la limite de la vision de son interlocuteur, non comme un jugement définitif sur sa propre valeur.

Mythe 3 — Les structures existantes sont immuables, et il faut partir pour compter

- L'intervenante cite un chiffre pour illustrer les effets de cette croyance à l'échelle du secteur : au premier trimestre de l'année en cours, près des deux tiers du capital-risque mondial se seraient concentrés sur seulement quatre entreprises — une concentration qu'elle attribue moins à un manque de talent ou de capital qu'à un manque collectif d'imagination sur les lieux et les façons possibles de construire.
- Elle prend pour contre-exemple InstaDeep, entreprise fondée en Tunisie et rachetée par BioNTech, dont les travaux sur le suivi géographique des maladies infectieuses illustrent qu'un ancrage régional peut constituer un avantage — permettant de percevoir des problèmes que d'autres, plus éloignés, ne voient pas — plutôt qu'un handicap.
- Elle invite en particulier les femmes présentes dans la salle, soulignant l'équilibre de genre relativement favorable des universités de la région comparé à d'autres pays européens, à s'appuyer sur des réseaux tels que Women in Machine Learning, et rappelle enfin que la structure interdisciplinaire de DeepMind lui-même (chercheurs de disciplines très différentes réunis autour d'un même tableau blanc, à l'origine par exemple d'AlphaFold) est elle-même le résultat d'un choix délibéré de réécrire les règles habituelles d'organisation de la recherche.

Partie IV — Ce que signifie (vraiment) travailler sur l'éthique de l'IA

Cette dernière intervention de l'école a été assurée par un chercheur désigné dans la transcription sous le nom de Magd, ancien membre de l'équipe d'IA éthique de Google (dont il a démissionné, selon ses propres mots, « pour des raisons éthiques »), aujourd'hui professeur à l'École Polytechnique à Paris. L'exposé, volontairement provocateur dans son titre — « pourquoi je ne recommande pas de travailler sur l'éthique de l'IA » —, vise moins à décourager qu'à exposer honnêtement les réalités concrètes de ce champ de recherche.

Chapitre 9. Distinguer l'éthique de l'IA des questions de sécurité et d'ingénierie

L'intervenant commence par retirer de la catégorie « éthique de l'IA » un ensemble de sujets qui y sont fréquemment rattachés à tort, selon lui, y compris dans le cadre de cette même école d'été.

Idées clés

- Des sujets tels que l'apprentissage automatique adversarial (empoisonnement de données, évasion de modèles, extraction de données), l'interruptibilité sûre d'un système d'IA, la protection et la vérification de la propriété des données, ou l'alignement d'un modèle avec un objectif donné, sont selon l'intervenant des questions scientifiques et techniques — pas des questions d'éthique.
- Son argument est que ces sujets répondent à des besoins et à des normes déjà définis par la société (par exemple, des lois anciennes protégeant le secret de la correspondance) : le rôle du chercheur y consiste à concevoir une solution technique permettant de respecter une règle déjà établie, non à déterminer ce qui devrait être fait.
- L'éthique, par contraste, est définie comme l'étude de ce qui devrait être fait — une question normative plutôt que technique — étant entendu qu'il existe une boucle de rétroaction entre les deux : une découverte technique (une nouvelle capacité de violation de la vie privée, par exemple) peut informer en retour la réflexion éthique sur ce qui devrait être interdit ou régulé.

Chapitre 10. Le coût personnel : les effets Sagan et Gabru sur la carrière

L'intervenant introduit ensuite un coût de carrière spécifique et documenté, associé au fait de s'engager publiquement sur les questions sociétales de l'IA.

Idées clés

- L'effet Sagan, nommé d'après l'astrophysicien Carl Sagan, désigne le fait que les pairs d'un scientifique tendent à sous-estimer sa productivité et sa rigueur scientifiques dès lors qu'il s'engage dans la vulgarisation ou la communication publique — un phénomène documenté empiriquement dans la littérature, et qui a par exemple contribué au fait que Sagan, malgré une production scientifique supérieure au seuil habituel, n'ait jamais été élu à l'Académie nationale des sciences américaine.
- L'intervenant décrit un phénomène analogue, qu'il nomme par extension « effet Gabru » (du nom de la chercheuse Timnit Gebru), chez les personnes travaillant aujourd'hui sur les conséquences sociétales de l'IA : leur compétence technique tend à être systématiquement sous-estimée par leurs pairs, y compris lorsque leur formation technique est solide et documentée (il rappelle par exemple que Gebru a participé au développement matériel de l'iPad chez Apple avant de rejoindre le champ de l'éthique de l'IA).
- La conséquence concrète, selon l'intervenant, est que les chercheurs travaillant sur ces questions doivent s'attendre, lors d'entretiens d'embauche ou d'évaluations de carrière, à être perçus comme

moins rigoureux techniquement — voire à être qualifiés d'« activistes » plutôt que de scientifiques — quelle que soit la qualité réelle de leur travail.

Chapitre 11. Où peut-on — et ne peut-on pas — mener ce travail ?

L'intervenant passe en revue, un par un, les environnements institutionnels où l'on pourrait espérer mener ce type de recherche, pour conclure qu'aucun d'entre eux, en l'état actuel des choses, n'offre selon lui les conditions nécessaires.

Environnement	Limite identifiée par l'intervenant
Entreprise privée	Autocensure structurelle : impossible d'étudier de façon indépendante des pratiques qui iraient à l'encontre des intérêts commerciaux de l'employeur ; les sujets autorisés restent, selon l'intervenant, superficiels et consensuels.
Institution publique / université	Absence d'accès aux données pertinentes (détenues par les entreprises privées), contraignant le chercheur à des travaux spéculatifs ou empiriquement peu étayés, faute de terrain d'étude accessible.
États et régulateurs	Manque actuel de moyens humains, financiers et techniques pour auditer véritablement les grandes entreprises technologiques, contrairement à ce qui se pratique déjà dans d'autres secteurs industriels.

L'intervenant illustre cette impasse par un exemple concret : il serait, selon lui, impossible d'étudier depuis l'intérieur d'une grande entreprise technologique la façon dont certains régimes autoritaires utilisent les systèmes de recommandation des réseaux sociaux à des fins de répression psychologique — un sujet qu'il juge pourtant légitime, mais structurellement hors de portée dans le cadre institutionnel actuel.

Chapitre 12. Défis techniques propres à l'étude des impacts sociétaux de l'IA

Au-delà des contraintes institutionnelles, l'intervenant identifie des difficultés proprement méthodologiques, qui distinguent ce champ de recherche des problèmes d'apprentissage automatique plus classiques.

Idées clés

- L'absence de vérité de terrain (ground truth) fiable : contrairement à un jeu de données comme MNIST, où l'étiquette correcte d'une image ne fait guère débat, il n'existe généralement pas de label objectivement correct pour des données décrivant des interactions sociales complexes (discours haineux, désinformation, etc.).
- Le travail d'annotation de données repose largement sur une main-d'œuvre payée, souvent dans des conditions de travail documentées comme problématiques ; ce travail reste peu étudié, en partie parce qu'il est structurellement invisibilisé dans les organisations qui en dépendent — l'intervenant note, à titre d'illustration personnelle, n'avoir jamais entendu quiconque, dans une entreprise technologique, désigner spontanément les annotateurs de données comme des « collègues ».
- L'intervenant identifie néanmoins un sous-domaine qu'il juge praticable sans nécessiter d'accès à des données sensibles : la théorie du choix social (social choice theory), qui permet de formaliser mathématiquement, par exemple, l'entraînement collaboratif d'un modèle comme une forme de vote agrégeant les préférences implicites contenues dans chaque paire donnée-étiquette.

Détails et illustration du problème de l'absence de vérité de terrain : voir Annexe B.1.

Chapitre 13. Le véritable goulot d'étranglement est politique, non technique

L'intervenant conclut son exposé, largement prolongé par les échanges avec le public, en formulant sa thèse centrale : les progrès substantiels attendus dans ce domaine ne viendront pas d'une meilleure fonction de perte, mais d'une évolution des structures politiques, juridiques et de gouvernance.

Idées clés

- Un exemple récurrent est celui des réseaux sociaux, dont l'objectif d'optimisation (maximiser le temps passé sur la plateforme, illustré par une citation attribuée au PDG de Netflix selon laquelle « notre principal concurrent est le sommeil ») est aujourd'hui bien identifié et documenté, sans que cela ait, à ce jour, entraîné de conséquences juridiques substantielles pour les entreprises concernées — bien que l'Union européenne commence, selon l'intervenant, à agir sur ce terrain.
- L'intervenant relève un phénomène de deux poids, deux mesures dans l'écosystème international de la recherche : il cite l'exemple d'une conférence scientifique majeure accueillant un stand sponsorisé portant le nom d'un dirigeant politique controversé, une situation qu'il juge impensable si elle impliquait des dirigeants occidentaux, et qu'il présente comme une source d'usure pour quiconque s'engage dans ce champ.
- Face à une question sur la responsabilité individuelle des ingénieurs et chercheurs impliqués dans des systèmes controversés, l'intervenant plaide pour une responsabilité concentrée sur les directions d'entreprise plutôt que sur les employés techniques, ces derniers ayant le plus souvent, selon son expérience des dossiers documentés, signalé les problèmes en interne sans que cela n'entraîne de changement de politique.
- En conclusion, l'intervenant recommande explicitement aux étudiants présents de mesurer, avant de s'engager dans ce champ, le décalage entre l'importance collective de ce travail pour la société et son coût individuel pour la carrière de celui ou celle qui le mène — recommandant à certains de commencer par des activités plus rémunératrices avant de s'y consacrer, et rappelant que ce travail gagne à être mené collectivement plutôt qu'isolément.

Conclusion générale

Cette dernière journée, clôturant l'école d'été, relie des thèmes en apparence très éloignés — écosystème régional de recherche, mathématiques des symétries, trajectoires de carrière, éthique de l'IA — autour d'une même question implicite : quelles structures, souvent présentées comme données ou immuables, méritent en réalité d'être interrogées et, le cas échéant, réécrites ?

Fils conducteurs de la journée

- La présentation d'AI Albania illustre, à l'échelle d'un pays, la construction volontaire d'une structure de recherche là où elle faisait défaut — un thème qui rejoint directement l'intervention de Suad Glass le jour précédent sur l'engagement communautaire.
- L'exposé de Petar Veličković montre comment une même grille de lecture mathématique (les symétries et leurs groupes) permet d'unifier et de justifier rigoureusement des architectures de deep learning en apparence disparates — des CNN aux transformeurs jusqu'à AlphaFold — prolongeant ainsi, sous un angle différent, les analyses sur les contraintes structurelles des transformeurs déjà abordées dans la semaine.
- L'intervention de Dorothy Chou invite à interroger les règles implicites de la compétition, de la légitimité et de la localisation géographique qui façonnent les trajectoires de carrière en intelligence artificielle, en particulier pour les chercheurs de la région.
- L'exposé final sur l'éthique de l'IA referme la boucle en montrant que les limites les plus difficiles à surmonter dans ce domaine ne sont pas d'ordre mathématique, mais institutionnel, professionnel et politique — un message qui, par contraste, met en perspective l'essentiel des contenus plus techniques présentés au cours des journées précédentes.

Ce document restitue les notions abordées dans un cadre pédagogique et objectif ; les nombreux échanges avec le public lors des deux dernières interventions, particulièrement riches, n'ont pu être que partiellement synthétisés dans le corps du texte et l'annexe.

Annexe — Approfondissements par chapitre

Cette annexe reprend, chapitre par chapitre, les développements techniques qui étayent les synthèses présentées dans le corps du document.

A.1 — Formalisation de l'invariance et de l'équivariance (complément du chapitre 3)

Pour un groupe de symétrie G agissant sur un espace d'entrée X (par exemple, une action ρ_X(g) transformant l'entrée), une fonction f est dite invariante à G si, pour tout élément g du groupe, f(ρ_X(g)·x) = f(x) : le résultat ne dépend pas de la transformation appliquée en amont. Elle est dite équivariante à G s'il existe une seconde action ρ_Y(g), définie sur l'espace de sortie, telle que f(ρ_X(g)·x) = ρ_Y(g)·f(x) — c'est-à-dire qu'appliquer la symétrie avant ou après la fonction donne le même résultat, à condition de transformer la sortie selon sa propre action ρ_Y. L'invariance est un cas particulier de l'équivariance, obtenu lorsque ρ_Y est l'identité (la sortie ne change jamais).

Une représentation ρ d'un groupe associe à chaque élément g du groupe une matrice, de telle sorte que la représentation de l'élément neutre soit la matrice identité, et que la représentation d'une composition de deux éléments soit égale au produit des représentations de chaque élément séparément ($\rho(g_1 g_2) = \rho(g_1)\rho(g_2)$) — cette propriété garantissant que les matrices respectent fidèlement la structure algébrique du groupe. Exemple donné en séance : le groupe SO(2) des rotations planes est représenté par les matrices de rotation habituelles (cosinus, sinus) ; le groupe des permutations de n objets est représenté par des matrices de permutation, obtenues en réarrangeant les lignes ou colonnes de la matrice identité.

A.2 — Dérivation complète : l'attention comme passage de messages (complément du chapitre 4)

Pour établir l'équivalence, l'intervenant part de la formule standard de l'attention par produit scalaire : chaque coefficient d'attention α (obtenu par un softmax sur les logits, eux-mêmes calculés à partir du produit scalaire d'une requête et d'une clé) pondère un vecteur de valeur, et la somme pondérée de ces valeurs constitue la nouvelle représentation du jeton receveur.

En réécrivant explicitement le softmax comme une fraction (un numérateur exponentiel divisé par une somme de termes exponentiels sur l'ensemble des voisins autorisés par le masque causal), on peut définir un message comme la paire formée par le numérateur partiel (produit de l'exponentielle du logit et du vecteur de valeur) et le dénominateur partiel (l'exponentielle du logit seule) associés à chaque voisin. L'agrégation de ces messages sur l'ensemble des voisins se fait alors par une simple somme (une opération invariante par permutation, comme l'exige la contrainte de passage de messages), et la fonction de mise à jour finale se réduit à la division du numérateur agrégé par le dénominateur agrégé — retrouvant exactement le résultat du softmax d'origine. La fonction de mise à jour globale du jeton correspond, elle, au réseau à propagation directe (feed-forward network) partagé et appliqué indépendamment à chaque jeton dans un bloc transformeur.

Un point de vigilance signalé par l'intervenant : contrairement à un graphe standard, le graphe sous-jacent à un transformeur causal (défini par le masque d'attention) doit lui-même être permuté de façon cohérente avec les jetons lorsqu'on vérifie la condition d'équivariance par permutation — la structure de voisinage n'est donc pas fixe indépendamment de l'ordre des jetons, contrairement à un graphe moléculaire par exemple.

A.3 — Transport parallèle et couche équivariante de jauge (complément du chapitre 7)

Trois notions successives permettent de manipuler des données sur une variété courbe : l'espace tangent en un point (une approximation locale de la variété par un plan, où l'on peut stocker et manipuler des vecteurs comme dans un espace euclidien ordinaire) ; l'application exponentielle, qui permet de reprojeter un vecteur de l'espace tangent sur la variété elle-même ; et le transport parallèle, qui permet de déplacer un vecteur défini dans l'espace tangent d'un point vers l'espace tangent d'un point voisin, le long de la surface, en préservant son orientation relative.

Plutôt que d'exiger une équivariance simultanée à deux jauges arbitraires et différentes (une pour chaque nœud impliqué dans le passage de message, condition jugée trop complexe à vérifier et à implémenter), l'astuce mathématique présentée consiste à ramener le problème à une équivariance locale à un seul nœud à la fois, en transportant d'abord parallèlement le vecteur du nœud voisin vers le référentiel du nœud receveur — cette opération de transport se réduisant, dans le cas d'une variété localement plane à deux dimensions, à une simple rotation, prédéterminée uniquement par la géométrie de la variété (et non apprise). La couche résultante ressemble alors, formellement, à un réseau de neurones sur graphe standard, à ceci près que les caractéristiques vectorielles des voisins doivent être transportées (pivotées) avant d'être agrégées, et que les matrices de poids doivent elles-mêmes dépendre des angles relatifs entre les référentiels locaux, afin de garantir la symétrie de rotation recherchée en sortie.

B.1 — L'absence de vérité de terrain en apprentissage supervisé sociétal (complément du chapitre 12)

L'intervenant illustre ce problème par contraste avec un jeu de données classique comme MNIST (chiffres manuscrits), où l'étiquette correcte d'une image, bien qu'occasionnellement ambiguë (un « 7 » mal formé pouvant ressembler à un « 1 »), fait globalement consensus. Dès lors que les données décrivent des relations sociales complexes — un commentaire en ligne, une interaction entre individus — la notion même d'étiquette « correcte » devient discutable : deux annotateurs raisonnables peuvent légitimement diverger, sans qu'il existe de procédure objective pour trancher entre eux, ce qui remet en question la validité même de l'approche par apprentissage supervisé classique pour de tels problèmes.

Conclusion personnelle

Arrivé au terme de ce travail, je mesure combien cette semaine suivie à distance a dépassé ce que j'en attendais au départ. J'espérais consolider quelques notions de deep learning ; j'en ressors avec une carte beaucoup plus large de ce qui structure la recherche actuelle en intelligence artificielle — des fondements mathématiques des réseaux de neurones jusqu'aux questions les plus concrètes de déploiement, de financement et d'éthique.

Plusieurs fils me semblent traverser l'ensemble des six journées, au-delà de leurs sujets respectifs. Le premier est la place centrale de la géométrie et des symétries comme grille de lecture : elle relie, sans que cela soit toujours explicite au moment de l'écoute, la lecture géométrique des représentations du premier jour, l'apprentissage profond géométrique du dernier jour, et jusqu'aux réseaux sur graphes utilisés en mathématiques ou en biomédecine. Le second est la tension récurrente entre théorie et échelle : ce qui fonctionne parfaitement sur le papier (l'élagage optimal d'un réseau, l'inversion d'une matrice hessienne, la vérification exacte d'une symétrie) devient souvent impraticable dès qu'on l'applique à des modèles de plusieurs milliards de paramètres, ce qui pousse la recherche vers des approximations ingénieuses plutôt que vers l'abandon de l'idée d'origine. Le troisième, plus inattendu pour moi, est la fréquence avec laquelle les interventions les plus techniques ont été suivies, la même semaine, d'interventions qui interrogeaient leurs conditions humaines et sociales de production — le coût du bénévolat, les règles implicites d'une trajectoire de carrière, le prix personnel de s'engager sur l'éthique de l'IA.

Sur un plan plus personnel, ce travail de mise en forme m'a été utile en lui-même : reformuler un contenu dense oblige à vérifier qu'on l'a réellement compris, et pas seulement entendu. Je garde de cette semaine plusieurs pistes concrètes à approfondir dans la suite de mon parcours — en particulier tout ce qui touche à la géométrie des représentations et à l'apprentissage par renforcement appliqué aux grands modèles de langage, deux fils que je retrouve, sous des formes différentes, dans presque chacune des six journées. Je garde aussi, plus simplement, la conviction qu'il existe une communauté de recherche active dans cette région du monde, et qu'y participer — même à distance, même depuis le Bénin — reste possible et utile.

Ce document n'a pas vocation à remplacer les contenus originaux de l'école d'été, dont il ne restitue qu'une lecture partielle et personnelle. Il vise plus modestement à me servir, dans les mois et les années qui viennent, de point de départ fiable pour revenir sur ces notions — et, je l'espère, à pouvoir servir de la même façon à toute personne qui, comme moi, aurait suivi cette semaine à distance et chercherait à en garder une trace structurée.